

STANFORD RNA 3D FOLDING THESIS

RNA 3D Final Pipeline — White-box

TBM, pretrained, Geometry v2, GeoFuse và submission qua ví dụ thật

Generated 2026-07-29

Mục lục


1. Pipeline làm gì trong một câu?
2. Hai ví dụ thật dùng trong tài liệu
 - Ví dụ A — R1108 cho TBM, pretrained và metric
 - Ví dụ B — 8K0Y_A cho GeoFuse confirmatory
3. Data thực sự có gì?
 - 3.1 Competition tables
 - 3.2 PDB_RNA template library
 - 3.3 Dữ liệu nào không đi vào pipeline cuối?
4. Chuẩn bị offline một lần
5. TBM white-box
 - 5.1 Bước T1 — nhận target
 - 5.2 Bước T2 — MMseqs prefilter
 - K-mer là gì?
 - Tham số thực tế
 - MMseqs trả gì?
 - 5.3 Bước T3 — exhaustive composite search
 - 5.4 Bước T4 — temporal/self filter
 - 5.5 Bước T5 — merge, realign và rank
 - 5.6 Bước T6 — alignment và chuyển tọa độ
 - 5.7 Bước T7 — gap filling
 - 5.8 Bước T8 — chọn nhiều template
 - 5.9 TBM-only đã được submit gì?
6. Pretrained white-box
 - 6.1 DRfold2 thực hiện gì?
 - 6.2 Confidence không phải “độ đúng”
 - 6.3 Vì sao pretrained vẫn cần?
 - 6.4 Boltz nằm ở đâu?
7. Geometry v2 white-box
 - 7.1 Priors được học thế nào?
 - 7.2 Objective được tối ưu
 - 7.3 Bảng chứng module
8. GeoFuse white-box
 - 8.1 OOF là gì?
 - 8.2 Bước G1 — cluster theo global fold
 - 8.3 Bước G2 — robust superposition và local disagreement
 - 8.4 Bước G3 — router dự đoán source tốt hơn
 - 8.5 Bước G4 — selective fusion hoặc abstain
 - 8.6 Ví dụ 8K0Y_A
 - 8.7 Kết quả confirmatory của GeoFuse
9. Chọn final five và ghi submission
 - 9.1 Native-blind selection
 - 9.2 Schema
 - 9.3 Trạng thái submission cần nói rõ
10. Người ta làm gì, mình dùng lại gì, cái gì mới?
 - 10.1 Top-1 TBM notebook
 - 10.2 Top-1 hybrid notebook
 - 10.3 Phần kế thừa và phần của thesis
11. Pseudocode cuối
12. Glossary ngắn

Mục đích của tài liệu. Đây là bản giải thích đúng một đường chạy cuối, không phải nhật ký mọi thử nghiệm đã từng làm. Mỗi block đều trả lời bốn câu: nhận gì, tính gì, quyết định gì, trả ra gì. Những con số gắn nhãn “evaluation” chỉ được tính sau khi prediction đã hoàn tất; chúng không được dùng để chọn cấu trúc lúc inference.

1. Pipeline làm gì trong một câu?

Cho một chuỗi RNA và mốc thời gian được phép sử dụng dữ liệu, pipeline:

1. tìm các RNA cũ có thể làm **template**;
2. xin thêm các giả thuyết cấu trúc từ **DRfold2 pretrained**;
3. sửa nhẹ hình học cục bộ bằng **Geometry v2**, không đổi fold một cách tùy tiện;
4. chỉ ghép TBM với pretrained khi **GeoFuse** có đủ bằng chứng theo từng đoạn;
5. nếu không đủ bằng chứng thì **abstain** — từ chối ghép và giữ nguyên các cấu trúc cha;
6. chọn năm cấu trúc vừa đáng tin vừa khác nhau và ghi ra `submission.csv`.



Đầu vào và đầu ra cho target dài `L`:

INPUT

```
target_id
sequence: L ký tự A/U/G/C
temporal_cutoff
```

OUTPUT

```
5 structures × L residues × 3 tọa độ C1'
shape = [5, L, 3]
```

Vị trí tuyệt đối trong không gian không quan trọng: quay hoặc tịnh tiến cả cấu trúc vẫn là cùng một hình dạng. Điều cần dự đoán là quan hệ hình học tương đối giữa các nucleotide.

2. Hai ví dụ thật dùng trong tài liệu

Ví dụ A — R1108 cho TBM, pretrained và metric

```
target_id:      R1108
length:         69 nucleotide
temporal_cutoff: 2022-05-27
sequence:
GGGGGCCACAGCAGAAGCGUUCACGUCGCGGGCCCGUGUCAGCCAUUGCACUCCGGCUGCGAAUUCUGCU
```

R1108 là target validation CASP15. Nó phù hợp để giải thích search vì:

- raw database có template gần như native nhưng chúng phải bị loại bởi ngày/self-filter;
- MMseqs tìm được các đoạn giống ngắn;
- exhaustive composite tìm thêm 1DRZ_B, template tốt mà nhánh nhanh bỏ sót;
- DRfold2 tạo một candidate tốt hơn TBM trên target này.

Ví dụ B — 8K0Y_A cho GeoFuse confirmatory

```
target_id:      8K0Y_A
length:         56 nucleotide
temporal_cutoff: 2025-01-15
sequence:
GACGCCGGUGGUGGCACUCCUGGUUUUCAGGACGGGGUUCAAUUCUCCUGCGGUGUC
```

GeoFuse được kiểm tra confirmatory trên một cohort mới hơn, post-2023 và family/temporal-safe. Vì vậy phần fusion dùng 8K0Y_A, không tráo kết quả từ R1108 vào protocol mới.

3. Data thực sự có gì?

3.1 Competition tables

Data	Nội dung	Có được dùng lúc inference?
*_sequences.csv	ID, chuỗi, cutoff, mô tả	Có
train_labels*.csv	C1' coordinates của RNA cũ	Chỉ để học prior/calibration hợp lệ
validation_labels.csv	native của validation	Không; chỉ mở sau để chấm
test_sequences.csv	sequence phải predict	Có
sample_submission.csv	đúng schema và thứ tự dòng	Có

Native là cấu trúc thực nghiệm dùng làm đáp án đánh giá. “Không nhìn native” nghĩa là không đọc tọa độ của chính target khi tạo/chọn prediction.

3.2 PDB_RNA template library

PDB là kho cấu trúc đại phân tử đã được giải bằng thực nghiệm. Mỗi file CIF có nhiều chain; pipeline parse thành:

```
chain_key
pdb_id
RNA sequence
C1' coordinates
resolved mask
release_date
polymer metadata
```

Audit hiện có:

```
8,670 CIF
→ 23,869 RNA hoặc RNA-DNA chains
→ khoảng 10.86 triệu residues
```

Artifact của kernel Kaggle chứa khoảng 20,844 chain tìm được bằng MMseqs và một library composite đã khử trùng sequence gồm 7,155 entry. Các số khác nhau vì đây là hai artifact search với luật lọc/dedup khác nhau, không phải hai “train set” mâu thuẫn.

3.3 Dữ liệu nào không đi vào pipeline cuối?

MSA có trong competition data nhưng TBM của repo không dùng MSA. DRfold2 runner dùng đúng input mà model/checkpoint của nó yêu cầu; tài liệu không claim rằng MSA là một block riêng của TBM.

4. Chuẩn bị offline một lần

“Offline” nghĩa là làm trước khi một target test cụ thể được đưa vào dự đoán.

```
PDB_RNA/*.cif —parse—> template metadata + sequence + C1' coords
                        |
                        |—> MMseqs nucleotide DB
                        |—> deduplicated composite library

temporal-safe old labels —statistics—> Geometry v2 priors

DRfold2 repository + checkpoints ———> frozen pretrained runner
```


Hai nguyên tắc chống leakage:

- template phải có `release_date < target.temporal_cutoff` ;
- PDB được khai báo là structure/reference của chính target phải bị loại.

Với pretrained evaluation, repo còn audit cutoff huấn luyện structural của model và family overlap. Đây là lý do tập confirmatory mới hơn được chia theo thời gian và family.

5. TBM white-box

TBM — Template-Based Modeling: dự đoán cấu trúc target bằng cách tìm một RNA đã biết, align hai sequence, rồi chuyển hình dạng của template sang target.



5.1 Bước T1 — nhận target

TBM nhận:

```
R1108 sequence, L = 69
cutoff = 2022-05-27
exclude PDB IDs = các reference ID của R1108
```

Nó chưa đọc `validation_labels` của R1108.

5.2 Bước T2 — MMseqs prefilter

K-mer là gì?

K-mer là đoạn con liên tiếp dài `k`. Dùng `k=3` để minh họa:

```
sequence: G G G G G C C
3-mers:   GGG, GGG, GGG, GGC, GCC
```

Code thật dùng `k=13`, không phải 3. Một seed dài hơn ít xuất hiện ngẫu nhiên hơn nhưng có thể bỏ sót họ hàng xa; seed ngắn tăng recall nhưng tốn RAM/thời gian và sinh nhiều hit.

MMseqs dùng prefilter seed để thu hẹp database rồi tạo alignment ứng viên. Không nên mô tả nó là “chỉ lấy giao của các exact k-mer”: implementation MMseqs còn có scoring và alignment nội bộ. K-mer ở đây là trực giác đúng cho bước tìm seed, không phải toàn bộ thuật toán.

Tham số thực tế

```
search type      = nucleotide
k                = 13
sensitivity      = 7.5
maximum hits     = 300
E-value threshold = 100
memory cap      = 3 GB
```

`k=13` được chọn vì nucleotide index mặc định `k=15` không vừa máy cũ khoảng 5 GB RAM. Mục tiêu của nhánh này là mở một lưới candidate đủ rộng; mọi hit tốt sẽ được realign lại ở bước sau.

MMseqs trả gì?

Mỗi dòng `.m8` có:

Field	Nghĩa
<code>pident</code>	% ký tự giống nhau trong đoạn alignment , không phải toàn target
<code>alnlen</code>	độ dài đoạn alignment
<code>qstart/qend</code>	đoạn tương ứng trên query
<code>tstart/tend</code>	đoạn tương ứng trên template
<code>bits</code>	bit score; lớn hơn thường là bằng chứng sequence mạnh hơn
<code>evaluate</code>	số hit tốt tương tự kỳ vọng do ngẫu nhiên; nhỏ hơn thường tốt hơn

R1108 có raw hit:

Hit	Raw evidence	Vì sao giữ/loại?
<code>7QR3_C/D</code>	100%, 69/69, bits 125	direct/self structure → loại
<code>7QR4_B</code>	98.5%, bits 121	release 2022-10-26 sau cutoff → loại
<code>3B02_B</code> , <code>1ZZN_B</code> , <code>1U6B_B</code> , ...	95.8% trên 24 residue, bits 40	cũ hơn cutoff → giữ để realign

Đoạn local 24 residue của `1U6B_B`:


```
R1108: UCAGCCAUUGCACUCCGGCUGCGA
1U6B_B: GCAGCCAUUGCACUCCGGCUGCGA
```

95.8% ở đây không có nghĩa hai chuỗi dài 69 giống nhau 95.8%. Sau global realignment, các candidate nhóm này có identity khoảng 0.5882 và coverage $68/69 = 0.9855$.

5.3 Bước T3 — exhaustive composite search

Exhaustive search ở đây là tính similarity của query với mọi entry hợp lệ trong library 7,155 unique sequences, thay vì chỉ xem shortlist do MMseqs trả về.

Mỗi pair nhận bốn score:

$$S = 0.4 S_{\text{global}} + 0.3 S_{\text{local}} + 0.2 S_{\text{feature}} + 0.1 S_{\text{3-mer}}$$

- **Global alignment:** bắt đầu—kết thúc toàn chuỗi; trả lời “hai chuỗi giống nhau tổng thể đến đâu?”.
- **Local alignment:** tìm đoạn con giống nhất; trả lời “có motif/đoạn nào rất giống không?”.
- **RNA feature cosine:** cosine similarity giữa vector thành phần A/U/G/C, dinucleotide, GC/AU, purine/pyrimidine, entropy, length, repeat content.
- **3-mer Jaccard:** $|A \cap B| / |A \cup B|$ trên tập các đoạn 3 ký tự.

Đây là search **high-recall**: mục tiêu là không bỏ lỡ một template xa nhưng có fold hữu ích. Nó không chứng minh hai RNA có cùng chức năng sinh học.

Với R1108, composite tìm 1DRZ_B :

```
release date      1999-02-16      → temporal-safe
global score      0.4696
local score       0.5500
RNA-feature cosine 0.9954
3-mer Jaccard     0.6170
weighted score    0.6136
```

5.4 Bước T4 — temporal/self filter

Với từng template:

```
if release_date >= cutoff: drop
if pdb_id belongs to target/reference: drop
else: keep
```

Phải dùng dấu < nghiêm ngặt. Một cấu trúc công bố đúng hoặc sau ngày target không được giả vờ là đã tồn tại tại thời điểm dự đoán.

5.5 Bước T5 — merge, realign và rank

MMseqs và composite là hai nhánh độc lập:

```
MMseqs shortlist ─┐
                  └─ union → deduplicate → global realign → rank
composite shortlist ┘
```

Code không rank cuối bằng raw bit score hay raw composite score. Nó global-align lại target/template bằng:

```
match +2
mismatch -1
gap open -6
gap extend -0.5
end gaps unpenalized
```

Gap ở đầu/cuối không bị phạt cho phép một template partial nhưng có đoạn hỗ trợ dài vẫn được dùng.

Sau realignment:

$$\text{confidence} = \text{identity} \times \text{coverage} \times \text{completeness}$$

- **identity** : số nucleotide giống / số cột alignment không gap;
- **coverage** : số target residue nhận C1' thật / L ;
- **completeness** : số template residue có C1' / chiều dài template.

Với 1DRZ_B :

```
identity      = 0.6471
coverage      = 68/69 = 0.9855
completeness   = 1.0000
confidence    = 0.63768
```

TM = 0.49384 của candidate này chỉ được biết sau evaluation. Nó không tham gia công thức confidence.

5.6 Bước T6 — alignment và chuyển tọa độ

Alignment tạo mapping:

```
target residue i ↔ template residue j
```

Nếu j có tọa độ C1' hữu hạn:

```
target_coords[i] = template_coords[j]
support_mask[i] = true
```

Nếu target có insertion, hoặc C1' ở template không resolved:

```
target_coords[i] = NaN tạm thời
support_mask[i] = false
```

`support_mask` trả lời “tọa độ này có bằng chứng trực tiếp từ template không?”. Nó quan trọng hơn một kiểm tra `isfinite`: gap-fill cũng tạo số hữu hạn nhưng bằng chứng yếu hơn.

Với `1DRZ_B`, residue 1–68 được transfer; residue 69 không có template partner.

5.7 Bước T7 — gap filling

Submission không được chứa NaN, nên gap phải được dựng:

Loại gap	Cách dựng	Confidence
internal ngắn	nội suy giữa hai điểm hai bên	thấp, giảm vào giữa gap
internal dài	nội suy + độ cong sinus vuông góc	thấp
terminal	kéo theo hướng backbone gần nhất, khoảng 6 Å	0.1
không có điểm nào	extended chain fallback	0

Gap-fill là “tạo tọa độ hợp lệ để pipeline chạy”, không phải tuyên bố đoạn đó đúng.

5.8 Bước T8 — chọn nhiều template

Candidate được sort theo confidence. Pipeline lấy PDB khác nhau trước rồi mới backfill. Lý do: Kaggle chấm best-of-5; năm chain gần như trùng từ một PDB ít hữu ích hơn nhiều fold hypothesis.

R1108 khi bật composite chọn `1DRZ_B` trước nhóm partial MMseqs. Ablation cùng code, cùng 12 target:

```
MMseqs-only          0.2117
MMseqs + exhaustive  0.3072
delta                +0.0955 TM
top-1 TBM reproduction 0.2983
ours - reproduction   +0.0089
```

Trên riêng R1108:

```
MMseqs-only best-of-5    0.3124
+ composite              0.4889
delta                   +0.1765
top-1 reproduction      0.4767
```

Đây là attribution hợp lệ vì chỉ một block bị bật/tắt trên cùng target/protocol.

5.9 TBM-only đã được submit gì?


Late submission private/public 0.60175/0.60084 là kernel **TBM-only** của repo, không có DRfold2, Boltz hay GeoFuse. Đường chạy đã submit:

```
MMseqs + composite
→ temporal/self filter
→ realign/rank/distinct PDB
→ coordinate transfer + gap-fill
→ confidence-weighted geometry cleanup, 300 Adam steps
→ validate submission.csv
```

Nó cao hơn TBM-only notebook được báo cáo 0.59298 một lượng +0.00877, gần với chênh lệch local +0.0089. Tuy nhiên hidden Kaggle set khác 12 CASP15; không cộng/trừ hai score này với nhau để suy ra contribution.

6. Pretrained white-box

Pretrained model là model đã học pattern từ một tập dữ liệu trước đó. “Frozen” nghĩa là checkpoint không đổi trong thesis inference; repo không train lại một foundation model RNA 3D từ đầu.



6.1 DRfold2 thực hiện gì?

Khái niệm chính:

- **checkpoint**: snapshot trọng số neural network;
- **learned restraint/potential**: model dự đoán các quan hệ như distance/orientation có khả năng xảy ra giữa residue;
- **folding/optimization**: tìm tọa độ 3D có energy thấp theo các restraint đó;
- **model confidence**: ước lượng nội bộ, không phải native TM.

Runner của repo:

1. ghi sequence target thành FASTA;
2. chạy 20 checkpoint của cấu hình `cfg97`;
3. mỗi checkpoint dự đoán prior/potential từ sequence;
4. selection gộp thông tin checkpoint;
5. PotentialFold tối ưu cấu trúc coarse-grained;

6. Arena tạo PDB hoàn chỉnh;
7. đọc C1' coordinates và confidence;
8. giữ các hypothesis đứng đầu.

Đầu ra cũng được chuẩn hóa thành:

```
target_id, sequence
coords[L,3]
confidence[L]
support_mask[L]
source/model/checkpoint provenance
```

6.2 Confidence không phải “độ đúng”

R1108 có:

Candidate	DRfold confidence	Native TM sau evaluation
P1	0.3545	0.60192
P2	0.3241	0.53589
P3	0.3166	0.48550
P4	0.3059	0.54627
P5	0.2983	0.55306

P5 confidence thấp hơn P2/P3/P4 nhưng TM cao hơn cả ba. Trên 55 DRfold2 candidates, pooled Spearman confidence–TM là 0.486 nhưng mean within-target chỉ -0.036. Vì vậy không được sort chung TBM và DRfold2 bằng raw confidence rồi gọi đó là quality.

6.3 Vì sao pretrained vẫn cần?

Trên 12 target:

```
TBM oracle          0.3143
pretrained oracle    0.4972
union oracle         0.5123
union - TBM          +0.1981
native-blind selected union 0.4713
```

Oracle ở đây chỉ là diagnostic sau evaluation: chọn candidate có TM cao nhất nếu đã biết native. Nó đo “candidate bank có chứa lời giải tốt không”, không phải method có thể deploy. 0.4713 mới là mức selection native-blind đạt được trong protocol này.

R1108:

```
best TBM      1DRZ_B, TM = 0.49384
best DRfold2  P1,      TM = 0.60192
union gain    = +0.10808
```

Một final-five source-balanced thật của R1108 là:

```
T(1DRZ_B), P1, T(5V7Q_B), P2, T(1U6B_B)
```

6.4 Boltz nằm ở đâu?

Boltz đã được dùng trong feasibility Phase A cho R1138 dài 720 nucleotide khi DRfold2 vượt giới hạn GPU 16 GB:

```
R1138 TBM  0.2243
Boltz      0.2751
gain      +0.0508
```

Nhưng final confirmatory cohort dài ≤ 100 dùng DRfold2 thống nhất. Vì vậy Boltz là fallback/pretrained evidence cho target dài, không phải block mặc định trong đường chạy final được vẽ.

7. Geometry v2 white-box

Mục tiêu của Geometry v2 không phải dựng một fold mới. Nó là **projection bảo thủ**: dịch tọa độ vừa đủ để hình học C1' cục bộ hợp lý hơn, trong khi anchor mạnh giữ candidate gần cấu trúc nguồn.

7.1 Priors được học thế nào?

Từ các structure cũ hợp lệ, pipeline đo:

- C1'–C1' distance liên tiếp;
- pseudo-angle của ba C1' liên tiếp;
- signed pseudo-torsion của bốn C1' liên tiếp;
- radius of gyration `Rg`;
- non-local clash;
- context `pair_like` hoặc `unpaired`.

`pair_like` không phải annotation base pair thật. Nó là proxy inference-time: hai base thuộc AU/UA/GC/CG/GU/UG, cách nhau ít nhất bốn vị trí sequence và có C1' distance quanh 10.5 ± 2.5 Å. Tên proxy được giữ để không claim quá mức sinh học.

Angle/torsion được lưu thành histogram probability; negative log-likelihood thấp nghĩa là hình học giống phân bố của RNA cũ hơn.

7.2 Objective được tối ưu

Với source coordinates `xo`, Geometry v2 tìm `x` nhỏ nhất:

$$\mathcal{L}(X) = 3.0 L_{\text{source}} + s (1.0 L_{\text{backbone}} + 0.3 L_{\text{clash}} + 0.02 L_{\text{Rg}} + 0.30 L_{\text{angle}} + 0.15 L_{\text{torsion}} + 20 L_{\text{kink}})$$

Trong đó:

- `source`: Huber distance từ `x` về `xo`, weighted bằng confidence;
- `backbone`: adjacent distance theo empirical prior;
- `clash`: phạt điểm non-neighbour quá gần;
- `Rg`: phạt kích thước global quá xa RNA cùng chiều dài;
- `angle/torsion`: phạt hình học hiếm theo context;
- `kink`: constraint ngăn tạo/worsen sharp local kink;
- `s = 0.2 + 0.8(1 - global_confidence)`: candidate yếu được phép sửa mạnh hơn.

Tối ưu dùng Adam, 300 steps, learning rate 0.04 và gradient clipping. Raw parent luôn được giữ, nên projection không xóa đường lui.

7.3 Bảng chứng module

Trên 12 target, cùng 60 selected candidates:

	raw	Geometry v2	delta
best-of-5 TM	0.471268	0.471308	+0.000040
C1'-IDDT	0.472117	0.481823	+0.009706
window-9 RMSD (Å)	4.00131	3.94415	-0.05716

Geometry v2 cải thiện C1'-IDDT trên 12/12 targets và giữ TM trong tolerance đã đăng ký. Đây là claim chính xác: **cải thiện local distance preservation mà không làm thay đổi global score có ý nghĩa**. Không claim Geometry v2 tăng Kaggle private score vì chưa có GeoFuse/Geometry-v2 private submission.

8. GeoFuse white-box

GeoFuse kiểm tra idea: “đoạn TBM tốt thì giữ, đoạn pretrained tốt thì thay”. Điểm khó là inference không có native để biết bên nào tốt. Câu trả lời của pipeline là một router được train/calibrate ngoài target và có quyền từ chối.

8.1 OOF là gì?

OOF — out-of-fold prediction là prediction cho một target được tạo bởi model/calibrator không được train trên chính fold/family chứa target đó. Repo kết hợp:

- time split: train cũ, calibration mới hơn, confirmatory mới nhất;
- family clustering: sequence gần nhau không rơi vào hai phía train/eval;
- pretrained structural-cutoff audit;
- template release/self audit.

Mục đích: confidence router phải gặp target “chưa biết”, giống deployment hơn train fit.

8.2 Bước G1 — cluster theo global fold

Pipeline tính self-TM giữa candidate với candidate, không cần native, rồi cluster ở threshold đã freeze 0.35.

Chỉ pair:

```
one template + one pretrained  
trong cùng global-fold cluster
```

mới được cân nhắc. Hai nguồn khác fold không được cắt/ghép với nhau.

8.3 Bước G2 — robust superposition và local disagreement

Pretrained parent được rigid-align lên template parent bằng các residue:

```
finite ở hai bên  
+ template có support  
+ template confidence  $\geq 0.25$ 
```

Sau align:

$$\text{disagreement}_i = \|\hat{P}_i - T_i\|_2$$

và smooth bằng cửa sổ 15 residue. Disagreement chỉ nói hai nguồn khác nhau bao nhiêu, không nói nguồn nào đúng.

8.4 Bước G3 — router dự đoán source tốt hơn

Router nhận feature native-blind của pair: source confidence, support, disagreement, candidate geometry và context prior. Nó trả:

$$p_i = P(\text{pretrained tốt hơn tại residue } i)$$

Điều kiện switch đã freeze:

```
p_i ≥ decision_threshold 0.75 + margin 0.15 = 0.90  
0.5 Å ≤ local disagreement ≤ 12 Å  
ít nhất 7 residue liên tục cùng qua gate
```

Tại sao cần 7 residue liên tục? Một điểm confidence cao đơn lẻ dễ là nhiễu; một đoạn liên tục có ý nghĩa cấu trúc hơn và giảm seam do đổi nguồn liên tục.

8.5 Bước G4 — selective fusion hoặc abstain

Nếu có segment hợp lệ, binary switch được Gaussian smooth thành $\alpha_i \in [0,1]$:

$$X_i^{\text{fused}} = (1 - \alpha_i) T_i + \alpha_i \hat{P}_i$$

Nhờ smooth, boundary không nhảy đột ngột. Geometry v2 có thể project fused candidate, nhưng hai raw parents vẫn còn trong bank.

Nếu không có segment hợp lệ:

```
return None  
→ không tạo fused candidate  
→ giữ raw parents
```

Đây là **abstention**, một quyết định hợp lệ của thuật toán chứ không phải crash.

8.6 Ví dụ 8K0Y_A

Raw bank:

Source	Candidate	Global confidence
TBM	8V1I_B	0.9107
TBM	8V1H_A	0.8571
TBM	4KR3_C	0.6786
DRfold2	P1	0.4969

Source	Candidate	Global confidence
DRfold2	P2	0.4849

Self-TM tạo hai cluster; một cluster mixed chứa 8V1I_B và P1:

```
alignment RMSD      1.099 Å
mean point disagreement 2.855 Å
mean window disagreement 2.853 Å
p90 window disagreement 5.529 Å
mean P(pretrained better) 0.7218
```

Không có run ≥ 7 residue cùng vượt 0.90, nên selective GeoFuse abstain. Raw final five đạt:

```
TM      0.65667
C1'-1DDT 0.87125
```

Một heuristic fusion không deployable-default cải thiện riêng target này lên TM 0.66255, nhưng aggregate confirmatory không ổn định. Frozen quality-gated method chọn an toàn và không thay raw parent.

8.7 Kết quả confirmatory của GeoFuse

Trên 20 newest validation targets:

```
F0 raw selected TM      0.588304
quality-gated GeoFuse TM 0.588304
delta                   0.000000
quality-gated fused candidates 0
```

Kết luận đúng:

- router hiện tại chưa chứng minh được selective fusion generalize;
- abstention ngăn regression vật chất;
- final deployable behavior hiện tại là giữ bank cha khi thiếu bằng chứng;
- thesis contribution là protocol/router có fail-safe và kết quả âm trung thực, không phải claim rằng fusion đã tăng TM.

9. Chọn final five và ghi submission

9.1 Native-blind selection

Candidate bank được đánh giá bằng feature không dùng native. Selection:

1. giữ fold diversity theo self-TM cluster;
2. không để raw confidence scale của một source xóa source kia;
3. ưu tiên quality/diversity;
4. giữ tối đa năm candidate;
5. nếu GeoFuse abstain, chọn trực tiếp từ raw/Geometry-v2 bank.

Native TM chỉ được đọc sau khi list năm ID đã freeze.

9.2 Schema

Mỗi nucleotide là một row:

```
ID,resname,resid,  
x_1,y_1,z_1,  
x_2,y_2,z_2,  
...  
x_5,y_5,z_5
```

Sanity checks:

- đúng toàn bộ ID như sample;
- đúng thứ tự row;
- residue chạy từ 1 tới L ;
- resname khớp sequence;
- đủ năm conformations;
- tất cả coordinate hữu hạn;
- không duplicate ID.

9.3 Trạng thái submission cần nói rõ


Artifact	Đã chạy?	Score
TBM-only kernel	Đã late-submit Kaggle	private 0.60175; public 0.60084
TBM + DRfold2 + Geometry v2 + GeoFuse	Đã local/confirmatory evaluation theo module	chưa submit private Kaggle

Không được gọi 0.60175 là score của hybrid/GeoFuse.


10. Người ta làm gì, mình dùng lại gì, cái gì mới?

Bảng chứng score: chỉ so các thanh có cùng protocol


A. Ablation temporal-safe trên cùng 12 CASP15 targets



B. Kaggle late submission (hidden set; không dùng để chia attribution nội bộ)



C. Candidate diversity và Geometry v2 (12-target local protocol)



Geometry v2: $\Delta C1'-IDDT + 0.0097$; best-of-5 TM 0.471268 $\rightarrow$ 0.471308 (giữ nguyên trong sai số).

10.1 Top-1 TBM notebook

Notebook TBM dùng:

- exhaustive composite similarity;
- global/local alignment, RNA features, 3-mer;
- KMeans/farthest clustering để đa dạng hóa;
- coordinate transfer, rule-based gap fill/refine;
- de-novo fallback.

Repo port lại để có baseline. Reproduction temporal-safe trên 12 target đạt 0.2983.

10.2 Top-1 hybrid notebook

Captured hybrid V4:

- chạy Boltz tạo structure;
- dùng Boltz như AF3-style restraint cho DRfold2 trên một subset;
- template fallback cho target còn lại;
- với một số RNA dài, thay một conformation bằng Boltz.

Nó không thực hiện confidence-aware local fusion. Reported score V4 là 0.57631. Transcript cũng có các vấn đề selection/index/placeholder, nên score đó không chứng minh pretrained về bản chất kém hơn TBM.

10.3 Phần kế thừa và phần của thesis

Block	Nguồn ý tưởng	Thesis làm gì thêm?
composite search	top-1 TBM	ghép với MMseqs, temporal/self-safe, rank lại
coordinate transfer/gap fill	TBM chuẩn + top-1	support mask và per-residue confidence rõ ràng
candidate diversity	best-of-5/top-1	distinct PDB + source/fold-aware bank
DRfold2/Boltz	model công bố sẵn	audit, normalize provenance, OOF candidate evaluation
Geometry v2	contribution thesis	context-aware angle/torsion, strong source anchor, kink guard
GeoFuse router	contribution thesis	same-fold local gate, calibrated margin, contiguous segment, abstention
evaluation	competition + thesis	TM + C1'-RMSD + C1'-IDDT + sliding-window RMSD, target bootstrap

Claim nên dùng:

Pipeline temporal-safe kết hợp template và pretrained candidates làm tăng fold coverage. Geometry v2 cải thiện local C1' distance preservation trong khi giữ global TM. Selective GeoFuse hiện chưa generalize; abstention giữ nguyên raw bank và ngăn fusion thiếu bằng chứng.

Không nên claim:

- “GeoFuse đã tăng Kaggle private TM”;
- “router biết chắc đoạn nào đúng”;
- “pair_like là base-pair annotation thật”;
- “confidence của DRfold2 tương đương confidence TBM”;
- “0.60175 chứng minh toàn bộ hybrid pipeline”.

11. Pseudocode cuối

```
for target in test_sequences:
    assert cutoff exists

    mm_hits = mmseqs_search(target.sequence, k=13)
    comp_hits = exhaustive_composite_search(target.sequence)
    hits = temporal_and_self_filter(mm_hits ∪ comp_hits, target)

    tbm = []
    for template in realign_and_rank(hits):
        transferred, support = copy_C1_coordinates(template, target)
        filled, confidence = gap_fill(transferred, support)
        tbm.append(normalize_candidate(filled, confidence, support))
    tbm = distinct_PDB_top3(tbm)

    pretrained = DRfold2_frozen(target.sequence, top2=True)
    raw = normalize(tbm + pretrained)

    augmented = keep(raw)
    geometry_v2_candidates = conservative_projection(raw)
    augmented += geometry_v2_candidates

    clusters = self_TM_cluster(raw, threshold=0.35)
    for same_fold(T, P) in mixed_source_pairs(clusters):
        probability = quality_router(T, P)
        segment = contiguous(
            probability >= 0.90
            and 0.5 <= local_disagreement <= 12,
            minimum=7
        )
        if segment exists:
            fused = smooth_segment_fusion(T, P, segment)
            augmented += [fused, geometry_v2(fused)]
        else:
            abstain

    final5 = native_blind_quality_diversity_select(augmented)
    write_target_rows(final5)

validate_against_sample_submission()
```

Pseudocode trên mô tả design cuối. Artifact Kaggle hiện đã submit mới chỉ đi qua nhánh TBM-only nêu ở §5.9.

12. Glossary ngắn

Thuật ngữ	Nghĩa đơn giản
candidate	một giả thuyết cấu trúc
chain	một chuỗi polymer trong file PDB/CIF
checkpoint	bộ trọng số model tại một thời điểm
confidence	ước lượng native-blind; không phải accuracy thật
exhaustive	duyệt toàn bộ library hợp lệ
fold	bố cục/hình dạng 3D tổng thể
gap	vị trí không map được giữa target và template
homolog	sequence có quan hệ tiến hóa/tương đồng đáng kể
inference	tạo prediction cho input mới
k-mer	đoạn sequence liên tiếp dài k
native	cấu trúc thực nghiệm làm reference
OOF	prediction cho target ngoài fold train/calibration của nó
pretrained	model đã được train trước
prior	phân bố/kiến thức thống kê có từ trước
refinement/projection	sửa tọa độ từ một candidate có sẵn
restraint	điều kiện/energy khuyến khích quan hệ hình học
temporal-safe	chỉ dùng thông tin đã tồn tại trước cutoff
template	cấu trúc đã biết dùng để chuyển sang target