

**TODO: UNIVERSITY OF SCIENCE AND TECHNOLOGY OF
HANOI**

TODO: ICT LAB

TODO: ĐỒ THÀNH ĐẠT

**MÔ HÌNH LAI DỰA TRÊN KHUÔN MẪU
VÀ HỌC SÂU CHO DỰ ĐOÁN CẤU TRÚC
BA CHIỀU RNA VỚI KIỂM SOÁT RÒ RỈ
THỜI GIAN VÀ TÍNH CHÍNH HÌNH HỌC**

*A Hybrid Template-Based and Deep-Learning Framework for RNA
Three-Dimensional Structure Prediction with Temporal Leakage Control
and Conservative Geometric Refinement*

LUẬN VĂN THẠC SĨ

TODO: DATA SCIENCE

Giảng viên hướng dẫn: **TODO: NGUYỄN MINH HƯƠNG + NGUYỄN CẨM LINH**

Mã số học viên: **TODO: 2440059**

TODO: HÀ NỘI, 2026

Lời cam đoan

TODO: Bổ sung lời cam đoan theo mẫu chính thức của trường.

Lời cảm ơn

TODO: Bổ sung lời cảm ơn giảng viên hướng dẫn, đơn vị đào tạo, đồng nghiệp và gia đình.

Tóm tắt

Dự đoán cấu trúc ba chiều RNA từ trình tự vẫn khó do dữ liệu thực nghiệm ít, RNA linh động và một trình tự có thể có nhiều cấu dạng. Luận văn nghiên cứu một quy trình dự đoán ở mức nguyên tử C1' gồm mô hình hóa dựa trên khuôn mẫu (TBM), ứng viên từ mô hình học sâu DRfold2 và một phép tinh chỉnh bảo thủ tên Geometry v2. Mục tiêu chính là sinh năm giả thuyết có TM-score cao; câu hỏi phương pháp là liệu sửa hình học cục bộ có tăng độ đúng cục bộ mà không làm hỏng nếp gấp tổng thể hay không.

Mọi khuôn mẫu được lọc theo nguyên tắc phát hành trước đối tượng dự đoán và loại PDB của chính đối tượng. Phân tích TBM cho thấy MMseqs2 chỉ tìm được khuôn ở 8/20 RNA hiệu chỉnh, trong khi tìm kiếm composite tạo ứng viên cho 20/20. Xếp hạng bằng identity nhân coverage tăng best-of-five TM trung bình 0.01566 so với identity đơn lẻ, còn thành phần completeness và luật distinct-PDB không tăng TM trên cohort này. Công thức composite $0.4G + 0.3L + 0.2F + 0.1K_3$ ổn định trước thay đổi trọng số nhưng không tốt hơn rõ ràng so với chỉ dùng căn chỉnh toàn cục; do đó luận văn xem nó là heuristic tăng recall, không khẳng định tối ưu. Bỏ lọc thời gian làm điểm tăng lạc quan khoảng 0.02696.

Nhánh TBM đạt 0.60084 công khai và 0.60175 riêng tư trên Kaggle. Quy trình ba TBM, hai DRfold2 và Geometry v2 đạt 0.62809/0.61390. Trên 20 RNA mới nhất, TBM oracle đạt 0.565183, DRfold2 oracle 0.502627, nhưng hợp hai nguồn đạt 0.588304: DRfold2 thắng TBM ở 8/20 RNA và bổ sung nếp gấp thay vì thay thế TBM. Với cùng ba vị trí dự đoán, thay một TBM bằng một DRfold2 tăng TM trung bình 0.016012 nhưng khoảng tin cậy còn chứa 0.

Đánh giá Geometry v2 dùng giao thức thời gian và họ trình tự 60/20/20: 60 RNA ước lượng phân bố hình học, 20 RNA chọn tham số, rồi cấu hình được khóa trước khi mở 20 RNA mới nhất. Trên tập xác nhận, C1'-IDDT tăng từ 0.659836 lên 0.666496 ($\Delta = +0.006660$, khoảng tin cậy 95% $[+0.000933, +0.013093]$); RMSD cửa sổ 9 và 15 giảm lần lượt 0.040386 và 0.017257 Å. TM-score thay đổi từ 0.588304 xuống 0.587197 ($\Delta = -0.001107$, khoảng tin cậy chứa 0), nằm trong biên bảo toàn 0.005. Đối chứng chỉ giữ nguồn và khoảng cách backbone tăng IDDT tương đương, nhưng Geometry v2 cải thiện mạnh hơn RMSD cửa sổ

9, giảm va chạm, NLL góc và NLL góc xoắn, đồng thời không làm tăng góc gấp sắc. Lợi ích IDDT tập trung ở ứng viên ban đầu yếu; nhóm chất lượng cao không có bằng chứng cải thiện.

Kết luận chính là: tìm kiếm composite mở rộng độ phủ khuôn; TBM và DRfold2 có tính bổ sung; Geometry v2 tạo cải thiện cục bộ nhỏ nhưng có ý nghĩa thống kê trong khi bảo toàn nếp gấp tổng thể theo biên định trước. GeoFuse được giữ như thí nghiệm khám phá trong phụ lục và không được xem là đóng góp lỗi vì chưa tạo cải thiện khái quát.

Từ khóa: cấu trúc ba chiều RNA, mô hình hóa dựa trên khuôn mẫu, DRfold2, TM-score, C1'-IDDT, an toàn thời gian, tinh chỉnh hình học.

Contents

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt	iii
1 Giới thiệu	1
1.1 Bối cảnh và động lực nghiên cứu	1
1.2 Bối cảnh bài toán thực nghiệm	2
1.3 Phát biểu bài toán	2
1.4 Khoảng trống nghiên cứu và giả thuyết	3
1.5 Câu hỏi nghiên cứu	3
1.6 Mục tiêu	4
1.6.1 Mục tiêu tổng quát	4
1.6.2 Mục tiêu cụ thể	4
1.7 Đóng góp	4
1.8 Phạm vi	5
1.9 Cấu trúc luận văn	5
2 Kiến thức nền và tổng quan công trình liên quan	6
2.1 Từ trình tự đến cấu trúc ba chiều RNA	6
2.2 Biểu diễn cấu trúc và tính bất biến hình học	6
2.3 Mô hình hóa dựa trên khuôn mẫu	7
2.3.1 Truy hồi trình tự và nhận diện tương đồng xa	7
2.3.2 Căn chỉnh và chuyển tọa độ	8
2.4 Dự đoán dựa trên học sâu	8

2.5	Tinh chỉnh cấu trúc	8
2.6	Ước lượng chất lượng cấu trúc	9
2.7	Độ tin cậy, hiệu chỉnh và cơ chế từ chối	9
2.8	Đánh giá chất lượng cấu trúc	9
2.8.1	TM-score và chất lượng nếp gấp tổng thể	10
2.8.2	RMSD và sai lệch tọa độ	10
2.8.3	C1'-IDDT và độ chính xác cục bộ	10
2.8.4	RMSD theo cửa sổ trượt	10
2.9	Khoảng trống mà luận văn giải quyết	11
3	Dữ liệu và quy trình đánh giá	12
3.1	Các nhóm dữ liệu	12
3.2	Thư viện khuôn mẫu	12
3.3	Tập phát triển CASP15	13
3.4	Tập 60/20/20 cho Geometry v2 và phân tích lai	13
3.5	Kiểm tra trùng lặp và mốc huấn luyện của mô hình học sâu	14
3.6	Kiểm soát rò rỉ theo thời gian	14
3.7	Quy trình sử dụng nhãn	14
3.8	Chỉ số và đơn vị phân tích	15
4	Khung dự đoán lai đề xuất	16
4.1	Tổng quan	16
4.2	Sinh cấu trúc từ khuôn mẫu	16
4.2.1	Truy hồi nhanh bằng MMseqs2	16
4.2.2	Tìm kiếm tương đồng mở rộng	17
4.2.3	Hợp nhất kết quả, lọc và xếp hạng	17
4.2.4	Chuyển tọa độ	17
4.2.5	Lấp khoảng trống và gán độ tin cậy	17
4.3	Sinh cấu trúc bằng mô hình học sâu	18
4.3.1	DRfold2	18
4.3.2	Boltz cho RNA dài	18
4.3.3	Biểu diễn ứng viên thống nhất	18

4.4	Geometry v2	19
4.4.1	Mục tiêu thiết kế	19
4.4.2	Các phân bố hình học thực nghiệm	19
4.4.3	Hàm mục tiêu	20
4.5	Phân bố năm cấu trúc cuối và ghi tệp	20
5	Thiết kế thí nghiệm	22
5.1	Chiến lược kiểm định giả thuyết	22
5.2	Liên hệ giữa câu hỏi nghiên cứu và thí nghiệm	22
5.3	Phương pháp đối chứng	23
5.4	Điểm lý tưởng và điểm lựa chọn	23
5.5	Phân tích thống kê	24
5.6	Tiêu chí đánh giá Geometry v2	24
5.7	Factorial và giới hạn allocation	24
5.8	Môi trường tính toán và tái lập	24
6	Kết quả	25
6.1	RQ1: Mở rộng khả năng tìm khuôn mẫu	25
6.1.1	Đánh giá bên ngoài trên Kaggle	26
6.2	RQ2: Giá trị bổ sung của mô hình học sâu	27
6.2.1	Bảng chứng phát triển CASP15	28
6.2.2	Boltz trên RNA dài	29
6.3	RQ3: Hiệu quả, cơ chế và khả năng khái quát của Geometry v2	29
6.3.1	Khóa cấu hình trên 20 RNA hiệu chỉnh	29
6.3.2	Kết quả confirmatory trên 20 RNA mới nhất	30
6.3.3	Factorial nguồn ứng viên và Geometry	31
6.3.4	Khi nào tinh chỉnh có lợi?	31
6.4	Mạch phát hiện qua ba câu hỏi nghiên cứu	31
7	Thảo luận	32
7.1	Từ retrieval coverage đến candidate complementarity	32
7.2	Vì sao Geometry v2 cải thiện cục bộ nhưng không tăng TM-score	32
7.3	Quan hệ giữa phần kế thừa và đóng góp của luận văn	33

7.4	Quan hệ với kết quả cuộc thi	33
7.5	Các nguy cơ đối với tính hợp lệ	34
7.5.1	Tính hợp lệ nội tại	34
7.5.2	Khả năng khái quát	34
7.5.3	Mức độ phù hợp của đại lượng đo	34
7.5.4	Tính hợp lệ của kết luận thống kê	34
7.6	Hạn chế kỹ thuật	35
8	Kết luận và hướng phát triển	36
8.1	Kết luận	36
8.2	Hướng phát triển ưu tiên	36
A	Thí nghiệm khám phá GeoFuse (không thuộc pipeline cuối)	38
A.1	Giả thuyết	38
A.2	Kết quả khám phá	38
A.3	Quyết định phạm vi	39
B	Bảng thuật ngữ	40
C	Danh sách kiểm tra khả năng tái lập	42
D	Các mục cần hoàn thiện trước khi nộp	43

List of Tables

3.2	Phân chia thời gian/họ cho đánh giá Geometry v2	13
6.1	Ảnh hưởng của tìm kiếm tương đồng mở rộng đối với TBM	25
6.2	Ablation nguồn truy hồi trên 20 RNA hiệu chỉnh	26
6.3	Ablation reranking trên cùng pool composite high-recall	26
6.4	Đánh giá bên ngoài của TBM và pipeline lai cuối	27
6.5	Allocation TBM–DRfold2 với Geometry tắt trên 20 RNA mới nhất	28
6.6	Khả năng bao phủ nếp gấp của TBM và mô hình học sâu	28
6.7	Các ablation tiêu biểu trên 20 RNA hiệu chỉnh	29
6.8	Raw, đối chứng đơn giản và Geometry v2 trên tập xác nhận mới nhất	30
7.1	Nguồn gốc và vai trò của các thành phần	33

List of Figures

4.1	Khung dự đoán tổng thể. Cấu trúc thực nghiệm chỉ xuất hiện trong huấn luyện và đánh giá, không xuất hiện khi suy luận.	16
-----	--	----

Chapter 1

Giới thiệu

1.1 Bối cảnh và động lực nghiên cứu

RNA tham gia nhiều quá trình sinh học như điều hòa biểu hiện gene, xúc tác, nhận diện phân tử và hình thành các phức hợp ribonucleoprotein. Những chức năng này không chỉ phụ thuộc vào trình tự A, C, G và U mà còn phụ thuộc vào cách chuỗi RNA tổ chức thành cấu trúc bậc hai và cấu trúc ba chiều. Cấu trúc bậc hai mô tả chủ yếu các cặp base nitơ và các mô-típ như thân xoắn hoặc vòng; cấu trúc bậc ba xác định cách các mô-típ đó sắp xếp, tiếp xúc và xoắn trong không gian. Vì vậy, khả năng suy ra cấu trúc ba chiều từ trình tự có ý nghĩa đối với nghiên cứu chức năng RNA và thiết kế các phân tử tác động lên RNA.

Cấu trúc RNA có thể được xác định bằng tinh thể học tia X, cộng hưởng từ hạt nhân hoặc kính hiển vi điện tử nghiệm lạnh. Tuy nhiên, các quy trình này thường đòi hỏi nhiều thời gian, chi phí và không phải RNA nào cũng phù hợp để đo. So với protein, số lượng cấu trúc RNA thực nghiệm còn hạn chế; hơn nữa RNA có độ linh động cao, nhiều tương tác không chuẩn Watson–Crick và các motif bậc ba phụ thuộc mạnh vào môi trường. Những đặc điểm đó khiến dự đoán RNA 3D vẫn là một bài toán chưa được giải quyết hoàn toàn [4, 6, 7].

Các phương pháp tính toán hiện nay có thể được nhìn theo ba nhóm chính. Phương pháp dựa trên vật lý tìm cấu hình có năng lượng thuận lợi nhưng phải đối mặt với không gian tìm kiếm rất lớn. Phương pháp dựa trên tri thức hoặc khuôn mẫu tái sử dụng motif và cấu trúc đã biết; nhóm này thường chính xác khi có khuôn mẫu phù hợp nhưng suy giảm khi gặp nếp gấp mới. Phương pháp học sâu học mối liên hệ giữa trình tự và hình học từ dữ liệu; chúng có thể tạo dự đoán không phụ thuộc trực tiếp vào một khuôn mẫu sẵn, nhưng bị giới hạn bởi lượng dữ liệu RNA, độ lệch phân bố và khó khăn trong ước lượng độ chính xác của từng dự đoán [10, 11, 12, 14].

Như vậy, không có một nguồn dự đoán đơn lẻ nào luôn chiếm ưu thế. Khuôn mẫu

thường mạnh khi có họ hàng gần; mô hình học sâu có thể bổ sung nếp gấp khi khuôn yếu. Luận văn trước hết hỏi từng nguồn làm tăng độ phủ nếp gấp ở đâu, sau đó tập trung vào một câu hỏi hẹp hơn: khi nếp gấp ban đầu đã có, liệu có thể sửa quan hệ C1' cục bộ mà không làm dịch chuyển bố cục toàn phân tử hay không?

Động lực trung tâm vì vậy là xây dựng một pipeline RNA 3D an toàn theo thời gian, phân tích định lượng thành phần TBM và tính bổ sung TBM–DRfold2, rồi kiểm chứng Geometry v2 bằng ablation và tập xác nhận mới nhất. Luận văn không lấy ước lượng chất lượng cục bộ hay hợp nhất tọa độ làm contribution lõi; GeoFuse chỉ còn là thí nghiệm khám phá ở phụ lục vì chưa cho thấy cải thiện khái quát.

1.2 Bối cảnh bài toán thực nghiệm

Cuộc thi Stanford RNA 3D Folding [16] được sử dụng như bối cảnh triển khai và đánh giá bên ngoài. Với mỗi RNA, hệ thống phải xuất năm cấu trúc, mỗi nucleotide được biểu diễn bằng tọa độ nguyên tử C1'. Chất lượng được đánh giá bằng TM-score tốt nhất trong năm dự đoán. Thiết lập này phản ánh hai đặc điểm thực tế: dự đoán cấu trúc có tính bất định, và khả năng sinh một tập giả thuyết đa dạng có thể quan trọng không kém việc tối ưu một dự đoán duy nhất.

Các mã nguồn dạng sổ tay tính toán của nhóm đứng đầu cuộc thi cho thấy mô hình hóa dựa trên khuôn mẫu và mô hình học sâu có thể kết hợp hiệu quả ở cấp độ hệ thống. Tuy nhiên, một giải pháp thi đấu chủ yếu tối ưu điểm số và thời gian chạy, trong khi một luận văn cần tách rõ dữ liệu nào được sử dụng, thành phần nào tạo ra cải thiện, kết quả có tổng quát hay không và giới hạn sinh học của biểu diễn C1'. Do đó luận văn không xem bảng xếp hạng là bằng chứng duy nhất, mà xây dựng các tập phát triển và xác nhận riêng với kiểm soát thời gian, họ trình tự và thống kê theo đối tượng RNA.

1.3 Phát biểu bài toán

Cho một RNA cần dự đoán có trình tự

$$S = (s_1, s_2, \dots, s_L), \quad s_i \in \{A, C, G, U\}, \quad (1.1)$$

và mốc thời gian t_{cutoff} , hệ thống phải sinh năm cấu trúc ứng viên

$$\mathcal{X} = \{X^{(1)}, \dots, X^{(5)}\}, \quad X^{(k)} \in \mathbb{R}^{L \times 3}, \quad (1.2)$$

trong đó hàng thứ i của $X^{(k)}$ là tọa độ (x_i, y_i, z_i) của nguyên tử C1' đại diện cho nucleotide thứ i . Cấu trúc thực nghiệm của RNA không được sử dụng khi suy luận. Mọi khuôn mẫu phải có ngày phát hành nhỏ hơn t_{cutoff} .

Mục tiêu theo thiết lập của cuộc thi là tối đa hóa

$$\frac{1}{N} \sum_{n=1}^N \max_{k \in \{1, \dots, 5\}} \text{TM}(X_n^{(k)}, Y_n), \quad (1.3)$$

với Y_n là cấu trúc thực nghiệm chỉ được sử dụng khi đánh giá.

Ngoài mục tiêu toàn cục trên, luận văn xét thêm độ chính xác cục bộ. Điều này xuất phát từ nhận xét rằng một dự đoán có nếp gấp đúng vẫn có thể chứa khoảng cách hoặc góc cục bộ chưa chính xác, trong khi một cấu trúc có hình học trơn tru chưa chắc thuộc đúng nếp gấp. Hai loại chất lượng này cần được đo bằng các chỉ số bổ sung thay vì quy về một số duy nhất.

1.4 Khoảng trống nghiên cứu và giả thuyết

Ba khoảng trống được xét. Thứ nhất, điểm toàn hệ thống không cho biết thành phần nào của TBM tạo recall, precision hay đa dạng. Thứ hai, mức tăng của pipeline lai có thể bị nhiễu giữa số lượng candidate, nguồn DRfold2 và Geometry. Thứ ba, các chỉ số hình học nội bộ không đủ chứng minh cấu trúc gần native hơn vì chúng cũng là mục tiêu được tối ưu.

Ba giả thuyết tương ứng là: tìm kiếm composite tăng độ phủ khi MMseqs2 không có hit; DRfold2 bổ sung chứ không thay thế ứng viên TBM; và Geometry v2 có thể cải thiện các chỉ số native độc lập ở quy mô cục bộ trong khi giữ TM-score trong biên suy giảm 0.005.

1.5 Câu hỏi nghiên cứu

Luận văn trả lời ba nhóm câu hỏi:

- RQ1.** Việc kết hợp truy hồi nhanh với tìm kiếm tương đồng mở rộng có cải thiện khả năng tìm khuôn mẫu trong điều kiện an toàn theo thời gian hay không?
- RQ2.** DRfold2 có bổ sung nếp gấp mà TBM bỏ lỡ hay không; hiệu ứng nguồn còn tồn tại khi giữ cố định số lượng cấu trúc dự đoán hay không?
- RQ3a.** Geometry v2 có cải thiện độ chính xác cục bộ theo C1'-IDDT và RMSD cửa sổ, đồng thời bảo toàn TM-score hay không?

- RQ3b.** Thành phần source, backbone, angle, torsion, clash/Rg, kink guard và adaptive strength đóng vai trò gì so với một đối chứng source–backbone đơn giản?
- RQ3c.** Hiệu ứng có khái quát sang 20 RNA mới nhất tách theo thời gian/họ và thay đổi theo nguồn, chất lượng ban đầu, độ dài hay độ phủ như thế nào?

1.6 Mục tiêu

1.6.1 Mục tiêu tổng quát

Xây dựng và đánh giá một pipeline lai dự đoán RNA 3D mức C1' có thể tái lập và an toàn theo thời gian; đồng thời kiểm chứng liệu tinh chỉnh hình học bảo thủ có cải thiện độ đúng cục bộ mà không phá nếp gấp toàn cục hay không.

1.6.2 Mục tiêu cụ thể

1. Xây dựng thư viện khuôn mẫu RNA từ PDB/mmCIF và kiểm tra ngày công bố.
2. Kết hợp MMseqs2 với tìm kiếm tương đồng mở rộng để tăng khả năng truy hồi khuôn mẫu.
3. Chuẩn hóa đầu ra TBM và DRfold2 thành một biểu diễn ứng viên thống nhất; Boltz chỉ được ghi nhận như feasibility case cho RNA dài.
4. Thiết kế Geometry v2 với các phân bố hình học thực nghiệm và ràng buộc nguồn thích nghi theo độ tin cậy.
5. Phân rã ảnh hưởng của retrieval, reranking, distinct-PDB, gap filling và phân bố TBM–DRfold2 bằng các ablation giữ biến còn lại cố định khi có thể.
6. Đánh giá Geometry v2 bằng protocol 60 train–20 calibration–20 validation, chỉ số native độc lập và bootstrap theo đối tượng RNA.

1.7 Đóng góp

Luận văn có một đóng góp phương pháp và hai đóng góp thực nghiệm chính.

1. **Pipeline TBM an toàn theo thời gian và phân tích white-box.** Luận văn kết hợp MMseqs2 với tìm kiếm composite, lọc theo ngày/PDB, căn chỉnh, reranking, distinct-PDB và gap filling; mỗi component được gắn với giả thuyết và ablation.

2. **Bằng chứng thực nghiệm về tính bổ sung TBM–DRfold2.** Các allocation fixed-size tách lợi ích nguồn khỏi lợi thế có thêm prediction slot. Kết quả cho thấy DRfold2 yếu hơn TBM trung bình nhưng thắng trên 8/20 RNA và tăng union oracle.
3. **Geometry v2 và kiểm chứng confirmatory.** Phương pháp kết hợp source restraint, backbone, clash/Rg, angle/torsion empirical NLL, kink guard và adaptive strength. Priors chỉ học từ 60 RNA sớm; tham số chọn trên 20 calibration; hiệu quả chấm đúng một lần trên 20 RNA mới nhất bằng IDDT/RMSD cửa sổ/TM độc lập.

GeoFuse không còn là contribution: kết quả âm được rút khỏi mạch lập luận chính và chỉ giữ ở phụ lục như một hướng khám phá đã đóng băng.

1.8 Phạm vi

Luận văn dự đoán đường $C1'$, không phải cấu trúc RNA toàn nguyên tử. Vì vậy nghiên cứu có thể kết luận về nếp gấp tổng thể, tọa độ $C1'$, khả năng bảo toàn khoảng cách cục bộ và hình học thô; không kết luận trực tiếp về liên kết hydro, xếp chồng base nitơ, cấu hình đường, hóa học lập thể của phosphate, năng lượng tự do hay độ ổn định trong mô phỏng động lực học phân tử.

1.9 Cấu trúc luận văn

Chương 2 trình bày nền tảng và tổng quan công trình liên quan. Chương 3 mô tả dữ liệu, kiểm soát rò rỉ và quy trình đánh giá. Chương 4 trình bày phương pháp lai đề xuất. Chương 5 mô tả thiết kế thí nghiệm. Chương 6 lần lượt trả lời ba nhóm câu hỏi nghiên cứu. Chương 7 diễn giải ý nghĩa của các kết quả, giới hạn và quan hệ với công trình trước. Chương 8 kết luận và đề xuất hướng phát triển.

Chapter 2

Kiến thức nền và tổng quan công trình liên quan

2.1 Từ trình tự đến cấu trúc ba chiều RNA

Cấu trúc RNA thường được mô tả theo một hệ phân cấp. Cấu trúc bậc một là trình tự nucleotide. Cấu trúc bậc hai mô tả các cặp base nitơ và các phần tử như thân xoắn (stem), vòng kẹp tóc (hairpin), chỗ phình (bulge) hay vòng trong (internal loop). Cấu trúc bậc ba xác định cách những phần tử đó sắp xếp và tương tác trong không gian. Phân cấp này giúp thu hẹp bài toán nhưng không làm nó đơn giản: hai mô hình có thể dự đoán đúng phần lớn cặp base nitơ mà vẫn đặt sai tương quan giữa các miền hoặc junction. RNA-Puzzles ghi nhận rằng một cấu trúc giữ đúng cấu trúc bậc hai vẫn có thể lệch đáng kể khỏi cấu trúc thực nghiệm ở cấp ba chiều [4, 5].

RNA còn có nhiều tương tác không chuẩn Watson–Crick, pseudoknot và chuyển động giữa các trạng thái cấu dạng. Vì thế, trình tự giống nhau là bằng chứng có giá trị nhưng không quyết định duy nhất cấu trúc; tương tự, một phân bố hình học phổ biến không thể thay thế hoàn toàn thông tin về tiếp xúc xa và tổ chức miền. Các tổng quan gần đây thường chia phương pháp dự đoán RNA 3D thành ba họ: mô phỏng dựa trên vật lý, lắp ráp dựa trên tri thức/khuôn mẫu, và phương pháp học máy hoặc học sâu [6, 7, 8].

2.2 Biểu diễn cấu trúc và tính bất biến hình học

Một nucleotide gồm base nitơ, đường ribose và nhóm phosphate. Nguyên tử C1' nằm trong đường ribose và cung cấp một điểm đại diện cho mỗi nucleotide. Khi chỉ giữ C1', một RNA dài L trở thành ma trận $X \in \mathbb{R}^{L \times 3}$. Đây là biểu diễn đầu ra của cuộc thi và là mức biểu diễn

chính của luận văn.

Tọa độ tuyệt đối không có ý nghĩa: cùng một cấu trúc có thể được xoay hoặc tịnh tiến mà không thay đổi hình dạng. Do đó, phép so sánh cấu trúc phải bất biến đối với nhóm biến đổi cứng trong không gian, thường ký hiệu là $SE(3)$, gồm phép xoay và tịnh tiến. Kabsch là thuật toán tìm phép xoay và tịnh tiến làm sai số bình phương nhỏ nhất giữa hai tập điểm tương ứng. Phép chồng khít Kabsch, RMSD sau căn chỉnh và TM-score xử lý tính bất biến này bằng cách tìm phép chồng khít cứng tối ưu. IDDT tránh căn chỉnh toàn cục bằng cách so sánh trực tiếp các khoảng cách nội tại.

Biểu diễn $C1'$ làm giảm chi phí và phù hợp mục tiêu dự đoán nếp gấp, nhưng không chứa hướng quay đầy đủ của base nitơ, liên kết hydro, xếp chồng base nitơ, cấu hình đường hoặc va chạm toàn nguyên tử. Vì vậy một đánh giá hợp lý phải phân biệt “độ chính xác đường $C1'$ ” với “tính hợp lý vật lý toàn nguyên tử”.

2.3 Mô hình hóa dựa trên khuôn mẫu

Mô hình hóa dựa trên khuôn mẫu (template-based modeling, TBM) tận dụng quan sát rằng các RNA có quan hệ trình tự hoặc motif tương tự có thể chia sẻ một phần cấu trúc. Quy trình TBM gồm bốn nhiệm vụ: nhận diện khuôn mẫu, căn chỉnh trình tự, chuyển thông tin hình học và xây các vùng không được khuôn mẫu hỗ trợ. Các công cụ như ModeRNA và RNAComposer cho thấy khả năng lắp ráp cấu trúc RNA từ khuôn mẫu hoặc đoạn cấu trúc đã biết [9, 4].

Điểm mạnh của TBM là truyền trực tiếp nếp gấp thực nghiệm, nhờ đó không phải tìm kiếm toàn bộ không gian cấu dạng. Điểm yếu nằm ở chính giả định đó. Nếu thư viện không có khuôn mẫu gần, nếu chỉ một motif ngắn tương đồng, hoặc nếu căn chỉnh sai tại insertion, tọa độ được chuyển có thể thiếu hoặc sai. Các bộ đánh giá chuẩn RNA 3D cũng ghi nhận việc nhận diện đúng khuôn mẫu là yếu tố quyết định đối với mô hình so sánh [7, 6].

2.3.1 Truy hồi trình tự và nhận diện tương đồng xa

Công cụ truy hồi nhanh thường dùng các đoạn con liên tiếp (k -mer) làm hạt giống để loại phần lớn thư viện trước khi căn chỉnh chính xác. Lựa chọn k tạo ra đánh đổi giữa độ nhạy và chi phí: hạt giống dài giảm nhiễu nhưng dễ bỏ lỡ quan hệ xa. Vì cấu trúc có thể được bảo tồn lâu hơn trình tự, chỉ một cơ chế tìm kiếm nhanh theo trình tự có thể không đủ để phát hiện khuôn mẫu cấu trúc tiềm năng. Đây là lý do luận văn bổ sung một điểm tương đồng tổng hợp, kết hợp căn chỉnh toàn cục, căn chỉnh cục bộ, thành phần trình tự và mức trùng lặp của

3-mer.

2.3.2 Căn chỉnh và chuyển tọa độ

Căn chỉnh toàn cục phù hợp khi hai trình tự tương đồng trên phần lớn chiều dài; căn chỉnh cục bộ tìm một miền hoặc motif bảo tồn. Kết quả căn chỉnh ánh xạ nucleotide thứ i của đối tượng sang nucleotide thứ j của khuôn mẫu. Chỉ những vị trí có ánh xạ và có tọa độ hợp lệ mới được sao chép trực tiếp. Những vị trí còn lại tạo thành khoảng trống và cần được dựng bằng hình học, đoạn cấu trúc khác hoặc một mô hình dự đoán bổ sung. Sai lệch ở bước căn chỉnh có thể truyền thành sai lệch hình học, vì vậy độ tương đồng trình tự, độ phủ và độ đầy đủ tọa độ đều cần tham gia xếp hạng.

2.4 Dự đoán dựa trên học sâu

Sự phát triển của mô hình attention, biểu diễn ngôn ngữ và học hình học đã tạo ra nhiều phương pháp RNA 3D mới. DRfold kết hợp học end-to-end về khung tọa độ cục bộ với các thể năng hình học để hướng dẫn lắp ráp cấu trúc [10]. RhoFold+ tận dụng một mô hình ngôn ngữ RNA tiền huấn luyện trên tập trình tự lớn cùng thông tin tiến hóa để dự đoán cấu trúc đơn chuỗi [11]. DRfold2 thay đổi đáng kể kiến trúc tiền nhiệm bằng mô hình ngôn ngữ RNA tổng hợp, module cấu trúc khử nhiễu và quy trình lựa chọn–tinh chỉnh cấu dạng [12]. Boltz-1 là mô hình mở cho dự đoán cấu trúc và tương tác phân tử, được dùng trong luận văn như một phương án khả thi cho RNA dài [13].

So với TBM, mô hình học sâu có thể sinh một giả thuyết ngay cả khi không có khuôn mẫu gần trong thư viện truy vấn. Tuy nhiên, chúng vẫn học từ một tập cấu trúc thực nghiệm hữu hạn. Độ chính xác có thể giảm khi chiều dài, họ RNA hoặc loại tương tác khác với dữ liệu huấn luyện; hơn nữa một số phương pháp phụ thuộc vào MSA hoặc có giới hạn tài nguyên. Vì vậy, kết quả từ mô hình học sâu cần được kiểm tra trùng lặp trình tự và mốc thời gian huấn luyện trước khi diễn giải như bằng chứng tổng quát.

2.5 Tinh chỉnh cấu trúc

Cấu trúc sinh bởi TBM, lắp ráp đoạn cấu trúc hoặc học sâu có thể chứa khoảng cách bất thường trên đường trục phân tử, va chạm, vùng thiếu hoặc lỗi hình học tại chỗ nối. Các phương pháp tinh chỉnh dùng trường lực, thể năng thống kê, ràng buộc thực nghiệm hoặc tối ưu hình học để giảm những lỗi đó. Các tổng quan về RNA 3D ghi nhận rằng refinement có

thể sửa khuyết tật cục bộ, nhưng mức cải thiện toàn cục phụ thuộc mạnh vào chất lượng cấu trúc ban đầu và thông tin tiếp xúc xa [6].

Điểm cần phân biệt là “làm cấu trúc hợp lý hơn theo hàm năng lượng” và “làm cấu trúc gần thực nghiệm hơn”. Nếu một phương pháp được tối ưu trực tiếp để giảm va chạm hoặc độ lệch góc, việc các đại lượng đó giảm chỉ chứng minh bộ tối ưu hoạt động theo mục tiêu đã đặt. Để kết luận về độ chính xác, cần chỉ số độc lập như IDDT hoặc RMSD cục bộ. Đây là nguyên tắc dẫn tới thiết kế đánh giá Geometry v2.

2.6 Ước lượng chất lượng cấu trúc

Sinh được một tập cấu trúc tốt chưa đồng nghĩa chọn được cấu trúc tốt. ARES cho thấy một mạng học hình học có thể xếp hạng cấu trúc RNA từ tọa độ và cải thiện khả năng nhận diện mô hình gần thực nghiệm [14]. Các hệ thống đánh giá RNA truyền thống và gần đây cũng sử dụng thế năng thống kê, bản đồ tiếp xúc, đặc trưng nguyên tử hoặc dự đoán IDDT để ước lượng chất lượng [15, 14].

Trong pipeline cuối, độ tin cậy chỉ dùng để xếp hạng trong từng nguồn và điều chỉnh cường độ Geometry; nó không được xem là xác suất đúng đã hiệu chỉnh giữa hai nguồn. Một thí nghiệm khám phá về quality routing được trình bày ở phụ lục, nhưng kết quả đó không tham gia contribution hay pipeline cuối.

2.7 Độ tin cậy, hiệu chỉnh và cơ chế từ chối

Độ tin cậy là đầu ra nội bộ của một mô hình, còn độ chính xác là quan hệ với cấu trúc thực nghiệm. Hai khái niệm chỉ tương ứng chặt khi đã hiệu chỉnh. Giá trị 0.8 của TBM và 0.8 của DRfold2 không mặc nhiên cùng ý nghĩa; vì vậy pipeline không trộn hai thang điểm thành một ranking toàn bank. Adaptive strength được ablate với fixed strength để kiểm tra trực tiếp liệu việc dùng confidence có tạo giá trị hay không.

2.8 Đánh giá chất lượng cấu trúc

Không có một chỉ số duy nhất phản ánh đầy đủ mọi khía cạnh của RNA 3D. RNA-Puzzles và các bộ công cụ đánh giá sử dụng nhiều chỉ số bổ sung cho nhau ở cấp độ toàn cục, cục bộ và mạng tương tác [4, 5, 15]. Vì luận văn chỉ có đường C1', bốn nhóm chỉ số sau được chọn.

2.8.1 TM-score và chất lượng nếp gấp tổng thể

TM-score đo độ giống nếp gấp sau phép chồng khít cứng và chuẩn hóa theo chiều dài cấu trúc tham chiếu [1]. Dạng trực giác:

$$TM = \max_{R,t} \frac{1}{L} \sum_{i=1}^L \frac{1}{1 + (d_i/d_0(L))^2}, \quad (2.1)$$

trong đó R, t là phép xoay và tịnh tiến, d_i là khoảng cách sau căn chỉnh và $d_0(L)$ phụ thuộc chiều dài. Khoảng cách nhỏ đóng góp gần 1; khoảng cách lớn nhanh chóng bị giảm trọng số. Luận văn dùng US-align để tính TM-score [2]. Với năm cấu trúc có TM lần lượt 0.42, 0.61, 0.38, 0.55 và 0.47, điểm của đối tượng là 0.61; ví dụ này giải thích tại sao độ đa dạng của năm dự đoán có ý nghĩa.

2.8.2 RMSD và sai lệch tọa độ

Sau phép chồng khít cứng tối ưu:

$$RMSD = \sqrt{\frac{1}{L} \sum_{i=1}^L \|\hat{x}_i - y_i\|_2^2}. \quad (2.2)$$

RMSD thấp hơn là tốt hơn, nhưng một miền đặt sai xa có thể chi phối toàn bộ giá trị.

2.8.3 C1'-IDDT và độ chính xác cục bộ

IDDT đo khả năng bảo toàn các khoảng cách lân cận mà không cần căn chỉnh toàn cục [3]. Bản thích nghi của luận văn dùng một atom C1' mỗi nucleotide, bán kính xét cặp 15 Å và các ngưỡng sai lệch 0.5, 1, 2 và 4 Å. Do không dùng đầy đủ nguyên tử, tên chính xác là C1'-IDDT, không phải IDDT toàn nguyên tử.

2.8.4 RMSD theo cửa sổ trượt

RMSD được tính lại sau khi căn chỉnh riêng từng đoạn liên tiếp dài 9, 15 và 31 nucleotide. Cửa sổ ngắn nhạy với hình học tại chỗ; cửa sổ dài hơn bắt đầu phản ánh tổ chức rộng. Ba kích thước này là quy mô phân tích được xác định trước, không phải hằng số sinh học phổ quát.

2.9 Khoảng trống mà luận văn giải quyết

Các công trình trước cho thấy TBM mạnh khi nhận đúng khuôn, còn học sâu có thể tạo nếp gấp bổ sung. Khoảng trống của luận văn là thiếu phân rã white-box dưới kiểm soát thời gian và thiếu bằng chứng độc lập rằng một refiner hình học coarse-grained làm cấu trúc gần native hơn, thay vì chỉ giảm chính loss đã đặt. Geometry v2 vì vậy được đánh giá bằng IDDT, RMSD cửa sổ và TM trên split 60/20/20, kèm đối chứng và component ablation.

Chapter 3

Dữ liệu và quy trình đánh giá

3.1 Các nhóm dữ liệu

Nhóm	Nội dung	Vai trò
Bảng trình tự	mã đối tượng, trình tự, mô tả, mốc thời gian	Đầu vào và siêu dữ liệu cho các tập huấn luyện, hiệu chỉnh và đánh giá.
Bảng nhãn	tọa độ thực nghiệm C1'	Học prior trên 60 RNA; calibration tham số; đánh giá một lần sau khi đóng băng phương pháp.
PDB_RNA/*.cif	chuỗi RNA, nguyên tử, nucleotide biến đổi, ngày công bố	Thư viện khuôn mẫu chính.
MSA	các trình tự họ hàng đã căn chỉnh	Đầu vào tiềm năng cho mô hình học sâu; nhánh TBM hiện tại không phụ thuộc MSA.
Dữ liệu mô hình học sâu	bộ trọng số đã huấn luyện và cấu trúc DRfold2/Boltz	Nguồn giả thuyết nếp gấp bổ sung.

3.2 Thư viện khuôn mẫu

Phiên bản dữ liệu được phân tích bằng Gemmi gồm 8,670 tệp CIF, tạo 23,869 chuỗi RNA hoặc chuỗi lai RNA–DNA với khoảng 10.86 triệu nucleotide. Khoảng 99.9% nucleotide có

C1' được mô hình hóa. Nucleotide biến đổi được ánh xạ về A/C/G/U khi có quy tắc; tọa độ thiếu được giữ là NaN để bước dựng khoảng trống xử lý, thay vì nội suy âm thầm trong lúc đọc dữ liệu.

Hai thư viện tìm kiếm được xây:

- khoảng 20,844 chuỗi hợp lệ trong cơ sở dữ liệu MMseqs2;
- 7,155 trình tự duy nhất trong thư viện tìm kiếm mở rộng, giữ đại diện tọa độ có ngày công bố sớm nhất.

3.3 Tập phát triển CASP15

Tập phát triển cục bộ gồm 12 đối tượng: R1107, R1108, R1116, R1117v2, R1126, R1128, R1136, R1138, R1149, R1156, R1189 và R1190, chiều dài từ 30 đến 720 nucleotide. Tập này được dùng để đánh giá việc tìm khuôn mẫu, độ đa dạng của nguồn dự đoán và Geometry v2. Vì chỉ có 12 RNA độc lập, thống kê được lấy mẫu lại theo RNA, không coi hàng nghìn nucleotide trong cùng phân tử là các mẫu độc lập.

3.4 Tập 60/20/20 cho Geometry v2 và phân tích lai

Một trăm RNA dài tối đa 100 nucleotide được sắp theo thời gian và gom nhóm họ trình tự. Tập này không còn phục vụ mô hình GeoFuse trong mạch chính; nó được chuyển đúng vai trò train–calibration–validation cho Geometry v2:

Table 3.2: Phân chia thời gian/họ cho đánh giá Geometry v2

Tập	Số RNA	Số họ	Khoảng ngày	TBM	DRfold2
Huấn luyện prior	60	54	2024-01-10–2024-12-04	180	120
Hiệu chỉnh	20	17	2024-12-11–2025-01-08	60	40
Xác nhận mới nhất	20	16	2025-01-15–2025-03-26	60	40

Không có họ hoặc nhóm trình tự trùng hoàn toàn xuất hiện ở nhiều tập. Mỗi RNA có đúng ba ứng viên TBM và hai DRfold2 hữu hạn. Sáu mươi RNA đầu chỉ ước lượng prior hình học; 20 RNA hiệu chỉnh chọn cấu hình trong một danh sách khai báo trước; cấu hình và checksum được khóa trước khi mở 20 RNA xác nhận. Một đối tượng lỗi kỹ thuật được thay theo thứ tự dự phòng định trước, không dựa trên độ chính xác.

3.5 Kiểm tra trùng lặp và mốc huấn luyện của mô hình học sâu

R1128 có trình tự trùng hoàn toàn với một mục trong FASTA huấn luyện DRfold2 và tạo TM-score rất cao. Vì vậy, kết quả về khả năng bổ sung nếp gấp được báo cáo theo hai cách: đủ 12 đối tượng theo thiết lập cuộc thi và phân tích độ nhạy loại R1128. R1138 dùng Boltz có mốc dữ liệu huấn luyện được công bố sớm hơn ngày phát hành cấu trúc đích. Việc kiểm tra này giảm nguy cơ diễn giải ghi nhớ dữ liệu thành khả năng khái quát.

3.6 Kiểm soát rò rỉ theo thời gian

Với R1107 có mốc 2022-05-28, cấu trúc 7QR4 phát hành ngày 2022-10-26 phải bị loại khỏi thư viện khuôn mẫu dù có trình tự rất gần. Một phép tái tạo cho phép rò rỉ đạt TM 0.9355, trong khi phiên bản an toàn theo thời gian đạt 0.2983. Chênh lệch này cho thấy bộ lọc ngày công bố là điều kiện trung tâm để kết quả có giá trị khoa học.

Ngoài ngày công bố, quy trình còn loại PDB của chính đối tượng, kiểm tra trùng trình tự, gom nhóm theo họ và xem xét mốc dữ liệu huấn luyện của mô hình tiền huấn luyện. Những kiểm tra này không bảo đảm tuyệt đối rằng mọi quan hệ tiến hóa xa đã được loại, nhưng giảm đáng kể các hình thức rò rỉ có thể quan sát và tái lập.

3.7 Quy trình sử dụng nhãn

Cấu trúc thực nghiệm xuất hiện ở ba vai trò tách biệt. Nhãn của 60 RNA đầu chỉ dùng để ước lượng phân bố khoảng cách, kích thước, góc và góc xoắn. Tập hiệu chỉnh được dùng để chọn source restraint, adaptive strength, learning rate và số bước trong các giá trị khai báo trước. Tập xác nhận mới nhất chỉ được mở sau khi ghi cấu hình đóng băng; tham số không được thay đổi theo kết quả này. Đối với Kaggle, cấu trúc thực nghiệm của tập ẩn hoàn toàn không có sẵn.

Khái niệm ngoài nếp gấp (out-of-fold, OOF) bảo đảm ứng viên của một RNA không được tạo bởi một mô hình huấn luyện trên chính RNA hoặc họ của nó. Ngoài OOF theo mô hình, thứ tự thời gian giữa ba tập tạo một phép kiểm tra triển vọng: prior luôn đến trước calibration, và calibration luôn đến trước validation.

3.8 Chỉ số và đơn vị phân tích

TM-score tốt nhất trong năm cấu trúc là chỉ số chính cho chất lượng nếp gấp. Geometry v2 được đánh giá thêm bằng C1' RMSD, C1'-IDDT và RMSD cửa sổ 9, 15, 31 nucleotide. Clash proxy, sharp-kink, bán kính quán tính và NLL góc/góc xoắn chỉ là diagnostic của objective; chúng không thay thế các chỉ số native độc lập.

Mỗi RNA có trọng số bằng nhau trong giá trị trung bình. So sánh theo cặp sử dụng lấy mẫu lại 10,000 lần ở cấp RNA với hạt giống ngẫu nhiên 2025 để tạo khoảng tin cậy 95%. Cách làm này tránh nguy lặp, tức là coi nhiều nucleotide tương quan trong một RNA như nhiều thí nghiệm độc lập.

Chapter 4

Khung dự đoán lai đề xuất

4.1 Tổng quan




Figure 4.1: Khung dự đoán tổng thể. Cấu trúc thực nghiệm chỉ xuất hiện trong huấn luyện và đánh giá, không xuất hiện khi suy luận.

4.2 Sinh cấu trúc từ khuôn mẫu

4.2.1 Truy hồi nhanh bằng MMseqs2

Trình tự cần dự đoán được truy vấn trong khoảng 20,844 chuỗi bằng MMseqs2 với $k = 13$. Nhánh này nhanh và hiệu quả khi có quan hệ tương đồng rõ. Kết quả ở giai đoạn này chỉ là danh sách khuôn mẫu tiềm năng và căn chỉnh sơ bộ; chưa có tọa độ nào được sao chép.

4.2.2 Tìm kiếm tương đồng mở rộng

Song song với MMseqs2, phương pháp quét 7,155 trình tự khuôn mẫu duy nhất. Điểm tương đồng tổng hợp được tính bởi:

$$C(S, T) = 0.4G(S, T) + 0.3L(S, T) + 0.2F(S, T) + 0.1K_3(S, T), \quad (4.1)$$

với G là độ tương đồng căn chỉnh toàn cục, L là độ tương đồng căn chỉnh cục bộ, F tổng hợp thành phần base nitơ, hàm lượng GC, cặp nucleotide liên tiếp, entropy, đoạn lặp và chiều dài; K_3 là tỷ lệ 3-mer chung. “Mở rộng” ở đây nghĩa là đánh giá toàn bộ thư viện trình tự hợp lệ thay vì chỉ các kết quả MMseqs2; không phải vét cạn không gian cấu hình 3D.

4.2.3 Hợp nhất kết quả, lọc và xếp hạng

Hai danh sách kết quả được hợp nhất. Mỗi khuôn mẫu phải thỏa:

$$t_{release}(T) < t_{cutoff}(S), \quad (4.2)$$

và không thuộc PDB tham chiếu của chính đối tượng. Các cặp được căn chỉnh lại toàn cục và xếp hạng theo tích của mức đồng nhất trình tự, độ phủ đối tượng và độ đầy đủ tọa độ khuôn mẫu. Phương pháp ưu tiên các PDB khác nhau để tránh năm dự đoán cùng một nguồn.

4.2.4 Chuyển tọa độ

Phép căn chỉnh tạo ánh xạ $m(i)$ từ nucleotide i của đối tượng tới nucleotide j của khuôn mẫu. Nếu $m(i) = j$ và khuôn mẫu có C1' hữu hạn:

$$x_i^{TBM} = x_j^{template}, \quad support_i = 1. \quad (4.3)$$

Nếu nucleotide không được ánh xạ, $support_i = 0$ và tọa độ được dựng ở bước lấp khoảng trống. Mặt nạ hỗ trợ phân biệt tọa độ sao chép trực tiếp với tọa độ suy dựng.

4.2.5 Lấp khoảng trống và gán độ tin cậy

Khoảng trống ngắn ở giữa được nội suy giữa hai điểm neo. Khoảng trống dài kết hợp nội suy với độ cong vuông góc để tránh đường thẳng co cụm. Phần thiếu ở đầu hoặc cuối chuỗi được kéo dài theo hướng backbone gần nhất. Nếu không có khuôn mẫu, một phương án dựng thô

sinh nhiều đường C1' dựa trên thân xoắn và vòng. Nucleotide được chuyển trực tiếp có độ tin cậy cao hơn; độ tin cậy trong vùng suy dựng giảm theo khoảng cách tới điểm neo.

4.3 Sinh cấu trúc bằng mô hình học sâu

4.3.1 DRfold2

Chương trình ghi trình tự thành FASTA, chạy 20 bộ trọng số đã huấn luyện của cấu hình `cfg97`, dự đoán các ràng buộc/thể năng hình học, dùng PotentialFold tối ưu cấu trúc thô và Arena tạo PDB trước khi trích C1'. Nhiều bộ trọng số tạo nhiều giả thuyết. Các cấu trúc được xếp hạng theo tiêu chí nội bộ của mô hình, nhưng độ tin cậy thô không được xem là độ chính xác so với thực nghiệm.

4.3.2 Boltz cho RNA dài

Boltz được kiểm tra cho R1138 dài 720 nucleotide khi DRfold2 vượt giới hạn GPU 16 GB. Do tập xác nhận giới hạn chiều dài ≤ 100 , DRfold2 được dùng thống nhất trong thí nghiệm lựa chọn nguồn. Boltz vì vậy cung cấp bằng chứng khả thi và phương án cho RNA dài, không phải bộ sinh mặc định trong thí nghiệm xác nhận cuối.

4.3.3 Biểu diễn ứng viên thống nhất

Hai nguồn được chuẩn hóa thành một cấu trúc dữ liệu chung:

```
target_id, sequence
coords:      [L, 3]
confidence:   [L]
support_mask: [L]
source, model, checkpoint, template_id, cutoff provenance
```

Biểu diễn này cho phép Geometry v2 xử lý hai nguồn bằng cùng một giao diện, đồng thời giữ nguồn gốc và phân biệt nucleotide được khuôn hỗ trợ với nucleotide do gap-fill dựng.

4.4 Geometry v2

4.4.1 Mục tiêu thiết kế

Geometry v2 không dự đoán lại nếp gấp từ đầu. Phương pháp tìm cấu trúc X có hình học $C1'$ cục bộ hợp lý hơn nhưng vẫn gần cấu trúc nguồn X_0 . Cấu trúc ban đầu luôn được giữ trong tập ứng viên để tinh chỉnh không loại bỏ một dự đoán vốn đã tốt.

4.4.2 Các phân bố hình học thực nghiệm

Từ các cấu trúc thực nghiệm cũ hợp lệ theo thời gian, phương pháp đo:

- khoảng cách $C1'$ liên tiếp;
- pseudo-angle từ ba $C1'$ liên tiếp;
- góc xoắn giả có dấu từ bốn $C1'$ liên tiếp;
- bán kính quán tính theo chiều dài;
- khoảng cách tối láng giềng không kề nhau, chỉ dùng để ước lượng ngưỡng clash;
- chỉ dấu pair-like, chỉ dùng để chọn prior angle/torsion theo ngữ cảnh.

Góc phẳng và góc xoắn được chia thành 72 khoảng, làm tròn bằng nhân có trọng số

$$(1, 2, 3, 4, 3, 2, 1), \quad (4.4)$$

thêm một lượng đếm nhỏ để tránh xác suất bằng 0 rồi đổi sang âm log-xác suất (NLL). NLL thấp nghĩa là hình học thuộc vùng thường gặp hơn trong dữ liệu dùng để xây phân bố.

Chỉ dấu “có dạng cặp” (pair-like) là một đại lượng gần đúng chỉ dựa trên thông tin có ở thời điểm suy luận. Một cặp được cân nhắc nếu base nitơ thuộc AU, UA, GC, CG, GU hoặc UG, cách nhau ít nhất bốn vị trí trên trình tự và có khoảng cách $C1'$ quanh 10.5 ± 2.5 Å. Các cặp được chọn tuần tự theo độ gần mục tiêu, mỗi nucleotide tối đa một cặp; các cặp giao nhau được phép để không loại nút giả (pseudoknot). Chỉ dấu này không phải nhãn cặp base nitơ thực nghiệm và không tạo một loss pair-like riêng; nó chỉ chọn histogram angle/torsion tương ứng cho từng vị trí.

4.4.3 Hàm mục tiêu

$$\mathcal{L}(X) = 1.5\mathcal{L}_{source} + s(1.0\mathcal{L}_{backbone} + 0.3\mathcal{L}_{clash} + 0.02\mathcal{L}_{Rg} + 0.30\mathcal{L}_{angle} + 0.15\mathcal{L}_{torsion} + 20.0\mathcal{L}_{kink}), \quad (4.5)$$

$$s = 0.2 + 0.8(1 - c_{global}). \quad (4.6)$$

$\mathcal{L}_{source}$ là khoảng cách Huber về X_0 , có trọng số theo độ tin cậy. $\mathcal{L}_{backbone}$ phạt khoảng cách nucleotide liên tiếp lệch khỏi phân bố thực nghiệm. $\mathcal{L}_{clash}$ phạt C1' không kề nhau quá gần. $\mathcal{L}_{Rg}$ giữ kích thước tổng thể hợp lý theo chiều dài. $\mathcal{L}_{angle}$ và $\mathcal{L}_{torsion}$ phạt vùng có âm log-xác suất (NLL) cao. $\mathcal{L}_{kink}$ ngăn tạo hoặc làm xấu góc gấp sắc.

Trọng số source 1.5 được chọn trên 20 RNA hiệu chỉnh từ các giá trị 1.5, 3.0 và 6.0; mọi thành phần còn lại giữ cấu hình khai báo trước. Một góc gấp sắc được ghi nhận khi pseudo-angle nhỏ hơn 70° . Bộ tối ưu dùng biên bảo vệ 75° : nếu góc của cấu trúc nguồn vốn lớn hơn biên, góc sau tinh chỉnh không nên rơi xuống dưới; nếu góc nguồn đã nhỏ, cận dưới là chính góc đó để không làm gấp sắc hơn. Tọa độ được tối ưu bằng Adam trong 300 bước, tốc độ học 0.04 và giới hạn chuẩn gradient ở 10.

4.5 Phân bổ năm cấu trúc cuối và ghi tệp

Pipeline cuối không ghép tọa độ giữa hai nguồn. Với RNA không quá 600 nucleotide, hệ thống giữ ba ứng viên TBM xếp hạng cao nhất và hai ứng viên DRfold2; nếu DRfold2 lỗi hoặc vượt giới hạn tài nguyên, vị trí đó quay về TBM. Geometry v2 tinh chỉnh từng ứng viên độc lập. Phân bổ cố định này không cần nhãn native khi suy luận và phản ánh đúng notebook Kaggle đã được chấm.

Mỗi nucleotide là một dòng ID, resname, resid, x_1, y_1, z_1, ..., x_5, y_5, z_5. Kiểm tra cuối bảo đảm đúng ID/thứ tự mẫu, đúng nucleotide, đủ năm cấu dạng, tọa độ hữu hạn và không có ID trùng.

```
for target in test_sequences:
    hits = mmseqs_search(target.sequence, k=13)
    hits += exhaustive_composite_search(target.sequence)
    hits = temporal_and_self_filter(hits, target)
    tbm = transfer_rank_distinct_and_gap_fill(hits, top=3)
    deep = DRfold2_frozen(target.sequence, top=2)
    raw5 = tbm + deep if deep succeeds else tbm_fallback_to_five
    final5 = [geometry_v2(candidate) for candidate in raw5]
```

```
validate_and_write_submission(target, final5)
```


Chapter 5

Thiết kế thí nghiệm

5.1 Chiến lược kiểm định giả thuyết

Các thí nghiệm đi theo chuỗi component–hypothesis–ablation–conclusion. TBM được tách thành retrieval source, bốn thành phần composite score, reranking, distinct-PDB và gap filling. Tính bổ sung TBM–DRfold2 được kiểm tra bằng allocation giữ cố định số candidate. Geometry v2 được mô phỏng bằng cumulative/leave-one-out, đối chứng đơn giản, sensitivity, convergence và cuối cùng là xác nhận 20 RNA mới nhất.

Prior được ước lượng trên 60 RNA; tham số Geometry chỉ được chọn trên 20 hiệu chỉnh từ danh sách khai báo trước. Tập xác nhận mới nhất được mở sau khi ghi tệp cấu hình đóng băng. Native reference cho mỗi candidate refined được cố định theo candidate thô để phương pháp không được lợi do đổi sang cấu dạng native dễ hơn.

5.2 Liên hệ giữa câu hỏi nghiên cứu và thí nghiệm

ID	Giả thuyết	So sánh	Chỉ số chính
E0	TBM phải an toàn theo thời gian	safe so với cho phép template tương lai	TM, availability
E1	Composite tăng recall	MMseqs2, composite và hợp hai nguồn	availability, top-1/best-5 TM, coverage

ID	Giả thuyết	So sánh	Chỉ số chính
E2	Reranking/gap-fill có vai trò riêng	component score; identity; identity $\times$ coverage; distinct-PDB; linear/current gap-fill	top-1/3/5 TM, SW-RMSD9
E3	DRfold2 bổ sung TBM	3T; 2T+1D; 1T+2D; 3T+2D, Geometry off/on	best-of- N TM, oracle, bootstrap
E4	Thành phần Geometry có tác dụng gì	cumulative, leave-one-out, fixed/adaptive, source/lr/step sensitivity	TM, IDDT, SW-RMSD, diagnostic
E5	Geometry vượt đối chứng đơn giản	raw, source-backbone, full Geometry	chỉ số native độc lập
E6	Geometry khái quát khi nào	20 RNA newest; stratify source/quality/length/support	paired target bootstrap

5.3 Phương pháp đối chứng

Đối chứng TBM gồm MMseqs2 đơn lẻ, từng subset của composite score, identity-only ranking và gap-fill tuyến tính. Đối chứng Geometry “ngu” nhưng công bằng chỉ có source restraint và backbone loss, cùng số bước và candidate. Full Geometry được so với fixed strength, leave-one-out từng loss và raw không tinh chỉnh. Diagnostic được báo cáo để giải thích cơ chế nhưng gate chỉ dùng TM, C1'-IDDT và sliding-window RMSD độc lập.

5.4 Điểm lý tưởng và điểm lựa chọn

Điểm lý tưởng (oracle) chọn cấu trúc tốt nhất bằng cách nhìn cấu trúc thực nghiệm sau khi đánh giá; nó chỉ đo trần chất lượng của tập ứng viên. Điểm lựa chọn được tạo bằng quy tắc không sử dụng cấu trúc thực nghiệm và có thể áp dụng cho dữ liệu mới. Chênh lệch giữa điểm lý tưởng và điểm lựa chọn là phần chất lượng còn mất ở khâu xếp hạng. Khi điểm lý tưởng tăng nhưng điểm lựa chọn không tăng, hệ thống đã sinh được cấu trúc tốt hơn nhưng chưa nhận ra chúng một cách đáng tin.

5.5 Phân tích thống kê

Mọi RNA có trọng số bằng nhau bất kể chiều dài. So sánh theo cặp dùng phép lấy mẫu lại 10,000 lần ở cấp RNA với hạt giống ngẫu nhiên 2025 để tạo khoảng tin cậy 95%. Nucleotide trong cùng một RNA không được coi là đối tượng độc lập. Khi khoảng tin cậy của chênh lệch chứa 0, kết quả được diễn giải là chưa đủ bằng chứng về một thay đổi ổn định.

5.6 Tiêu chí đánh giá Geometry v2

Trước khi mở kết quả xác nhận, tiêu chí được đặt là C1'-IDDT phải tăng, RMSD phải cải thiện ở ít nhất hai trong ba quy mô cửa sổ và chênh lệch TM không thấp hơn -0.005 . Tiêu chí này buộc phương pháp thể hiện lợi ích bằng chỉ số độc lập đồng thời hạn chế làm hỏng nếp gấp tổng thể.

5.7 Factorial và giới hạn allocation

Cache confirmatory có ba TBM và hai DRfold2 trên mỗi RNA. Factorial chính vì vậy giữ cố định $N = 3$: 3T+0D so với 2T+1D, mỗi bank có Geometry off/on. Bảng allocation còn báo cáo mọi tổ hợp khả thi ở $N = 1, 2, 3$ và production bank 3T+2D. Không có dữ liệu để giả lập trung thực 5T+0D hay 0T+5D; luận văn ghi đây là giới hạn thay vì đếm bản sao.

5.8 Môi trường tính toán và tái lập

Hệ thống được phát triển trong WSL với môi trường `conda rna-fold`; mã nguồn và cấu hình thí nghiệm được quản lý bằng Git. Suy luận DRfold2 sử dụng GPU Kaggle khi tài nguyên cục bộ không đủ. Các tệp cấu trúc và bộ trọng số lớn được lưu ngoài Git, trong khi tệp kê khai, nguồn gốc dữ liệu, cấu hình, báo cáo và bảng tổng hợp được lưu trong kho mã. **TODO: Bổ sung CPU, GPU, RAM, phiên bản WSL, CUDA, Python, PyTorch và thời gian chạy cuối từ tệp kê khai.**

Chapter 6

Kết quả

6.1 RQ1: Mở rộng khả năng tìm khuôn mẫu

Giả thuyết đầu tiên cho rằng một cơ chế truy hồi nhanh có thể bỏ lỡ những khuôn mẫu xa, và việc bổ sung tìm kiếm tương đồng mở rộng sẽ cải thiện chất lượng tập dự đoán. Hai phương pháp được so sánh trên cùng 12 đối tượng CASP15, cùng bộ lọc thời gian, cùng bước chuyển tọa độ và cùng bộ tinh chỉnh; khác biệt duy nhất là việc bật tìm kiếm mở rộng.

Table 6.1: Ảnh hưởng của tìm kiếm tương đồng mở rộng đối với TBM

Phương pháp	TM trung bình tốt nhất trong năm	Chênh lệch
Chỉ MMseqs2	0.2117	—
MMseqs2 + tìm kiếm tổng hợp	0.3072	+0.0955
Ứng viên đầu theo phương pháp tái tạo, an toàn theo thời gian	0.2983	+0.0866 so với chỉ MMseqs2

Tìm kiếm mở rộng cải thiện 11 trong 12 đối tượng. R1116 là ngoại lệ duy nhất, giảm 0.0084. Trên R1108, TM-score tăng từ 0.3124 lên 0.4889; trên R1117v2, MMseqs2 không tìm được khuôn mẫu hữu ích nhưng nhánh mở rộng tạo đủ năm cấu trúc và tăng điểm từ 0.0999 lên 0.4199. Vì các bước còn lại được giữ cố định, mức tăng trung bình 0.0955 được quy chủ yếu cho khả năng truy hồi khuôn mẫu tốt hơn. Kết quả cũng cho thấy việc thêm một cơ chế tìm kiếm không bảo đảm cải thiện mọi RNA: khuôn mẫu xa vẫn có thể làm xếp hạng nhiều nếu giống trình tự nhưng không phản ánh đúng cấu trúc.

Để giải thích cơ chế thay vì chỉ báo cáo điểm cuối, một ablation mới được chạy trên 20 RNA hiệu chỉnh. MMseqs2 chỉ trả candidate ở 8/20 RNA; composite trả đủ ở 20/20. Trên

8 RNA có hit, MMseqs2 đạt best-of-five TM 0.678316, nhưng đây là trung bình có điều kiện và không đại diện 12 RNA thất bại retrieval. Hợp MMseqs2–composite đạt 0.389705 trên đủ 20 RNA, so với 0.376060 của composite đơn lẻ.

Table 6.2: Ablation nguồn truy hồi trên 20 RNA hiệu chỉnh

Nguồn	RNA có candidate	Availability	Best-5 khi có	Coverage
MMseqs2	8/20	0.40	0.678316	0.930965
Composite	20/20	1.00	0.376060	0.754893
Hợp hai nguồn	20/20	1.00	0.389705	0.812411

Component study không xác nhận rằng bộ trọng số composite là tối ưu. G-only đạt best-5 0.381177, còn full weighted đạt 0.376060; chênh +0.005117 theo hướng G-only có CI $[-0.002178, +0.015004]$. Thay đổi trọng số G, L quanh $\pm 25\%$ chỉ làm điểm dao động trong khoảng 0.375435–0.376500. Kết luận đúng mức là score composite ổn định và giúp recall, không phải mọi component đều tăng TM. Khi cho phép template phát hành sau target, best-5 tăng lạc quan 0.026961; đây là định lượng trực tiếp cho nhu cầu temporal filter.

Table 6.3: Ablation reranking trên cùng pool composite high-recall

Ranking	Top-1	Top-3	Top-5	PDB khác nhau
Identity	0.334450	0.363854	0.371900	4.85
Identity $\times$ coverage	0.363720	0.378412	0.387558	4.95
$\times$ completeness	0.363720	0.378412	0.387558	4.95
+ distinct-PDB	0.363720	0.378412	0.387558	5.00

Coverage là component reranking có hiệu ứng thực dụng lớn nhất (Δ best-5 +0.015659), dù CI còn chứa 0. Completeness không đổi ranking trên cohort có tọa độ gần đầy đủ; distinct-PDB tăng đa dạng nguồn nhưng không tăng TM. Với gap-fill, heuristic cong không khác tuyến tính ở gap 1–8 nucleotide, nhưng giảm SW-RMSD9 trung bình 0.036778 Å ở gap 9–20, CI $[0.009289, 0.067605]$. Với gap > 20, phần lớn là terminal nên hai cách dùng cùng extrapolation và cho kết quả bằng nhau.

6.1.1 Đánh giá bên ngoài trên Kaggle

Hai chương trình Kaggle được đóng băng trước khi xem điểm của tập riêng đạt:

Table 6.4: Đánh giá bên ngoài của TBM và pipeline lai cuối

Phương pháp	Công khai	Riêng tư
TBM	0.60084	0.60175
3 TBM + 2 DRfold2 + Geometry v2	0.62809	0.61390
Chênh lệch tuyệt đối	+0.02725	+0.01215

Phiên bản TBM gồm MMseqs2 và tìm kiếm mở rộng, lọc theo thời gian và PDB của chính đối tượng, căn chỉnh lại, chuyển tọa độ, lấp khoảng trống, tinh chỉnh hình học 300 bước và kiểm tra tệp CSV. Phiên bản này không chứa DRfold2 hay Boltz. Sở tay tính toán TBM dùng làm tham chiếu trên bảng xếp hạng có điểm được báo cáo là 0.59298, thấp hơn 0.00877 so với điểm trên tập riêng tư 0.60175 của phương pháp trong luận văn. Do tập ản không cung cấp điểm theo từng RNA, kết quả Kaggle là bằng chứng đánh giá bên ngoài cho toàn nhánh TBM, không phải bằng chứng nhân quả riêng cho từng thành phần.

Phiên bản lai `rna3d-thesis-hybrid-geometry-v2`, phiên bản 10, giữ ba cấu trúc TBM xếp hạng cao nhất và thay hai vị trí còn lại bằng hai cấu trúc DRfold2 có độ tin cậy mô hình cao nhất khi chiều dài không quá 600 nucleotide; nếu DRfold2 không khả thi thì vị trí đó quay về TBM. Geometry v2 sau đó tinh chỉnh cả năm cấu trúc trong 300 bước. Trong lần chạy kiểm tra công khai, DRfold2 sinh đủ hai cấu trúc cho 11/12 RNA; RNA dài 720 nucleotide dùng năm cấu trúc TBM, và Geometry v2 hoàn tất cho 60/60 cấu trúc. Tập kết quả khớp đúng 2.515 ID mẫu, không trùng ID, không có tọa độ thiếu và không sử dụng cấu trúc thực nghiệm. Đây là phép loại bỏ thành phần ở mức quy trình: mức tăng 0.01215 trên tập riêng chứng minh cấu hình lai có ích trên tập ản, nhưng không tách riêng phần đóng góp của DRfold2 và Geometry v2.

6.2 RQ2: Giá trị bổ sung của mô hình học sâu

Sau khi tăng khả năng tìm khuôn mẫu, câu hỏi tiếp theo là liệu mô hình học sâu chỉ lặp lại các nếp gấp đã có hay tạo thêm các giả thuyết hữu ích. Để tách chất lượng sinh cấu trúc khỏi chất lượng lựa chọn, thí nghiệm báo cáo cả điểm lý tưởng và điểm được lựa chọn không sử dụng cấu trúc thực nghiệm.

Bằng chứng chính đến từ 20 RNA mới nhất. Candidate tốt nhất trong ba TBM đạt TM 0.565183; candidate tốt nhất trong hai DRfold2 đạt 0.502627. DRfold2 vì vậy không mạnh hơn TBM theo trung bình, nhưng thắng TBM trên 8/20 RNA. Khi đặt cả năm cấu trúc vào tập, best-of-five/union oracle tăng lên 0.588304, chênh +0.023121 so với TBM với CI [+0.006444, +0.047519]. Tám RNA cải thiện và 12 RNA giữ nguyên vì scorer vẫn có thể

chọn candidate TBM cũ.

Table 6.5: Allocation TBM–DRfold2 với Geometry tắt trên 20 RNA mới nhất

Allocation	Số candidate	Mean best TM	Chênh so với TBM cùng N
1T+0D	1	0.533635	–
0T+1D	1	0.488402	–0.045233
2T+0D	2	0.549041	–
1T+1D	2	0.579587	+0.030546
3T+0D	3	0.565183	–
2T+1D	3	0.581195	+0.016012
1T+2D	3	0.582752	+0.017569
3T+2D	5	0.588304	+0.023121 so với 3T

Fixed- $N = 3$ thay một TBM bằng một DRfold2 tăng trung bình 0.016012 nhưng CI $[-0.002072, +0.041466]$ chứa 0: hiệu ứng có lợi tập trung ở 7 RNA, 10 hòa và 3 giảm. Ở $N = 2$, 1T+1D tăng 0.030546 với CI $[+0.002949, +0.068185]$. Hai DRfold2 đơn lẻ lại thấp hơn hai TBM 0.046414. Mẫu này hỗ trợ claim “complementarity”: giữ đại diện của cả hai nguồn tốt hơn thay toàn bộ TBM bằng deep learning.

6.2.1 Bằng chứng phát triển CASP15

Table 6.6: Khả năng bao phủ nếp gấp của TBM và mô hình học sâu

Phân tích	Số RNA	TBM lựa chọn	Hợp lựa chọn	TBM lý tưởng	Hợp lý tưởng
Đủ 12 RNA	12	0.3113	0.4713	0.3143	0.5123
Loại R1128 trùng trình tự	11	0.3155	0.4245	0.3188	0.4693

Mức tăng của điểm lý tưởng lần lượt là +0.1981 và +0.1505. Khi loại R1128 có trùng lặp trình tự, mô hình học sâu vẫn làm tăng điểm này ở 10 trong 11 RNA và giữ nguyên một RNA. Do đó lợi ích không chỉ đến từ trường hợp trùng dữ liệu. Tuy nhiên, nguồn học sâu không luôn vượt TBM: ở R1117v2, điểm lý tưởng của TBM đạt 0.4616 còn mô hình học sâu chỉ đạt 0.2799. Hệ thống lai vì thế cần bảo tồn cấu trúc tốt từ cả hai nguồn, thay vì luôn ưu tiên một nguồn.

Điểm lựa chọn của pilot đạt 0.4713, thấp hơn oracle 0.5123 khoảng 0.0411. Kết quả này giải thích vì sao GeoFuse từng được khảo sát, nhưng không còn là phát hiện trung tâm của luận văn sau khi phép hợp nhất không khái quát. Pipeline cuối giữ allocation cố định.

Độ tin cậy thô không giải quyết được nút thắt này. Trên 55 cấu trúc DRfold2, tương quan Spearman gộp giữa độ tin cậy và TM là 0.486, nhưng tương quan trung bình khi xếp hạng trong từng RNA chỉ là -0.036 . Quan hệ gộp chủ yếu phân biệt những RNA dễ và khó, chứ không ổn định để chọn giữa các cấu trúc của cùng một RNA hoặc giữa TBM với DRfold2.

6.2.2 Boltz trên RNA dài

R1138 dài 720 nucleotide:

$$TM_{TBM} = 0.2243, \quad TM_{Boltz} = 0.2751, \quad \Delta = +0.0508. \quad (6.1)$$

Kết quả này cho thấy Boltz có thể cung cấp một phương án bổ sung khi DRfold2 không chạy được vì giới hạn bộ nhớ. Một trường hợp đơn lẻ không đủ để kết luận Boltz luôn tốt hơn DRfold2 hoặc TBM.

6.3 RQ3: Hiệu quả, cơ chế và khả năng khái quát của Geometry v2

6.3.1 Khóa cấu hình trên 20 RNA hiệu chỉnh

Priors được ước lượng lại chỉ từ 60 RNA train. Trên 20 RNA calibration, hai cấu hình full fixed/adaptive đều qua gate: TM không giảm quá 0.005, IDDT tăng và ít nhất hai trong ba sliding-window RMSD giảm. Source restraint 1.5 tạo mức tăng IDDT lớn nhất trong các cấu hình full khai báo trước nên được đóng băng trước khi mở validation.

Table 6.7: Các ablation tiêu biểu trên 20 RNA hiệu chỉnh

Variant	Best-5 TM	IDDT	SW9	Kink	Angle NLL	Torsion NLL
Raw	0.407436	0.500573	4.175314	0.043392	0.867374	0.790828
Source+backbone	0.406346	0.510639	4.170749	0.063631	0.910474	0.823790
Full fixed	0.404957	0.506502	4.148670	0.039937	0.630507	0.704167
Full adaptive	0.404908	0.508102	4.151196	0.040512	0.635805	0.702107
Full, source=1.5	0.404674	0.511698	4.144572	0.038782	0.591498	0.677023

Đối chứng source+backbone thậm chí tăng IDDT mạnh, nhưng làm sharp-kink, angle NLL và torsion NLL xấu hơn. Leave-one-out giải thích các thành phần: bỏ backbone đưa

lDDT về 0.500739, gần raw; bỏ angle làm angle NLL tăng từ 0.638915 lên 0.837255; bỏ torsion làm torsion NLL tăng từ 0.706165 lên 0.829415; bỏ kink guard tăng kink từ 0.040512 lên 0.045454; bỏ clash/Rg tăng clash proxy. Không component nào một mình chứng minh native accuracy; vai trò của chúng là kiểm soát kiểu lỗi tương ứng.

Convergence cho thấy lDDT calibration tăng lần lượt 0.506190, 0.506357, 0.506953, 0.507858 và 0.508102 ở 25, 50, 100, 200 và 300 bước. Mức cải thiện dần bão hòa, không có dấu hiệu cần tối ưu vô hạn. Learning rate 0.02–0.08 và source restraint 1.5–6.0 đều giữ TM trong gate; phương pháp không phụ thuộc đúng một hằng số duy nhất.

6.3.2 Kết quả confirmatory trên 20 RNA mới nhất

Table 6.8: Raw, đối chứng đơn giản và Geometry v2 trên tập xác nhận mới nhất

Chỉ số	Raw	Source+backbone	Full Geometry v2
Best-of-5 TM	0.588304	0.587767	0.587197
C1' RMSD (Å)	10.903641	10.902999	10.903764
C1'-lDDT	0.659836	0.667417	0.666496
SW-RMSD9 (Å)	2.651395	2.641594	2.611010
SW-RMSD15 (Å)	4.273393	4.264781	4.256136
SW-RMSD31 (Å)	7.562650	7.558546	7.557402
Sharp-kink fraction	0.048977	0.068558	0.044498
Angle NLL	0.820552	0.869599	0.618824
Torsion NLL	0.837811	0.871896	0.734876

Full Geometry v2 tăng lDDT +0.006660, CI 95% [+0.000933, +0.013093], cải thiện 12 và làm giảm 8 RNA. SW-RMSD9 giảm 0.040386, CI [0.029354, 0.052090], cải thiện 19/20 RNA; SW-RMSD15 giảm 0.017257, CI [0.000617, 0.031336], cải thiện 15/20. SW-RMSD31 giảm 0.005248 nhưng CI chứa 0. TM giảm 0.001107, CI [−0.002809, +0.000418]: không có bằng chứng TM thay đổi và mức giảm nằm trong biên bảo toàn 0.005. Gate confirmatory vì vậy đạt.

Đối chứng đơn giản tăng lDDT +0.007581, lớn hơn full 0.000921 nhưng chênh trực tiếp có CI [−0.003118, +0.001327]; full không thắng đối chứng về lDDT. Full thắng rõ ở SW9 (+0.030585 theo chiều giảm lỗi, CI [0.019640, 0.044115]) và sửa các diagnostic mà đối chứng làm xấu. Claim đúng là full Geometry tạo projection cân bằng hơn ở nhiều khía cạnh; không phải mọi metric native đều vượt baseline đơn giản.

6.3.3 Factorial nguồn ứng viên và Geometry

Factorial fixed- $N = 3$ cho kết quả: TBM 3T+0D đạt 0.565183 khi Geometry off và 0.559331 khi on; hybrid 2T+1D đạt 0.581195 off và 0.578592 on. Hiệu ứng Geometry là -0.005852 trên TBM (CI chứa 0) và -0.002604 trên hybrid (CI $[-0.005473, -0.000278]$). Interaction $+0.003248$ có CI chứa 0. Như vậy mức tăng của pipeline Kaggle không được quy cho Geometry: nguồn candidate đa dạng tăng fold coverage, còn Geometry chủ yếu sửa cục bộ và có thể đổi candidate thắng best-of- N theo chiều xấu.

6.3.4 Khi nào tinh chỉnh có lợi?

Theo chất lượng raw, nhóm thấp tăng IDDT $+0.016261$, CI $[+0.008900, +0.024089]$; nhóm cao thay đổi -0.001788 , CI chứa 0. Nhóm TBM tăng $+0.007610$ với CI dương; DRfold2 tăng $+0.005235$ nhưng CI chứa 0. Hiệu ứng rõ hơn ở candidate support thấp và confidence trung bình; RNA ngắn/dài có interval rộng do chỉ có 4/5 target. Phát hiện này gợi ý Geometry nên được gate theo chất lượng ban đầu trong tương lai, nhưng luận văn không học gate mới sau khi đã mở validation.

6.4 Mạch phát hiện qua ba câu hỏi nghiên cứu

Ba câu hỏi tạo thành một chuỗi rõ: composite giúp TBM không rơi vào trạng thái không có khuôn; DRfold2 bổ sung một số nếp gấp TBM bỏ lỡ; Geometry v2 sửa quan hệ cục bộ trên candidate đã có. Candidate diversity cải thiện best-of-five TM, còn Geometry không tạo nếp gấp mới và không tăng TM. Giá trị khoa học nằm ở việc tách đúng hai hiệu ứng này và kiểm chứng local refinement trên một split thời gian/họ độc lập.

Chapter 7

Thảo luận

7.1 Từ retrieval coverage đến candidate complementarity

RQ1 cho thấy hai tầng search có vai trò khác nhau. MMseqs2 tạo candidate chất lượng cao khi có hit nhưng chỉ phủ 40% cohort hiệu chỉnh; composite hạ precision trung bình để đạt availability 100%. Reranking identity $\times$ coverage chuyển một phần recall đó thành top- k precision. Distinct-PDB không tăng TM trên cohort này nhưng làm năm giả thuyết ít phụ thuộc một PDB hơn. Đây là kết luận component-specific, mạnh hơn việc chỉ nói “full TBM tăng điểm”.

RQ2 cho thấy DRfold2 không thay thế TBM: oracle riêng của DRfold2 thấp hơn, nhưng thắng ở 8/20 RNA. Giữ đại diện cả hai nguồn làm union tăng 0.023121. Fixed-size allocation xác nhận hướng hiệu ứng dương nhưng CI còn rộng; do đó claim là complementarity có điều kiện theo target, không phải deep learning luôn ưu việt.

7.2 Vì sao Geometry v2 cải thiện cục bộ nhưng không tăng TM-score

Hàm mục tiêu của Geometry v2 được thiết kế để giữ gần cấu trúc nguồn. Trên tập confirmatory, IDDT và RMSD của số 9/15 cải thiện với CI không chứa 0, trong khi TM giảm 0.001107 và CI chứa 0. Projection dịch mỗi nucleotide trung bình khoảng 0.305 Å nhưng không tạo tiếp xúc xa hay nếp gấp mới.

TM-score ưu tiên nếp gấp tổng thể và giảm ảnh hưởng của một số sai số cục bộ. Geometry v2 không tạo tiếp xúc xa mới, không đổi cách các miền sắp xếp và không tìm một kiểu nếp gấp khác; do đó không có cơ chế mạnh để tăng TM-score nếu cấu trúc nguồn sai

toàn cục. Giá trị của phương pháp nằm ở việc sửa vừa phải quan hệ C1' cục bộ mà không làm mất giả thuyết nếp gấp đã có. Đối chứng source–backbone cho thấy một phần IDDT gain đến từ smoothing đơn giản; full Geometry được biện minh bởi SW9 tốt hơn và việc không làm xấu kink/angle/torsion. Stratification cho thấy gain tập trung ở candidate yếu, còn nhóm chất lượng cao không cải thiện. Vì biểu diễn chỉ gồm C1', kết quả không cho phép suy rộng sang bắt cặp base hay hóa học lập thể toàn nguyên tử.

7.3 Quan hệ giữa phần kế thừa và đóng góp của luận văn

Table 7.1: Nguồn gốc và vai trò của các thành phần

Thành phần	Nguồn ý tưởng	Phần được thực hiện hoặc nghiên cứu thêm
Tìm kiếm tương đồng mở rộng	Sổ tay tính toán TBM tham chiếu	Kết hợp MMseqs2, lọc thời gian/PDB, xếp hạng lại và đánh giá có đối chứng.
Chuyển tọa độ và lấp khoảng trống	TBM truyền thống và mã cuộc thi	Mật nạ hỗ trợ, độ tin cậy theo nucleotide và biểu diễn nguồn gốc thống nhất.
DRfold2/Boltz	Mô hình công bố	Kiểm tra mốc dữ liệu/trùng lặp, chuẩn hóa ứng viên và allocation fixed- N .
Geometry v2	Đóng góp phương pháp	Phân bố tiên nghiệm theo ngữ cảnh, cường độ thích nghi, ràng buộc nguồn, bảo vệ góc gấp và đánh giá cục bộ độc lập.
Quy trình đánh giá	Các bộ đánh giá chuẩn về cấu trúc	Chia theo thời gian/họ, nhiều chỉ số bổ sung và lấy mẫu lại theo RNA.

7.4 Quan hệ với kết quả cuộc thi

Sổ tay tính toán TBM tham chiếu có điểm được báo cáo là 0.59298. Phiên bản lai V4 có điểm 0.57631 và kết hợp Boltz, DRfold2 với ràng buộc cùng phương án quay về khuôn mẫu, nhưng không thực hiện lựa chọn nguồn cục bộ theo độ tin cậy. Mã nguồn này cũng có một số vấn đề về chỉ số hàng, lựa chọn đối tượng và tọa độ giữ chỗ; vì vậy điểm thấp hơn không phải bằng chứng rằng mô hình học sâu về bản chất kém hơn TBM [17, 18].

Phương pháp TBM của luận văn đạt 0.60175 trên tập riêng tư. Pipeline lai cuối đạt 0.61390, cao hơn 0.01215, nên khả năng triển khai và lợi ích của toàn cấu hình lai đã được

xác nhận bằng một lần nộp bên ngoài. Tuy nhiên, kết quả này đồng thời thay đổi thành phần ứng viên và áp dụng Geometry v2; vì vậy không được dùng để quy toàn bộ mức tăng cho một thành phần riêng. Factorial công khai cho thấy source diversity làm tăng fold coverage còn Geometry không tăng TM; bằng chứng cho Geometry đến từ chỉ số cục bộ trên tập xác nhận, không phải từ việc dò ngược bảng xếp hạng.

7.5 Các nguy cơ đối với tính hợp lệ

7.5.1 Tính hợp lệ nội tại

Nguy cơ gồm rò rỉ qua ngày công bố, khuôn mẫu của chính đối tượng, trình tự trùng hoàn toàn, mốc huấn luyện của mô hình học sâu và việc thay đổi tượng sau lỗi kỹ thuật. Các kiểm tra đã giảm rủi ro nhưng không thể chứng minh tuyệt đối rằng bộ trọng số chưa học một quan hệ họ hàng xa. Một số dữ liệu lớn nằm ngoài Git nên cần tệp kê khai và mã kiểm tra đầy đủ trước khi công bố.

7.5.2 Khả năng khái quát

Geometry v2 được xác nhận trên 20 RNA dài tối đa 96 nucleotide, sau calibration 20 RNA và prior-train 60 RNA. Kết quả chưa chắc áp dụng cho RNA rất dài, phức hợp nhiều chuỗi hoặc họ RNA ít được đại diện. Tập ản Kaggle khác CASP15 nên điểm giữa hai tập không thể so sánh trực tiếp.

7.5.3 Mức độ phù hợp của đại lượng đo

C1'-IDDT là bản thích nghi, độ dài cửa sổ là lựa chọn phân tích, còn tỷ lệ góc gấp sắc, va chạm C1', NLL góc phẳng/góc xoắn và chỉ dấu có dạng cặp là các đại lượng nội bộ. Chúng không đo trực tiếp độ đúng của cặp base nitơ, xếp chồng hoặc tính hợp lý vật lý toàn nguyên tử.

7.5.4 Tính hợp lệ của kết luận thống kê

Số RNA độc lập nhỏ hơn số nucleotide rất nhiều; candidate của cùng RNA cũng tương quan. Mỗi subgroup trước hết được trung bình trong target/group cell rồi mới bootstrap RNA. Những CI chứa 0 được trình bày là bằng chứng chưa đủ, không bị diễn giải thành cải thiện.

7.6 Hạn chế kỹ thuật

DRfold2 đòi hỏi GPU và khó chạy trên trình tự dài; Boltz chưa được tích hợp thống nhất vào đường xác nhận. Bản Kaggle lai vì vậy giới hạn DRfold2 ở 600 nucleotide và quay về TBM cho trình tự dài hơn. Bộ chọn năm cấu trúc vẫn dùng một luật cố định ba TBM cộng hai DRfold2 thay vì một ước lượng chất lượng toàn cấu trúc đã hiệu chỉnh. Một số nucleotide biến đổi hiếm được ánh xạ thành N, có thể làm giảm nhẹ mức đồng nhất trình tự dù tọa độ vẫn được chuyển.

Trong phạm vi những giới hạn trên, kết luận của luận văn được giữ ở mức tương xứng với dữ liệu: TBM và pipeline lai cuối đều đã được đánh giá bên ngoài trên Kaggle; nguồn học sâu tăng fold coverage; Geometry v2 cải thiện đường C1' cục bộ trên tập confirmatory nhưng không tăng TM-score.

Chapter 8

Kết luận và hướng phát triển

8.1 Kết luận

Luận văn đã xây dựng một pipeline RNA 3D mức C1' an toàn theo thời gian. MMseqs2 tạo precision khi có homolog rõ, còn composite bảo đảm retrieval coverage; reranking coverage chuyển một phần recall thành chất lượng top- k . Nhánh TBM đạt private Kaggle 0.60175. DRfold2 không mạnh hơn TBM trên mọi RNA nhưng thắng ở 8/20 RNA mới nhất; union 3T+2D đạt oracle 0.588304 so với 0.565183 của 3T. Pipeline lai cuối đạt private Kaggle 0.61390. Các kết quả fixed- N cho phép quy lợi ích này cho candidate complementarity thận trọng hơn, thay vì gán toàn bộ cho deep learning hoặc Geometry.

Đóng góp phương pháp Geometry v2 được kiểm tra bằng protocol 60/20/20. Trên 20 RNA confirmatory, IDDT tăng 0.006660 và SW-RMSD9 giảm 0.040386 Å với CI dương; TM giảm 0.001107, CI chứa 0 và nằm trong biên bảo toàn. Đối chứng source–backbone cho IDDT tương đương, nhưng full Geometry tốt hơn rõ ở SW9 và tránh làm xấu kink/angle/torsion. Hiệu ứng tập trung ở candidate ban đầu yếu. Factorial không cho thấy Geometry tăng TM, nên claim cuối là local refinement có kiểm chứng, không phải fold predictor.

Câu chuyện luận văn vì vậy gọn thành ba contribution: TBM time-safe có component analysis; bằng chứng TBM–DRfold2 complementarity; và Geometry v2 với ablation, baseline và held-out validation. GeoFuse bị loại khỏi core vì chưa móc được quality signal thành một cải thiện tọa độ khái quát.

8.2 Hướng phát triển ưu tiên

1. **Gate Geometry theo chất lượng ban đầu:** kiểm tra trên một cohort mới quy tắc chỉ refine candidate quality thấp; không học gate từ 20 RNA đã mở.

2. **Mở rộng allocation bank:** sinh thật ít nhất năm TBM và năm DRfold2 mỗi RNA để chạy fixed-five 5T–0D tới 0T–5D, thay vì đệm bản sao.
3. **Mở rộng số họ và chiều dài:** xác nhận trên RNA dài, phức hợp nhiều chuỗi và các họ ít đại diện; đánh giá riêng fallback Boltz.
4. **Đánh giá toàn nguyên tử:** dựng cấu trúc đầy đủ để đo cặp base nitơ, xếp chồng, va chạm lập thể và độ trung thành của mạng tương tác khi tài nguyên cho phép.
5. **Cải thiện lựa chọn cấu trúc:** học điểm chất lượng toàn cấu trúc có hiệu chỉnh riêng theo nguồn và mục tiêu đa dạng tường minh để giảm khoảng cách tới trần lý tưởng.
6. **Đối chứng refinement ngoài hệ:** nếu dựng được full-atom, so sánh với QRNAS hoặc force-field refinement theo cùng source restraint và native-blind protocol.

Appendix A

Thí nghiệm khám phá GeoFuse (không thuộc pipeline cuối)

A.1 Giả thuyết

GeoFuse thử trả lời câu hỏi: nếu một đoạn TBM tốt còn đoạn khác DRfold2 tốt, liệu có thể dùng đặc trưng native-blind để chọn nguồn theo nucleotide rồi ghép hai cấu trúc hay không? Hai cấu trúc trước hết được phân cụm self-TM để tránh ghép khác nếp gấp, chồng khít Kabsch, sau đó Conv1D dự đoán xác suất DRfold2 tốt hơn theo C1'-IDDT cục bộ. Chỉ đoạn dài ít nhất bảy nucleotide, xác suất ít nhất 0.90 và bất đồng 0.5–12 Å mới được ghép; nếu không, phương pháp từ chối.

A.2 Kết quả khám phá

Trên 20 RNA validation, Conv1D đạt ROC-AUC 0.729868 và lỗi 1-IDDT 0.238994, tốt hơn luật confidence/gap cố định. Tuy nhiên, điều đó chỉ chứng minh đặc trưng có tín hiệu so sánh nguồn, chưa chứng minh vector tọa độ hợp nhất đúng. Với ngưỡng khóa trên calibration, GeoFuse từ chối toàn bộ quyết định; TM/IDDT giữ nguyên 0.588304/0.795059. Một luật kinh nghiệm nói hơn tạo 24 cấu trúc, tăng TM trung bình 0.001681 nhưng CI $[-0.004908, +0.008495]$ chứa 0 và IDDT giảm 0.001218.

A.3 Quyết định phạm vi

GeoFuse không đạt tiêu chí “tạo cấu trúc tốt hơn trên RNA mới” và không tham gia submission Kaggle 0.61390. Vì vậy luận văn không coi Conv1D, clustering hay fusion là contribution. Thí nghiệm được lưu để minh bạch lịch sử nghiên cứu và giải thích một failure mode: biết nguồn nào có lỗi cục bộ thấp hơn không tự động cho biết cách cắt, căn chỉnh và ghép tọa độ liên tục. Hướng này chỉ nên mở lại với target mới, gate mới được preregister và một mô hình học phân dư tọa độ $SE(3)$ -equivariant.

Appendix B

Bảng thuật ngữ

Thuật ngữ	Nghĩa trong luận văn
Cấu trúc ứng viên	Một giả thuyết cấu trúc ba chiều cho RNA cần dự đoán.
Cấu trúc thực nghiệm	Cấu trúc được đo và dùng làm tham chiếu khi huấn luyện hoặc đánh giá.
Khuôn mẫu	Cấu trúc RNA đã biết dùng để chuyển tọa độ sang đối tượng mới.
TBM	Template-based modeling, mô hình hóa dựa trên khuôn mẫu.
Mô hình tiền huấn luyện	Mô hình đã học từ dữ liệu trước đó; bộ trọng số được giữ cố định khi suy luận.
Nếp gấp tổng thể	Kiểu nếp gấp và bố cục lớn của cấu trúc ba chiều.
Hình học cục bộ	Khoảng cách, góc phẳng và góc xoắn trong một vùng nucleotide ngắn.
Căn chỉnh	Ánh xạ nucleotide của đối tượng với nucleotide của khuôn mẫu.
Khoảng trống	Vị trí không có nucleotide khuôn mẫu tương ứng.
k -mer	Đoạn trình tự liên tiếp dài k .
Tìm kiếm mở rộng	Quét toàn thư viện tương đồng, không phải vét cạn không gian 3D.
Độ tin cậy	Tín hiệu nội bộ của mô hình, không đồng nhất với độ chính xác.
Hiệu chỉnh	Liên hệ đầu ra độ tin cậy với tần suất đúng quan sát được.

Thuật ngữ	Nghĩa trong luận văn
Oracle	Điểm lý tưởng do lựa chọn bằng cấu trúc thực nghiệm sau đánh giá; không triển khai được khi suy luận.
OOF	Dự đoán cho một mẫu nằm ngoài nếp gấp dữ liệu dùng để huấn luyện mô hình đó.
An toàn theo thời gian	Chỉ dùng dữ liệu đã tồn tại trước mốc của đối tượng.
Self-TM	TM-score giữa hai cấu trúc dự đoán, không cần cấu trúc thực nghiệm.
Cơ chế từ chối	Không hợp nhất khi bằng chứng chưa đủ mạnh.
Tinh chỉnh	Sửa nhẹ một cấu trúc có sẵn, không dự đoán lại nếp gấp từ đầu.

Appendix C

Danh sách kiểm tra khả năng tái lập

1. Tạo môi trường conda từ `environment.yml` và ghi phiên bản gói chính xác.
2. Kiểm tra mã kiểm tra của CSV, CIF, cơ sở khuôn mẫu, bộ trọng số và dữ liệu tạm.
3. Xây cơ sở khuôn mẫu bằng bộ đọc hiện tại; xác nhận số dòng và độ phủ ngày công bố.
4. Kiểm tra rò rỉ thời gian và PDB của chính đối tượng; mốc thiếu hoặc sai phải bị từ chối.
5. Chạy kiểm thử cho bộ đọc, căn chỉnh, chỉ số, gap-fill baseline và Geometry v2.
6. Tái tạo TBM white-box ablation trên 20 RNA hiệu chỉnh.
7. Tái tạo đánh giá Geometry v2 và lấy mẫu lại theo RNA với hạt giống ngẫu nhiên 2025.
8. Tái tạo tập 60/20/20, xác nhận không có họ hoặc trình tự trùng giữa các tập.
9. Chỉ huấn luyện trên tập huấn luyện; chỉ chọn mô hình và ngưỡng trên tập hiệu chỉnh.
10. Mở tập xác nhận mới nhất đúng một lần và lưu kết quả bất kể chiều hướng.
11. Kiểm tra định dạng tệp nộp cuối và nguồn gốc mọi dữ liệu đi kèm.

Appendix D

Các mục cần hoàn thiện trước khi nộp

- Thay toàn bộ marker TODO trên trang bìa và front matter.
- Chuẩn hóa mẫu LaTeX theo quy định của trường.
- Chốt tên luận văn tiếng Việt/Anh cùng giảng viên hướng dẫn.
- Chuyển tài liệu tham khảo nhúng sang BibTeX theo chuẩn của trường.
- Thêm hình mô tả dữ liệu, khung phương pháp và Geometry v2 từ kho mã.
- Bổ sung bảng kết quả từng RNA vào phụ lục nếu hội đồng yêu cầu.
- Bổ sung phần cứng, thời gian chạy, mã phiên bản Git và mã kiểm tra dữ liệu.
- Lưu mã phiên bản kernel, ID submission, manifest và mã kiểm tra SHA-256 của cả hai lần nộp Kaggle; không điều chỉnh ngược quy trình phát triển để khớp điểm tập riêng.
- Rà soát thuật ngữ Việt–Anh và định dạng số theo hướng dẫn khoa.

Bibliography

- [1] Y. Zhang và J. Skolnick, “Scoring function for automated assessment of protein structure template quality,” *Proteins*, 2004.
- [2] J. Zhang và cộng sự, “US-align: universal structure alignments of proteins, nucleic acids, and macromolecular complexes,” *Nature Methods*, 2022.
- [3] V. Mariani, M. Biasini, A. Barbato và T. Schwede, “IDDT: a local superposition-free score for comparing protein structures and models using distance difference tests,” *Bioinformatics*, 2013.
- [4] J. A. Cruz và cộng sự, “RNA-Puzzles: a CASP-like evaluation of RNA three-dimensional structure prediction,” *RNA*, 2012.
- [5] M. Magnus, M. Antczak, T. Zok và cộng sự, “RNA-Puzzles toolkit: a computational resource of RNA 3D structure benchmark datasets, structure manipulation, and evaluation tools,” *Nucleic Acids Research*, tập 48, số 2, trang 576–588, 2020, doi: 10.1093/nar/gkz1108.
- [6] X. Wang, S. Yu, E. Lou, Y.-L. Tan và Z.-J. Tan, “RNA 3D Structure Prediction: Progress and Perspective,” *Molecules*, tập 28, số 14, bài 5532, 2023, doi: 10.3390/molecules28145532.
- [7] C. Bernard, G. Postic, S. Ghannay và F. Tahi, “State-of-the-RNArt: benchmarking current methods for RNA 3D structure prediction,” *NAR Genomics and Bioinformatics*, tập 6, số 2, lqae048, 2024, doi: 10.1093/nargab/lqae048.
- [8] Y. Kagaya, B. Liu và D. Kihara, “Computational approaches for RNA structure prediction and design,” *Cell Reports Physical Science*, tập 7, số 2, bài 103097, 2026, doi: 10.1016/j.xcrp.2026.103097.
- [9] M. Biesiada, K. J. Purzycka, M. Szachniuk, J. Blazewicz và R. W. Adamiak, “Automated RNA 3D Structure Prediction with RNAComposer,” *Methods in Molecular Biology*, tập 1490, trang 199–215, 2016, doi: 10.1007/978-1-4939-6433-8_13.

- [10] Y. Li, C. Zhang, C. Feng, R. Pearce, P. L. Freddolino và Y. Zhang, “Integrating end-to-end learning with deep geometrical potentials for ab initio RNA structure prediction,” *Nature Communications*, tập 14, bài 5745, 2023.
- [11] T. Shen, Z. Hu, S. Sun và cộng sự, “Accurate RNA 3D structure prediction using a language model-based deep learning approach,” *Nature Methods*, tập 21, trang 2287–2298, 2024, doi: 10.1038/s41592-024-02487-0.
- [12] Y. Li, C. Feng, X. Zhang, S. Tsukiyama, D. Feng và Y. Zhang, “DRfold2 is a deep learning-based tool that enables efficient and accurate RNA structure prediction,” *PLOS Biology*, tập 24, số 2, e3003659, 2026, doi: 10.1371/journal.pbio.3003659.
- [13] J. Wohlwend, G. Corso, S. Passaro và cộng sự, “Boltz-1: Democratizing Biomolecular Interaction Modeling,” *bioRxiv*, 2024, doi: 10.1101/2024.11.19.624167.
- [14] R. J. L. Townshend, S. Eismann, A. M. Watkins và cộng sự, “Geometric deep learning of RNA structure,” *Science*, tập 373, trang 1047–1051, 2021, doi: 10.1126/science.abe5650.
- [15] P. Lukasiak, M. Antczak, T. Ratajczak và J. Blazewicz, “RNAAssess—a web server for quality assessment of RNA 3D structures,” *Nucleic Acids Research*, tập 43, trang W502–W506, 2015, doi: 10.1093/nar/gkv557.
- [16] Stanford RNA 3D Folding Competition, Kaggle competition documentation, <https://www.kaggle.com/competitions/stanford-rna-3d-folding>.
- [17] JaeJohn, “RNA 3D folds — TBM only approach,” Kaggle notebook, version được báo cáo 0.59298, <https://www.kaggle.com/code/jaejohn/rna-3d-folds-tbm-only-approach>.
- [18] JaeJohn, “Sub 1 4 4 hybrid final take,” Kaggle notebook, version được báo cáo 0.57631, <https://www.kaggle.com/code/jaejohn/sub-1-4-4-hybrid-final-take>.