

TRƯỜNG ĐẠI HỌC KHOA HỌC VÀ CÔNG NGHỆ HÀ NỘI  
ICT LAB

**ĐỒ THÀNH ĐẠT**

**MÔ HÌNH LAI DỰA TRÊN KHUÔN MẪU  
VÀ HỌC SÂU CHO DỰ ĐOÁN  
CẤU TRÚC BA CHIỀU RNA  
VỚI KIỂM SOÁT RÒ RỈ THỜI GIAN  
VÀ TÍNH CHỈNH HÌNH HỌC**

A Hybrid Template-Based and Deep-Learning Framework  
for RNA Three-Dimensional Structure Prediction with  
Temporal Leakage Control and Geometry Refinement

LUẬN VĂN THẠC SĨ

DATA SCIENCE

Giảng viên hướng dẫn: NGUYỄN MINH HƯƠNG  
NGUYỄN CẨM LINH

Mã số học viên: 2440059

HÀ NỘI, 2026

# Lời cam đoan

**[CẦN ĐIỀN: Bổ sung lời cam đoan theo biểu mẫu chính thức của trường.]**

# Lời cảm ơn

**[CẦN ĐIỀN: Bổ sung lời cảm ơn giảng viên hướng dẫn, đơn vị đào tạo, đồng nghiệp và gia đình.]**

# Tóm tắt

Dự đoán cấu trúc ba chiều RNA từ trình tự vẫn là một bài toán khó vì không gian cấu dạng lớn, dữ liệu cấu trúc thực nghiệm hạn chế và độ linh động nội tại của RNA [1, 11, 10]. Luận văn xây dựng một pipeline lai gồm mô hình hóa dựa trên khuôn mẫu có kiểm soát thời gian, DRfold2 như nguồn ứng viên độc lập và geometry refinement để sửa hình học cục bộ của từng ứng viên. Hệ thống xuất ba cấu trúc từ nhánh khuôn mẫu và hai cấu trúc từ DRfold2, sau đó tinh chỉnh riêng từng cấu trúc mà không sử dụng native label. Thiết kế này phù hợp với cơ chế best-of-five của cuộc thi Stanford RNA 3D Folding, nơi một hệ thống được đánh giá bằng cấu trúc tốt nhất trong năm dự đoán [12, 27].

Luận văn tách bằng chứng thành hai tầng. Tầng local sử dụng protocol thời gian và họ trình tự 60/20/20: 60 RNA để ước lượng prior hình học, 20 RNA để chọn cấu hình và 20 RNA mới nhất để xác nhận sau khi cấu hình đã khóa. Tầng external sử dụng public và private leaderboard của Kaggle như một phép kiểm tra toàn pipeline. Trong nghiên cứu thành phần TBM, MMseqs2 tìm được ít nhất một khuôn cho 8/20 RNA hiệu chỉnh, trong khi tìm kiếm composite tạo ứng viên cho 20/20. Composite vì vậy chủ yếu mở rộng độ phủ truy hồi; công thức trọng số đầy đủ không tốt hơn rõ ràng biến thể chỉ dùng căn chỉnh toàn cục.

Trên 20 RNA xác nhận, ba ứng viên TBM đạt mean best-available TM-score 0.565183 và hai ứng viên DRfold2 đạt 0.502627. Hợp hai nguồn nâng giá trị này lên 0.588304, tương ứng mức tăng 0.023121 với khoảng tin cậy bootstrap 95% [0.006444, 0.047519]. DRfold2 thắng nhánh TBM ở 8/20 target, cho thấy giá trị của nó nằm ở các trường hợp bổ sung thay vì ưu thế trung bình. Sau tinh chỉnh, C1'-IDDT tăng 0.006660 và SW-RMSD9 giảm 0.040386 Å, trong khi TM-score thay đổi  $-0.001107$  với khoảng tin cậy chứa 0. Mẫu kết quả này cho thấy geometry refinement sửa quan hệ cục bộ và gần như bảo toàn nếp gấp tổng thể.

Trên Kaggle, TBM an toàn thời gian đạt 0.60084 public và 0.60175 private. Pipeline cuối gồm ba TBM, hai DRfold2 và geometry refinement đạt 0.62809 public và 0.61390 private, cao hơn mốc private 0.59298 của notebook TBM-only tham chiếu. Vì lần nộp cuối thay đổi cả thành phần ứng viên lẫn tinh chỉnh, chênh lệch leaderboard chỉ được diễn giải ở mức toàn pipeline. Kết hợp với factorial local, bằng chứng hiện có ủng hộ tính bổ sung nguồn như cơ chế chính cho mức tăng global TM, còn geometry refinement đóng vai trò cải thiện độ hợp lý của đường C1' cục bộ.

**Từ khóa:** cấu trúc ba chiều RNA, mô hình hóa dựa trên khuôn mẫu, DRfold2, TM-score, C1'-IDDT, an toàn thời gian, tinh chỉnh hình học.

# Mục lục

|                                                      |            |
|------------------------------------------------------|------------|
| <b>Lời cam đoan</b>                                  | <b>i</b>   |
| <b>Lời cảm ơn</b>                                    | <b>ii</b>  |
| <b>Tóm tắt</b>                                       | <b>iii</b> |
| <b>1 Giới thiệu</b>                                  | <b>1</b>   |
| 1.1 Bối cảnh nghiên cứu . . . . .                    | 1          |
| 1.2 Vấn đề nghiên cứu . . . . .                      | 2          |
| 1.3 Câu hỏi nghiên cứu . . . . .                     | 3          |
| 1.4 Đóng góp . . . . .                               | 3          |
| 1.5 Phạm vi và cấu trúc luận văn . . . . .           | 4          |
| <b>2 Nền tảng và công trình liên quan</b>            | <b>5</b>   |
| 2.1 Tổ chức cấu trúc RNA . . . . .                   | 5          |
| 2.2 Mô hình hóa dựa trên khuôn mẫu . . . . .         | 6          |
| 2.3 Dự đoán bằng học sâu . . . . .                   | 6          |
| 2.4 Tinh chỉnh cấu trúc . . . . .                    | 7          |
| 2.5 Đánh giá cấu trúc . . . . .                      | 7          |
| 2.6 Khoảng trống nghiên cứu . . . . .                | 8          |
| <b>3 Dữ liệu và kiểm soát đánh giá</b>               | <b>9</b>   |
| 3.1 Các nguồn dữ liệu . . . . .                      | 9          |
| 3.2 Cutoff thời gian và loại self-template . . . . . | 11         |
| 3.3 Quy tắc sử dụng nhãn . . . . .                   | 12         |
| 3.4 Đơn vị phân tích và thống kê . . . . .           | 12         |

|                                                       |           |
|-------------------------------------------------------|-----------|
| <b>4 Pipeline đề xuất</b>                             | <b>14</b> |
| 4.1 Tổng quan . . . . .                               | 14        |
| 4.2 Nhánh TBM an toàn thời gian . . . . .             | 15        |
| 4.2.1 Truy hồi hai đường . . . . .                    | 15        |
| 4.2.2 Căn chỉnh lại và xếp hạng . . . . .             | 16        |
| 4.2.3 Chuyển tọa độ và lấp khoảng trống . . . . .     | 17        |
| 4.3 Nhánh DRfold2 . . . . .                           | 17        |
| 4.4 Geometry refinement . . . . .                     | 18        |
| 4.4.1 Mục tiêu thiết kế . . . . .                     | 18        |
| 4.4.2 Prior hình học . . . . .                        | 18        |
| 4.4.3 Baseline và output . . . . .                    | 19        |
| 4.5 Mã giả . . . . .                                  | 19        |
| <b>5 Thiết kế thí nghiệm</b>                          | <b>21</b> |
| 5.1 Chiến lược kiểm định . . . . .                    | 21        |
| 5.2 Ablation TBM . . . . .                            | 22        |
| 5.3 Thí nghiệm tính bổ sung . . . . .                 | 22        |
| 5.4 Thí nghiệm geometry refinement . . . . .          | 23        |
| 5.5 External evaluation và khả năng tái lập . . . . . | 23        |
| <b>6 Kết quả</b>                                      | <b>24</b> |
| 6.1 RQ1: Truy hồi và xếp hạng TBM . . . . .           | 24        |
| 6.1.1 Hai nguồn truy hồi . . . . .                    | 24        |
| 6.1.2 Thành phần composite . . . . .                  | 25        |
| 6.1.3 Reranking và gap fill . . . . .                 | 25        |
| 6.2 RQ2: TBM và DRfold2 bổ sung nhau . . . . .        | 26        |
| 6.3 RQ3: Geometry refinement . . . . .                | 27        |
| 6.3.1 Kết quả xác nhận . . . . .                      | 27        |
| 6.3.2 Baseline đơn giản và ablation . . . . .         | 28        |
| 6.3.3 Factorial source và refinement . . . . .        | 29        |
| 6.3.4 Phân tầng và failure case . . . . .             | 29        |
| 6.4 Đánh giá external trên Kaggle . . . . .           | 30        |

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| <b>7</b> | <b>Thảo luận</b>                                         | <b>32</b> |
| 7.1      | Vì sao pipeline hybrid có giá trị . . . . .              | 32        |
| 7.2      | Vì sao geometry refinement không tăng TM-score . . . . . | 33        |
| 7.3      | Diễn giải điểm leaderboard . . . . .                     | 33        |
| 7.4      | Nguy cơ đối với tính hợp lệ . . . . .                    | 34        |
| 7.4.1    | Tính hợp lệ nội tại . . . . .                            | 34        |
| 7.4.2    | Tính hợp lệ external . . . . .                           | 34        |
| 7.4.3    | Độ phù hợp của metric . . . . .                          | 35        |
| 7.5      | Hướng cải tiến . . . . .                                 | 35        |
| <b>8</b> | <b>Kết luận</b>                                          | <b>36</b> |
| <b>A</b> | <b>Khả năng tái lập</b>                                  | <b>38</b> |
| <b>B</b> | <b>Danh mục hình cần hoàn thiện</b>                      | <b>39</b> |



# Danh mục bảng

|     |                                                                                                                   |    |
|-----|-------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Phân chia dữ liệu cho geometry refinement và complementarity study. . . . .                                       | 10 |
| 5.1 | Ảnh xạ câu hỏi nghiên cứu sang thí nghiệm và claim. . . . .                                                       | 21 |
| 6.1 | Ảnh hưởng của nguồn truy hồi trên 20 RNA calibration. Điểm MMseqs2 là conditional trên tám target có hit. . . . . | 24 |
| 6.2 | Ablation xếp hạng TBM. . . . .                                                                                    | 25 |
| 6.3 | Candidate allocation với geometry refinement tắt. . . . .                                                         | 27 |
| 6.4 | Raw và full geometry refinement trên 20 RNA validation. . .                                                       | 28 |
| 6.5 | Factorial fixed-N=3 tách source composition và geometry refinement. . . . .                                       | 29 |

# Danh mục hình

|     |                                                                                                                                                                                                                  |    |
|-----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Protocol bằng chứng hai tầng. Ba split local tách theo thời gian và họ; Kaggle đóng vai trò external check ở mức toàn pipeline. . . . .                                                                          | 10 |
| 3.2 | Mình họa mức tăng điểm do rò rỉ template trên cohort CASP15 phát triển. Hai cột không an toàn chỉ là diagnostic và không tham gia kết quả phương pháp. . . . .                                                   | 11 |
| 4.1 | Pipeline cuối. Đa dạng nguồn được tạo trước refinement; không có lựa chọn hay hợp nhất tọa độ dựa trên native label.                                                                                             | 14 |
| 4.2 | Luồng TBM. MMseqs2 ưu tiên homolog rõ, composite mở rộng recall, còn safety gate được áp dụng trước khi căn chỉnh lại và chuyển tọa độ. . . . .                                                                  | 16 |
| 4.3 | Cơ chế geometry refinement. Một biến dạng cục bộ được làm tròn trong khi source restraint bảo toàn bố cục tổng thể; các prior còn lại xử lý backbone, angle, torsion, clash, kink và bán kính quán tính. . . . . | 18 |
| 6.1 | Tính bổ sung của candidate bank trên 20 RNA validation. Union gain được tính so với ba TBM và khoảng tin cậy bootstrap theo target. . . . .                                                                      | 26 |
| 6.2 | Effect confirmatory của geometry refinement. Điểm tăng dùng trực score; RMSD reduction dùng angstrom và được định hướng dương là tốt hơn. . . . .                                                                | 28 |
| 6.3 | Đánh giá hidden-set. Mốc TBM-only tham chiếu chỉ có private score được báo cáo; hai phương pháp của luận văn có cả public và private score. . . . .                                                              | 30 |

|                                                                                                                                                                                             |    |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 6.4 Placeholder cho hình chồng cấu trúc. Bản cuối nên dùng một RNA validation có native công khai, cùng một Kabsch transform và đầy đủ provenance; không dùng target hidden Kaggle. . . . . | 31 |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|

# Chương 1

## Giới thiệu

### 1.1 Bối cảnh nghiên cứu

RNA tham gia điều hòa biểu hiện gene, xúc tác, nhận diện phân tử và hình thành các phức hợp ribonucleoprotein. Các chức năng này phụ thuộc không chỉ vào thứ tự A, C, G và U mà còn vào cách chuỗi tạo cặp base, motif và cấu trúc ba chiều [2, 3, 4]. Cấu trúc bậc hai mô tả các cặp base và motif cục bộ, trong khi cấu trúc bậc ba xác định cách các motif tương tác và sắp xếp trong không gian [3, 4]. Do đó, một mô hình dự đoán RNA 3D hữu ích phải khôi phục được cả nếp gấp tổng thể lẫn quan hệ hình học cục bộ.

Tinh thể học tia X, cộng hưởng từ hạt nhân và kính hiển vi điện tử nghiệm lạnh là ba nhóm kỹ thuật chính để xác định cấu trúc RNA. Mỗi kỹ thuật có miền áp dụng và giới hạn riêng; chẳng hạn, cryo-EM đã mở rộng khả năng khảo sát các phức hợp RNA lớn nhưng việc chuẩn bị mẫu, thu dữ liệu và dựng mô hình vẫn đòi hỏi chuyên môn cùng tài nguyên đáng kể [1, 5]. Kho lưu trữ PDB cung cấp nền tảng dữ liệu cấu trúc thực nghiệm cho cộng đồng, song RNA vẫn ít đại diện hơn protein và nhiều họ RNA chưa có khuôn gán [6, 1]. Khoảng trống đó tạo động lực cho các phương pháp suy cấu trúc từ trình tự.

Các phương pháp tính toán RNA 3D thường kết hợp ba nguồn thông tin: nguyên lý vật lý, tri thức cấu trúc đã quan sát và mẫu học từ dữ liệu. Mô hình dựa trên khuôn có thể rất chính xác khi nhận ra một họ hàng cấu trúc phù hợp; ngược lại, mô hình học sâu có thể tạo một giả thuyết ngay cả khi truy hồi khuôn yếu [11, 16, 17, 18]. Các đánh giá mù RNA-Puzzles

và CASP cho thấy thứ hạng phương pháp thay đổi theo target, độ dài, mức độ mới của fold và nguồn thông tin được phép sử dụng [7, 9, 10]. Vì vậy, một candidate bank đa nguồn là lựa chọn tự nhiên khi metric giữ cấu trúc tốt nhất trong nhiều dự đoán.

Cuộc thi Stanford RNA 3D Folding tạo một bối cảnh đặc biệt phù hợp để khảo sát lựa chọn này. Hơn 1,700 đội tham gia dự đoán 43 cấu trúc chưa công bố, và hai hệ thống dẫn đầu đều khai thác TBM. Phân tích sau cuộc thi còn cho thấy một mô hình tích hợp TBM với học sâu có thể vượt các mô hình thành phần trên cùng tập kiểm tra [12]. Kết quả đó không làm mọi RNA trở thành bài toán có khuôn; thay vào đó, nó nhấn mạnh hai câu hỏi: làm thế nào truy hồi khuôn mà không nhìn tương lai, và làm thế nào bổ sung một nguồn de novo khi khuôn không đủ tốt.

## 1.2 Vấn đề nghiên cứu

Một pipeline TBM có thể nhận điểm cao giả tạo nếu thư viện chứa cấu trúc được phát hành sau ngày target cần được dự đoán. Đây là rò rỉ thời gian: thuật toán vẫn chỉ đọc dữ liệu công khai ở thời điểm chạy lại, nhưng dữ liệu đó chưa tồn tại trong bối cảnh đánh giá ban đầu. Các thử thách mùa RNA-Puzzles và CASP được thiết kế nhằm tách dự đoán khỏi cấu trúc chưa công bố; tính toàn vẹn của phép so sánh vì vậy phụ thuộc vào mốc dữ liệu [7, 9, 12]. Luận văn yêu cầu mọi template có ngày phát hành sớm hơn cutoff của target và loại PDB tham chiếu của chính target.

Ngay cả khi an toàn thời gian, retrieval bằng một công cụ duy nhất vẫn có thể bỏ lỡ template. MMseqs2 được thiết kế cho tìm kiếm trình tự có tốc độ và độ nhạy cao trên tập dữ liệu lớn [13]; tuy nhiên, RNA tương đồng về fold không nhất thiết biểu lộ một homolog đủ mạnh trong bước truy hồi nhanh. Luận văn vì thế kết hợp MMseqs2 với một đường tìm kiếm composite dựa trên căn chỉnh toàn cục, căn chỉnh cục bộ, thành phần trình tự và 3-mer. Mục tiêu của composite là tăng recall của candidate bank, không phải khẳng định một hàm điểm sinh học tối ưu.

TBM cũng không thể bảo đảm một ứng viên tốt cho mọi target. Để xử lý giới hạn này, DRfold2 được đưa vào như nguồn dự đoán độc lập thay vì thay thế nhánh khuôn. DRfold2 kế thừa hướng kết hợp end-to-end learning và thế năng hình học của DRfold, đồng thời được báo cáo là cải

thiện hiệu quả và độ chính xác của dự đoán RNA 3D [16, 18]. Cách bố trí ba TBM và hai DRfold2 giữ đủ ứng viên khuôn trong các trường hợp dễ, đồng thời dành hai vị trí cho fold mà mô hình học sâu có thể bổ sung.

Ứng viên từ cả hai nguồn vẫn có thể chứa khoảng cách backbone bất thường, va chạm hoặc biến dạng cục bộ. Các công cụ refinement trước đây cho thấy tối ưu hình học có thể tăng độ hợp lý hóa học nhưng không bảo đảm giảm RMSD so với native [20, 21]. Luận văn do đó đặt một mục tiêu hẹp cho geometry refinement: cải thiện quan hệ C1' cục bộ trong khi giữ thay đổi TM-score trong biên bảo toàn đã định trước. Cách phát biểu này tách rõ sửa hình học khỏi dự đoán lại global fold.

## 1.3 Câu hỏi nghiên cứu

Luận văn trả lời ba câu hỏi theo thứ tự từ nguồn ứng viên đến hậu xử lý:

- RQ1.** Tìm kiếm composite bổ sung gì cho MMseqs2 trong một pipeline TBM an toàn thời gian, và thành phần xếp hạng nào tạo ra thay đổi đo được?
- RQ2.** Khi số vị trí dự đoán được kiểm soát, DRfold2 có bổ sung các target mà TBM bỏ lỡ hay không?
- RQ3.** Geometry refinement có cải thiện độ chính xác cục bộ theo C1'-IDDT và sliding-window RMSD trong khi bảo toàn global TM-score hay không?

Ba câu hỏi tạo một mạch nhân quả có thể kiểm tra. RQ1 giải thích cách mở rộng candidate coverage, RQ2 kiểm tra lợi ích của diversity giữa hai nguồn, còn RQ3 xác định chính xác phần nào của cấu trúc được thay đổi sau refinement. Leaderboard chỉ đóng vai trò đánh giá external cho pipeline đã khóa và không thay thế ablation local.

## 1.4 Đóng góp

Đóng góp thứ nhất là một nhánh TBM có audit thời gian. Nhánh này hợp nhất truy hồi nhanh và tìm kiếm composite, kiểm tra ngày phát hành, căn

chỉnh lại các hit, xếp hạng theo identity và coverage, rồi chuyển tọa độ C1'. Mỗi quyết định được đánh giá bằng component ablation thay vì suy ra từ điểm cuối duy nhất.

Đóng góp thứ hai là bằng chứng định lượng cho tính bổ sung giữa TBM và DRfold2. Phân tích so sánh từng nguồn, union oracle và các bank có cùng số ứng viên. Thiết kế fixed-N tách một phần lợi ích thực sự của nguồn khỏi lợi ích cơ học do có nhiều slot hơn.

Đóng góp thứ ba là geometry refinement bảo thủ cùng protocol xác nhận độc lập. Prior được ước lượng trên 60 RNA, cấu hình được chọn trên 20 RNA hiệu chỉnh và được khóa trước khi mở 20 RNA xác nhận. Phương pháp được so sánh với raw candidate và một baseline đơn giản, đồng thời được mở bằng cumulative và leave-one-out ablation.

Đóng góp cuối cùng là một lập luận hai tầng về kết quả leaderboard. Điểm private 0.61390 cho thấy pipeline triển khai có giá trị external; complementarity và refinement studies giải thích cơ chế ở mức thành phần. Việc tách hai tầng bằng chứng tránh suy diễn rằng mọi mức tăng leaderboard đều do geometry refinement.

## 1.5 Phạm vi và cấu trúc luận văn

Luận văn dự đoán một tọa độ C1' cho mỗi nucleotide và xuất năm cấu trúc cho mỗi target. Phân tích confirmatory tập trung vào RNA đơn chuỗi dài tối đa 96 nucleotide; Kaggle cung cấp phép kiểm tra external trên một phân bố khác, gồm target dài hơn. Luận văn không mô hình hóa đầy đủ nguyên tử, ion, ligand, biến đổi hóa học hoặc tương tác RNA-protein. Những yếu tố này là thành phần quan trọng của cấu trúc RNA thực tế [4, 1], nhưng nằm ngoài phạm vi dữ liệu và biểu diễn được đánh giá ở đây.

Phần còn lại được tổ chức như sau. Chương 2 trình bày nền tảng và công trình liên quan. Chương 3 mô tả dữ liệu và kiểm soát leakage. Chương 4 trình bày pipeline. Chương 5 xây dựng protocol thí nghiệm. Chương 6 báo cáo kết quả theo ba câu hỏi nghiên cứu. Chương 7 giải thích cơ chế, giới hạn và quan hệ với cuộc thi. Chương 8 tổng kết và đề xuất hướng phát triển.

## Chương 2

# Nền tảng và công trình liên quan

### 2.1 Tổ chức cấu trúc RNA

RNA là một polymer có backbone đường-phosphate và bốn base chính. Tương tác Watson-Crick, base stacking, cặp base không chuẩn, ion và tiếp xúc bậc ba cùng góp phần ổn định cấu trúc [3, 4]. Do nhiều tương tác cách xa nhau trên trình tự lại gần nhau trong không gian, sai lệch ở một motif có thể thay đổi toàn bộ bố cục của phân tử. Điều này giải thích vì sao chất lượng local và global cần được đo bằng các metric khác nhau.

Luận văn sử dụng trace C1' làm biểu diễn thống nhất. Với chuỗi dài  $L$ , một ứng viên được viết thành ma trận

$$X = [\mathbf{x}_1, \dots, \mathbf{x}_L]^T \in \mathbb{R}^{L \times 3}, \quad (2.1)$$

trong đó  $\mathbf{x}_i$  là tọa độ C1' của nucleotide  $i$ . Biểu diễn coarse-grained này phù hợp trực tiếp với định dạng dự đoán của cuộc thi [12, 27]. Nó không thể hiện hướng base hoặc hóa học đầy đủ, vì vậy mọi kết luận của luận văn được giới hạn ở chất lượng fold và trace C1'.

Một phép quay hoặc tịnh tiến toàn phân tử không làm thay đổi cấu trúc nội tại. Khi cần so sánh theo correspondence đã biết, phép chồng Kabsch tìm rigid transformation làm nhỏ nhất tổng bình phương sai lệch giữa hai tập điểm [25]. Các metric như lDDT không cần superposition, trong khi TM-score tìm alignment cấu trúc và chuẩn hóa theo độ dài để



giảm độ nhạy với kích thước phân tử [22, 24, 23].

## 2.2 Mô hình hóa dựa trên khuôn mẫu

TBM dựa trên giả thuyết rằng một cấu trúc đã biết có thể cung cấp scaffold cho chuỗi mục tiêu có liên hệ. Quy trình điển hình gồm truy hồi template, căn chỉnh query-template, chuyển tọa độ tương ứng, xây phần thiếu và tinh chỉnh mô hình [11, 12]. Chất lượng phụ thuộc vào việc nhận ra template phù hợp và căn đúng residue. Một hit có identity cao nhưng chỉ phủ đoạn ngắn có thể kém hữu ích hơn hit yếu hơn nhưng phủ gần toàn chuỗi.

Needleman-Wunsch giải bài toán căn chỉnh toàn cục bằng quy hoạch động, còn Smith-Waterman tìm căn chỉnh cục bộ tốt nhất [14, 15]. Hai dạng căn chỉnh phục vụ tín hiệu khác nhau: global alignment đo sự tương đồng trên toàn chuỗi, trong khi local alignment nhận ra motif hoặc miền bảo tồn. Composite search của luận văn sử dụng cả hai cùng các đặc trưng thành phần và 3-mer để mở rộng tập hit.

MMseqs2 cung cấp truy hồi nhạy và nhanh trên cơ sở dữ liệu trình tự quy mô lớn [13]. Tuy nhiên, một pipeline nghiên cứu không nên đồng nhất tốc độ retrieval với độ phủ cấu trúc. Vì vậy, luận văn đo riêng availability, conditional TM khi có hit và mean trên toàn target. Cách tách này ngăn 12 target không có hit bị biến mất khỏi trung bình của cohort.

## 2.3 Dự đoán bằng học sâu

Các mô hình học sâu gần đây học biểu diễn trình tự, phân bố khoảng cách hoặc tọa độ để dự đoán RNA 3D. ARES sử dụng geometric deep learning để chấm điểm cấu trúc; DRfold kết hợp end-to-end learning với deep geometrical potentials; RhoFold+ sử dụng RNA language model; và DRfold2 phát triển một pipeline dự đoán hiệu quả hơn [19, 16, 17, 18]. Các phương pháp này giảm phụ thuộc trực tiếp vào một template gần, nhưng độ chính xác vẫn thay đổi theo target và benchmark [10, 18].

Trong luận văn, DRfold2 không được mô tả là đối thủ thay thế TBM. Hai nguồn có failure mode khác nhau: TBM phụ thuộc vào retrieval và

alignment, còn mô hình học sâu phụ thuộc vào phân bố huấn luyện cùng tín hiệu tiến hóa. Candidate bank giữ cả hai nguồn để tận dụng khác biệt đó. Lợi ích được kiểm tra trên target held-out thay vì suy ra từ mô tả kiến trúc.

## 2.4 Tinh chỉnh cấu trúc

Refinement tìm một cấu trúc lân cận thỏa các ràng buộc hình học hoặc năng lượng tốt hơn. QRNAS tối ưu cấu trúc acid nucleic bằng một hàm năng lượng mở rộng, trong khi Arena dựng mô hình full-atom từ biểu diễn coarse-grained [20, 21]. Các công trình này cho thấy hợp lý hóa hình học và tiến gần native là hai mục tiêu liên quan nhưng không đồng nhất. Một mô hình có bond hoặc clash tốt hơn vẫn có thể giữ nguyên, thậm chí giảm, độ đúng global.

Geometry refinement trong luận văn được thiết kế theo nhận xét trên. Source restraint giữ ứng viên gần cấu trúc ban đầu; prior khoảng cách, góc và góc xoắn điều chỉnh trace; clash, kink và bán kính quán tính kiểm soát các failure mode cụ thể. Hiệu quả không được đánh giá bằng chính loss tối ưu mà chủ yếu bằng TM-score, C1'-IDDT và sliding-window RMSD, là các đại lượng độc lập hơn với mục tiêu huấn luyện [22, 24, 23].

## 2.5 Đánh giá cấu trúc

TM-score ban đầu được phát triển cho protein và chuẩn hóa sai lệch cấu trúc theo độ dài [22]. US-align mở rộng căn chỉnh cấu trúc cho nucleic acid và phức hợp macromolecule [23]. Theo protocol cuộc thi, mỗi target được chấm bằng điểm tốt nhất qua năm model và các native conformation khả dụng, sau đó lấy trung bình qua target [12]. Trong luận văn, “best-of-five” luôn chỉ oracle evaluation; quy trình inference không dùng native để chọn candidate.

IDDT đo mức bảo toàn các khoảng cách cục bộ mà không cần chống khít toàn cấu trúc [24]. Luận văn tính biến thể trên atom C1', do đó gọi là C1'-IDDT. Sliding-window RMSD trước hết chống từng cửa sổ liên tiếp bằng Kabsch, sau đó lấy sai lệch tọa độ; cửa sổ 9 và 15 nhạy với biến dạng

cục bộ hơn của số 31 hoặc RMSD toàn cấu trúc [25]. Bộ metric kết hợp cho phép phân biệt sửa local trace với thay đổi global fold.

## 2.6 Khoảng trống nghiên cứu

Các benchmark đã so sánh nhiều phương pháp RNA 3D, còn paper cuộc thi đã cho thấy TBM vẫn cạnh tranh mạnh khi kho cấu trúc tăng trưởng [10, 12]. Tuy nhiên, một điểm leaderboard không giải thích thành phần nào tạo hiệu quả, và một ablation trên dữ liệu không kiểm soát thời gian có thể ưu ái template search. Khoảng trống thứ nhất vì vậy là phân tích white-box một pipeline TBM dưới cutoff thực tế.

Khoảng trống thứ hai là bằng chứng có kiểm soát về source complementarity. Nếu chỉ so union năm cấu trúc với một bank ba cấu trúc, mức tăng có thể đến từ hai slot bổ sung. Luận văn báo cáo cả union và fixed-N để tách hai cơ chế. Khoảng trống cuối cùng là kiểm chứng geometry refinement bằng held-out validation, baseline đơn giản, ablation và metric độc lập. Ba khoảng trống tương ứng trực tiếp với RQ1, RQ2 và RQ3.

## Chương 3

# Dữ liệu và kiểm soát đánh giá

### 3.1 Các nguồn dữ liệu

Thư viện template được xây từ các cấu trúc PDB công khai. PDB là kho lưu trữ toàn cầu cho dữ liệu cấu trúc macromolecule và cung cấp metadata cần thiết để truy nguyên chain, sequence cùng ngày phát hành [6]. Sau khi chuẩn hóa, snapshot của dự án gồm 8,670 tệp cấu trúc, 23,869 chain RNA hoặc RNA-DNA và khoảng 10.86 triệu residue. Tỷ lệ residue có tọa độ C1' là 99.9%. MMseqs2 index chứa khoảng 20,844 chain hợp lệ, còn thư viện composite sau khử trùng lặp chứa 7,155 sequence duy nhất. Những con số này mô tả artifact đã khóa của dự án, không phải kích thước hiện tại của PDB.

CASP15 cung cấp 12 target dài 30-720 nucleotide và được dùng cho phát triển ban đầu. CASP là một đánh giá mù, trong đó cấu trúc target chưa công bố tại thời điểm dự đoán; bộ RNA của CASP15 đã được phân tích độc lập trong báo cáo đánh giá chính thức [9]. Vì cohort nhỏ và gồm nhiều target khó, luận văn dùng nó để phát triển, minh họa leakage và kiểm tra triển khai, chứ không dùng làm bằng chứng confirmatory duy nhất.

Phân tích chính sử dụng 100 RNA có ngày phát hành từ tháng 1 năm 2024 đến tháng 3 năm 2025. Mỗi RNA có năm candidate được sinh blind gồm ba TBM và hai DRfold2. Dữ liệu được chia theo thời gian thành 60 train, 20 calibration và 20 validation như Bảng 3.1. Audit xác nhận không có sequence group hoặc family group nào đi qua hai split. Việc vừa tách theo thời gian vừa tách họ làm giảm khả năng một motif gần xuất hiện ở


cả bước chọn cấu hình và bước xác nhận.

Bảng 3.1: Phân chia dữ liệu cho geometry refinement và complementarity study.

| Split       | Số RNA | Khoảng ngày phát hành     | Vai trò                  |
|-------------|--------|---------------------------|--------------------------|
| Train       | 60     | 2024-01-10 đến 2024-12-04 | Ước lượng prior hình học |
| Calibration | 20     | 2024-12-11 đến 2025-01-08 | Chọn và khóa cấu hình    |
| Validation  | 20     | 2025-01-15 đến 2025-03-26 | Xác nhận một lần         |

Mẫu chính trong Bảng 3.1 là sự tách vai trò: train chỉ tạo thống kê, calibration quyết định hyperparameter và validation chỉ đo kết quả. Không có kết quả validation nào được dùng để sửa cấu hình sau khi mở. Cách bố trí này không loại bỏ mọi dataset bias, nhưng nó ngăn một chu trình phổ biến trong đó cùng target vừa chọn method vừa chứng minh method.

Kaggle cung cấp lớp đánh giá external với sequence và native structure ẩn trong lúc notebook chạy. Theo paper tổng kết, cuộc thi yêu cầu năm dự đoán trên mỗi target và dùng US-align trên atom C1' để tính điểm tốt nhất [12, 27]. Luận văn lưu public score, private score, manifest thực thi và hash của CSV cuối. Vì native hidden không được công bố, Kaggle chỉ cho một số tổng hợp và không hỗ trợ ablation theo target.



Hình 3.1: Protocol bằng chứng hai tầng. Ba split local tách theo thời gian và họ; Kaggle đóng vai trò external check ở mức toàn pipeline.

Hình 3.1 làm rõ thứ tự sử dụng dữ liệu. Các mũi tên thời gian chỉ đi từ train sang calibration rồi validation; external leaderboard không quay ngược vào quá trình chọn cấu hình. Đây là điều kiện quan trọng để diễn giải kết quả private như kiểm tra ngoài mẫu thay vì một hyperparameter search khác.


## 3.2 Cutoff thời gian và loại self-template

Với target  $q$  có cutoff  $t_q$ , template  $s$  chỉ hợp lệ khi

$$\text{release}(s) < t_q \quad \text{và} \quad \text{PDB}(s) \notin \mathcal{E}_q, \quad (3.1)$$

trong đó  $\mathcal{E}_q$  là tập PDB cần loại cho chính target. Bất đẳng thức nghiêm ngặt tránh template phát hành đúng ngày cutoff đi qua do khác biệt múi giờ hoặc thứ tự cập nhật. Nếu thiếu cutoff hay release date, một triển khai an toàn nên fail closed thay vì coi template là hợp lệ.

Ảnh hưởng của leakage được minh họa trong Hình 3.2. Trên pipeline CASP15 ban đầu, mean best-of-five TM tăng từ 0.1612 với temporal filter lên 0.6388 khi bỏ filter và 0.9566 trong oracle leak. Các biến thể không an toàn không phải phương pháp cạnh tranh; chúng chỉ định lượng mức lạc quan có thể xuất hiện nếu data snapshot không khớp thời điểm đánh giá. Nguyên tắc benchmark mù của CASP và RNA-Puzzles cung cấp cơ sở cho audit này [7, 9].



Hình 3.2: Minh họa mức tăng điểm do rò rỉ template trên cohort CASP15 phát triển. Hai cột không an toàn chỉ là diagnostic và không tham gia kết quả phương pháp.

### 3.3 Quy tắc sử dụng nhãn

Native label chỉ được đọc trong các script đánh giá local sau khi candidate đã sinh. Trong complementarity study, “oracle” nghĩa là phép lấy maximum dùng để đo trần có sẵn của candidate bank; oracle không chọn cấu trúc trong pipeline inference. Geometry refinement chỉ nhận tọa độ nguồn, confidence và prior từ train. Đối với mỗi candidate, native conformation dùng khi tính local metric được cố định từ candidate raw để refinement không hưởng lợi bằng cách đổi sang conformation tham chiếu dễ hơn.

Artifact Kaggle cuối không chứa validation label, hidden test label hay submission dựng sẵn. Manifest ghi nhận `native_labels_used: false`; output có đúng 2,515 dòng, 18 cột, ID đúng thứ tự và tọa độ hữu hạn. SHA-256 của tệp cuối là

54fe6e6598a1c2924ef7cbf03482f7ecf3c2e52e8726a1609569f777b1ac8c9a

Các kiểm tra này chứng minh tính toàn vẹn của artifact triển khai, trong khi điều kiện ở Phương trình 3.1 kiểm soát tính hợp lệ của template.

### 3.4 Đơn vị phân tích và thống kê

Target RNA là đơn vị độc lập trong mọi khoảng tin cậy. Năm candidate của cùng target có chung sequence, native và quá trình sinh, do đó không được xem như năm quan sát độc lập. Với effect  $d_i$  trên  $n$  target, luận văn báo cáo

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i \quad (3.2)$$

và khoảng tin cậy percentile từ 10,000 bootstrap sample lấy lại target có hoàn lại. Bootstrap là phương pháp ước lượng độ bất định bằng re-sampling từ mẫu quan sát [26]. Seed được cố định ở 2025 để tái lập kết quả.

Một effect luôn được định hướng để giá trị dương nghĩa là tốt hơn. Với TM-score và lDDT,  $d_i = m_i^{\text{new}} - m_i^{\text{base}}$ ; với RMSD, clash hoặc deviation,  $d_i = m_i^{\text{base}} - m_i^{\text{new}}$ . Quy ước này giúp các bảng có chung cách đọc nhưng caption phải nêu rõ đơn vị. Luận văn báo cáo mean, median, khoảng tin

cậy và số target improve/tie/regress để tránh một trung bình che khuất failure case.




# Chương 4

## Pipeline đề xuất

### 4.1 Tổng quan

Pipeline nhận một RNA sequence và cutoff thời gian, sau đó sinh hai candidate bank độc lập. Nhánh TBM trả tối đa ba cấu trúc đã xếp hạng; DRfold2 trả hai cấu trúc theo confidence nội bộ. Nếu DRfold2 vượt giới hạn tài nguyên, vị trí còn thiếu được lấp bằng TBM. Geometry refinement xử lý riêng từng candidate trong 300 bước và writer xuất đúng năm trace C1'. Hình 4.1 tóm tắt luồng dữ liệu.



Hình 4.1: Pipeline cuối. Đa dạng nguồn được tạo trước refinement; không có lựa chọn hay hợp nhất tạo độ dựa trên native label.

Thiết kế có hai nguyên tắc. Thứ nhất, diversity được tạo ở cấp nguồn bằng cách giữ ba TBM và hai DRfold2, phù hợp với best-of-five evaluation. Thứ hai, refinement bị ràng buộc gần source để tránh phá một fold vốn

đã tốt. Hai nguyên tắc giải quyết hai failure mode khác nhau và được đánh giá riêng ở Chương 6.

## 4.2 Nhánh TBM an toàn thời gian


### 4.2.1 Truy hồi hai đường

Nhánh thứ nhất chạy MMseqs2 trên index sequence của template library. MMseqs2 dùng các bộ lọc tăng tốc và căn chỉnh nhạy để xử lý cơ sở dữ liệu lớn [13]. Raw hit được chuẩn hóa về chain key, identity, alignment coverage và release date. Hit thiếu tọa độ C1' hoặc vi phạm gate thời gian bị loại trước bước xếp hạng.

Nhánh thứ hai quét thư viện sequence đã khử trùng lặp bằng điểm composite

$$S_{\text{comp}}(q, s) = 0.4G(q, s) + 0.3L(q, s) + 0.2F(q, s) + 0.1K_3(q, s), \quad (4.1)$$

trong đó  $G$  là global-alignment similarity,  $L$  là local-alignment similarity,  $F$  là tương đồng đặc trưng thành phần và  $K_3$  là overlap 3-mer. Global và local alignment dựa trên hai quy hoạch động cổ điển [14, 15]. Các trọng số trong Phương trình 4.1 là heuristic frozen; ablation kiểm tra độ nhạy thay vì gán cho chúng ý nghĩa xác suất.



Hình 4.2: Luồng TBM. MMseqs2 ưu tiên homolog rõ, composite mở rộng recall, còn safety gate được áp dụng trước khi căn chỉnh lại và chuyển tọa độ.

Hai danh sách được hợp nhất theo chain key trước khi lọc thời gian và self-PDB. Mẫu thiết kế trong Hình 4.2 giữ vai trò của hai search branch tách biệt: MMseqs2 không bị mô tả là kém khi nó không trả hit, còn composite không được coi là chính xác chỉ vì nó luôn trả candidate. Availability và conditional quality được báo cáo riêng.

### 4.2.2 Căn chỉnh lại và xếp hạng

Mỗi hit hợp lệ được căn chỉnh toàn cục lại với query để tạo một hệ correspondence duy nhất cho transfer. Gọi identity trên cột khớp là  $I$ , tỷ lệ query có tọa độ được hỗ trợ là  $C_q$  và completeness của template là  $C_s$ . Rank score được viết

$$S_{\text{rank}} = I C_q C_s. \quad (4.2)$$

Trong pipeline cuối, identity nhân coverage tạo thứ tự chính; completeness dùng để xử lý trường hợp tọa độ thiếu. Ba candidate đầu được ưu tiên từ PDB khác nhau khi có thể, nhưng ablation kiểm tra riêng xem luật diversity này có tăng oracle TM trên cohort hay không.

Điểm rank không phải confidence đã hiệu chỉnh. Nó là tín hiệu nội bộ để sắp thứ tự candidate mà không nhìn native. Điểm này đặc biệt hữu ích khi một local hit có identity cao nhưng chỉ phủ đoạn ngắn: nhân  $C_q$  giảm khả năng hit đó chiếm vị trí đầu. Tác động thực nghiệm của

coverage được báo cáo ở Bảng 6.2.

### 4.2.3 Chuyển tọa độ và lấp khoảng trống

Với mỗi cặp residue đã căn chỉnh, tọa độ C1' của template được chép sang vị trí query. Residue không được hỗ trợ được đánh dấu confidence thấp. Gap giữa hai anchor được nội suy trên một đường cong xác định bởi hướng biên; terminal gap được ngoại suy từ các bước backbone gần nhất. Nếu không có đủ anchor, pipeline dùng một trace de novo xác định để bảo đảm output hữu hạn.

Curved gap filling chỉ nhằm tạo một candidate hợp lệ trước refinement. Nó không mang thông tin native và không thể khôi phục một motif mới chỉ từ hai anchor. Vì vậy, thí nghiệm chia gap theo độ dài và đo SW-RMSD9 tại residue không được hỗ trợ. Kết quả chỉ cho thấy cải thiện rõ ở gap 9-20 nucleotide; các nhóm còn lại được báo cáo như kết quả trung tính thay vì suy rộng.

## 4.3 Nhánh DRfold2

DRfold2 nhận sequence và sinh cấu trúc bằng một mô hình học sâu đã huấn luyện. Công trình gốc mô tả một pipeline dự đoán RNA 3D hiệu quả và chính xác, phát triển từ DRfold [16, 18]. Luận văn giữ nguyên pretrained inference path và không fine-tune bằng 100 RNA local. Hai model có confidence cao nhất được chuyển sang biểu diễn  $L \times 3$  trên atom C1'.

Các candidate DRfold2 được sinh độc lập với template hit. Độc lập ở đây nghĩa là nhánh lựa chọn cuối không dùng native hoặc điểm TBM để uốn tọa độ DRfold2; nó không hàm ý tập huấn luyện của pretrained model không có quan hệ với PDB. Audit mốc huấn luyện vì vậy được ghi như một nguy cơ external validity, còn split theo họ bảo vệ thí nghiệm local khỏi trùng lặp rõ ràng trong cohort dự án.

Giới hạn triển khai frozen là 600 nucleotide. Trong public execution, DRfold2 chạy cho 11/12 target và bỏ qua target 720 nucleotide; target đó giữ năm TBM. Luật fallback được xác định trước khi chạy hidden set, nhờ đó output luôn có năm candidate mà không thay đổi theo score.


## 4.4 Geometry refinement

### 4.4.1 Mục tiêu thiết kế

Cho candidate nguồn  $X^{(0)}$ , refinement tìm  $X$  giảm một hàm mục tiêu hình học nhưng không rời xa fold ban đầu. Mục tiêu tổng quát là

$$\mathcal{L}(X) = \lambda_s \mathcal{L}_{\text{source}} + \lambda_b \mathcal{L}_{\text{backbone}} + \lambda_a \mathcal{L}_{\text{angle}} + \lambda_t \mathcal{L}_{\text{torsion}} + \lambda_c \mathcal{L}_{\text{clash}} + \lambda_k \mathcal{L}_{\text{kink}} + \lambda_r \mathcal{L}_{R_g}. \quad (4.3)$$

Mỗi hạng xử lý một failure mode, còn source term giới hạn drift. Hình 4.3 minh họa cơ chế; đường vẽ mang tính khái niệm và không phải một target thực nghiệm.



Hình 4.3: Cơ chế geometry refinement. Một biến dạng cục bộ được làm trơn trong khi source restraint bảo toàn bố cục tổng thể; các prior còn lại xử lý backbone, angle, torsion, clash, kink và bán kính quán tính.

### 4.4.2 Prior hình học

Khoảng cách kề nhau được ký hiệu  $d_i = \|\mathbf{x}_{i+1} - \mathbf{x}_i\|_2$ . Trên 60 RNA train, phân bố này có mean 6.09 Å, standard deviation 1.11 Å và median 5.66 Å. Ngưỡng clash C1' không kề nhau được đặt ở 4.18 Å. Bán kính quán tính được mô hình bằng quan hệ power law

$$\hat{R}_g(L) = 5.18L^{0.346}. \quad (4.4)$$

Các thống kê là prior của snapshot dự án, không phải hằng số vật lý phổ quát. Chúng được ước lượng chỉ trên train và giữ cố định cho calibration

cùng validation.

Backbone term sử dụng negative log-likelihood theo bin của  $d_i$  và context cục bộ. Angle term áp dụng cho bộ ba C1' liên tiếp, torsion term cho bộ bốn liên tiếp. Kink term phạt góc gấp quá sắc, clash term phạt các cặp không kề nhau gần hơn ngưỡng, còn  $R_g$  term hạn chế collapse hoặc giãn quá mức. Các phân bố theo context cho phép trace uốn tự nhiên hơn một target distance duy nhất.

Source restraint được điều chỉnh theo confidence:

$$\mathcal{L}_{\text{source}} = \frac{1}{L} \sum_{i=1}^L w_i \|\mathbf{x}_i - \mathbf{x}_i^{(0)}\|_2^2, \quad (4.5)$$

trong đó  $w_i$  lớn hơn ở residue được template hỗ trợ hoặc có model confidence cao. Thiết kế này cho phép gap và vùng yếu di chuyển nhiều hơn phần scaffold đáng tin. Toàn bộ candidate được tối ưu 300 bước Adam với cấu hình source\_lp5 đã khóa trên calibration.

### 4.4.3 Baseline và output

Baseline đơn giản chỉ giữ source restraint và backbone smoothing. So sánh này trả lời một câu hỏi thực tế: các term phức tạp có tạo lợi ích vượt một phép làm trơn bảo thủ hay không? Full method phải được so với cả raw và baseline; thắng raw đơn thuần không đủ để chứng minh mọi term cần thiết.

Sau refinement, mỗi candidate được kiểm tra shape  $L \times 3$ , finite coordinates và thứ tự residue. Writer ghép năm candidate thành các cột  $x_1, y_1, z_1$  đến  $x_5, y_5, z_5$ , giữ đúng sample ID. Không có bước chọn source theo native, không có coordinate fusion và không có mô hình router trong pipeline cuối.

## 4.5 Mã giả

1. Nhận sequence  $q$ , cutoff  $t_q$  và danh sách PDB cần loại.
2. Truy hồi bằng MMseqs2 và composite; hợp nhất hit theo chain key.
3. Loại hit không thỏa Phương trình 3.1.

4. Căn chỉnh lại, tính rank score và tạo ba ứng viên TBM.
5. Chạy DRfold2 nếu  $L \leq 600$  và giữ hai ứng viên theo model confidence.
6. Nếu thiếu DRfold2, lấp slot bằng TBM; luôn tạo đúng năm candidate.
7. Chạy geometry refinement độc lập trên từng candidate trong 300 bước.
8. Kiểm tra ID, kích thước, thứ tự, uniqueness và finite coordinates; sau đó ghi CSV.

Mã giả cho thấy native label không nằm trên inference path. Tất cả quyết định trước khi ghi output dựa trên sequence, template metadata, pretrained confidence và prior aggregate. Điều này tách selection blind khỏi oracle score chỉ được tính trong bước đánh giá.

# Chương 5

## Thiết kế thí nghiệm

### 5.1 Chiến lược kiểm định

Mỗi RQ được gán với một nhóm thí nghiệm và một claim tối đa. RQ1 dùng 20 RNA calibration để mở search source, composite score, reranking và gap fill. RQ2 dùng 20 RNA validation để so candidate bank trước refinement. RQ3 dùng protocol 60/20/20, trong đó validation chỉ được mở sau khi khóa cấu hình. Phân tách này ngăn kết quả khám phá TBM trở thành bằng chứng xác nhận cho geometry refinement.

Bảng 5.1: Ánh xạ câu hỏi nghiên cứu sang thí nghiệm và claim.

| RQ  | So sánh chính                                                      | Claim được phép                                                                  |
|-----|--------------------------------------------------------------------|----------------------------------------------------------------------------------|
| RQ1 | MMseqs2, composite, union; component và reranking ablation         | Composite mở rộng availability; hiệu quả ranking được định lượng theo thành phần |
| RQ2 | 3T, 2D, union; fixed-N allocation                                  | TBM và DRfold2 bổ sung nhau theo target                                          |
| RQ3 | Raw, source+backbone, full refinement; cumulative và leave-one-out | Refinement cải thiện local trace trong biên bảo toàn TM                          |

Bảng 5.1 giới hạn mức diễn giải trước khi nhìn kết quả. Đặc biệt, RQ3 không đặt giả thuyết tăng TM-score. Hệ thống có thể đạt validation gate nếu local metric cải thiện và mean TM change nằm trong biên  $\pm 0.005$ . Biên được khóa trên calibration để tránh thay đổi tiêu chí sau khi mở validation.



## 5.2 Ablation TBM

Search-source study so sánh ba cấu hình: MMseqs2-only, composite-only và union. Với MMseqs2, TM chỉ được tính có điều kiện trên target có hit, đồng thời availability được báo riêng. Với composite và union, mean tính trên đủ 20 target. Cách báo cáo này tránh so sánh 8 target dễ với 20 target đầy đủ như thể hai mẫu giống nhau.

Composite component study so sánh  $G$ ,  $G + L$ ,  $G + L + F$ , tổ hợp bốn thành phần trọng số bằng nhau, full weighted và các biến thể đổi từng trọng số  $\pm 25\%$ . Tập hit chung được dùng để tính useful recall ở ngưỡng TM 0.45; đại lượng này là diagnostic nội bộ, không phải metric chính thức. Temporal-unsafe variant chỉ lượng hóa leakage.

Reranking study bắt đầu từ identity-only rồi lần lượt thêm query coverage, template completeness và distinct-PDB selection. Gap study so linear với curved interpolation ở bốn nhóm độ dài 1-3, 4-8, 9-20 và trên 20 nucleotide. Mỗi gap được đo tại residue không có template support; các gap trong cùng target được trung bình trước target bootstrap.

## 5.3 Thí nghiệm tính bổ sung

Candidate source được đánh giá trước geometry refinement để không trộn hai factor. Với target  $i$ , đặt  $T_i$  là ba TBM score và  $D_i$  là hai DRfold2 score. Ba oracle statistic là

$$O_T(i) = \max T_i, \quad O_D(i) = \max D_i, \quad O_U(i) = \max(T_i \cup D_i). \quad (5.1)$$

Union gain  $O_U - O_T$  đo giá trị tối đa sẵn có khi thêm hai candidate DRfold2. Vì  $|T_i \cup D_i| > |T_i|$ , phép đo này bao gồm cả source diversity và candidate-count effect.

Để kiểm soát số slot, fixed-N=2 so  $2T$  với  $1T + 1D$ , còn fixed-N=3 so  $3T$  với  $2T + 1D$ . Candidate trong mỗi nguồn được chọn bằng thứ tự confidence blind. Cache chỉ có ba TBM và hai DRfold2 cho mỗi RNA, nên không thể dựng một sweep đủ từ  $5T$  đến  $5D$  mà không nhân bản candidate. Luận văn báo giới hạn này thay vì tạo một allocation giả.

## 5.4 Thí nghiệm geometry refinement

Train split chỉ ước lượng prior. Trên calibration, cumulative ablation thêm lần lượt source, backbone, angle, torsion, clash, kink và  $R_g$ ; leave-one-out bỏ từng term khỏi full objective. Cấu hình source\_1p5 được chọn vì đạt local gain trong khi thỏa TM preservation gate, sau đó được serialize trước validation.

Validation so ba setting: raw, simple source+backbone và full refinement. Primary local metrics là C1'-IDDT, SW-RMSD9 và SW-RMSD15. Global safeguard là best-of-five TM-score; C1 RMSD toàn cấu trúc và SW-RMSD31 là secondary. Backbone deviation, clash, sharp kink, angle-NLL, torsion-NLL và  $R_g$  error chỉ là mechanism diagnostics vì chúng nằm trong hoặc gần objective.

Factorial fixed- $N=3$  tạo bốn cell:  $3T$  raw,  $3T$  refined,  $2T + 1D$  raw và  $2T + 1D$  refined. Main effects ước lượng source-bank gain khi refinement off và geometry effect trong từng bank. Interaction kiểm tra refinement có hoạt động khác theo source composition hay không. Thiết kế này trực tiếp kiểm tra liệu geometry refinement có thể giải thích mức tăng TM của pipeline hybrid.

## 5.5 External evaluation và khả năng tái lập

Hai submission frozen được so sánh: time-safe composite TBM và pipeline cuối. Submission TBM chạy search, rank, transfer, gap fill và refinement của baseline hiện có; submission hybrid thay hai slot bằng DRfold2 khi khả thi rồi áp dụng cấu hình geometry refinement đã khóa. Public và private score được đọc từ Kaggle, còn integrity được kiểm tra từ manifest và output hash [27].

Mọi bảng local được tạo bởi script trong repository. Random seed của bootstrap là 2025; cấu hình, prior provenance và candidate cache được lưu cùng artifact. Các phép kiểm tra bao gồm một target mỗi dòng trong metadata, không có group crossing split, đúng ba TBM và hai DRfold2 mỗi target, tọa độ hữu hạn và không thay đổi native conformation giữa raw với refined evaluation. Danh sách tệp tái lập được ghi ở Phụ lục A.

# Chương 6

## Kết quả

### 6.1 RQ1: Truy hồi và xếp hạng TBM

#### 6.1.1 Hai nguồn truy hồi

MMseqs2 tìm được template cho 8/20 RNA calibration, tương ứng availability 40%. Trên riêng tám target có hit, top-1 TM là 0.660029 và best-of-five TM là 0.678316. Composite search tạo candidate cho 20/20 target nhưng best-of-five mean chỉ 0.376060. Union giữ availability 100% và tăng mean lên 0.389705. Bảng 6.1 trình bày đầy đủ ba đại lượng.

Bảng 6.1: Ảnh hưởng của nguồn truy hồi trên 20 RNA calibration. Điểm MMseqs2 là conditional trên tám target có hit.

| Nguồn               | Target có hit | Availability | Best-of-five TM khi có hit |
|---------------------|---------------|--------------|----------------------------|
| MMseqs2-only        | 8/20          | 0.40         | 0.678316                   |
| Composite-only      | 20/20         | 1.00         | 0.376060                   |
| MMseqs2 + composite | 20/20         | 1.00         | 0.389705                   |

Kết quả cho thấy hai search branch có vai trò khác nhau. Khi MMseqs2 nhận ra homolog, candidate thường mạnh; composite lấp 12 target còn thiếu nhưng precision trung bình thấp hơn. Union tăng 0.013645 so với composite-only, song khoảng tin cậy  $[-0.004417, 0.042781]$  chứa 0 vì chỉ hai target thay đổi theo chiều tốt. Do đó, lợi ích được hỗ trợ rõ nhất là availability, không phải superiority trung bình của mọi composite hit.

### 6.1.2 Thành phần composite

Full weighted đạt best-of-five TM 0.376060, trong khi G-only đạt 0.381177. Chênh lệch theo chiều G-only tốt hơn là 0.005117 với khoảng tin cậy  $[-0.002178, 0.015004]$ . Các biến thể đổi trọng số  $\pm 25\%$  nằm trong khoảng 0.375436-0.376500. Như vậy, công thức composite ổn định trước nhiễu nhỏ nhưng không có bằng chứng rằng bốn thành phần vượt global alignment trên cohort này.

Tuy vậy,  $G + L + F$  có useful recall 0.676304 so với 0.635488 của G-only trong tập hit chung. Mẫu này phù hợp với vai trò recall heuristic: tín hiệu bổ sung có thể đưa candidate mới vào top five dù mean oracle chưa tăng rõ. Vì useful recall dùng threshold nội bộ, luận văn không dùng nó thay thế TM-score.

Bỏ temporal filter làm mean tăng từ 0.376060 lên 0.403022, chênh 0.026962. Khoảng tin cậy  $[-0.000343, 0.071258]$  còn rộng và 15/20 target không đổi. Kết quả không chứng minh unsafe search tốt hơn; nó cho thấy chỉ một vài leaked template cũng đủ dịch chuyển mean và vì vậy time filter là yêu cầu về tính hợp lệ.

### 6.1.3 Reranking và gap fill

Thêm query coverage vào identity tăng top-five TM từ 0.371900 lên 0.387558, tương ứng  $+0.015659$  với khoảng tin cậy  $[-0.003731, 0.045178]$ . Thêm completeness không đổi điểm trên cohort này; distinct-PDB selection cũng giữ nguyên oracle TM dù số PDB riêng trung bình tăng từ 4.95 lên 5.00. Bảng 6.2 cho thấy dominant pattern là coverage, còn hai rule sau chủ yếu bảo vệ robustness và diversity.

Bảng 6.2: Ablation xếp hạng TBM.


| Xếp hạng                   | Top-1 TM | Top-3 TM | Top-5 TM |
|----------------------------|----------|----------|----------|
| Identity only              | 0.334450 | 0.363854 | 0.371900 |
| Identity $\times$ coverage | 0.363720 | 0.378412 | 0.387558 |
| + template completeness    | 0.363720 | 0.378412 | 0.387558 |
| + distinct PDB             | 0.363720 | 0.378412 | 0.387558 |

Curved gap filling chỉ cải thiện rõ ở gap dài 9-20 nucleotide. SW-

RMSD9 giảm trung bình 0.036778 Å với khoảng tin cậy [0.009289, 0.067605]. Gap 1-3 và 4-8 không có bằng chứng khác linear interpolation, còn gap trên 20 không đổi trong triển khai hiện tại. Cơ chế hợp lý là đường cong có đủ chiều dài để tránh đoạn nối thẳng, nhưng hai anchor vẫn không đủ thông tin cho gap rất dài.

## 6.2 RQ2: TBM và DRfold2 bổ sung nhau

Trước refinement, ba TBM đạt mean oracle 0.565183 và hai DRfold2 đạt 0.502627. Union năm candidate đạt 0.588304, cao hơn TBM 0.023121 với khoảng tin cậy [0.006444, 0.047519]. DRfold2 cung cấp candidate tốt nhất ở 8/20 target, còn TBM thắng ở 12/20. Hình 6.1 cho thấy cả mức điểm và winner count.



Hình 6.1: Tính bổ sung của candidate bank trên 20 RNA validation. Union gain được tính so với ba TBM và khoảng tin cậy bootstrap theo target.

Kết quả chính không phải DRfold2 có mean cao hơn TBM; thực tế mean của nhánh học sâu thấp hơn 0.062556. Giá trị nằm ở tám target mà thứ tự nguồn đảo chiều. Vì oracle union không thể giảm khi thêm candidate, fixed-N là đối chứng cần thiết để xác định effect không chỉ do hai slot mới.

Với hai slot,  $1T + 1D$  cao hơn  $2T$  trung bình 0.030546, khoảng tin cậy [0.002949, 0.068185]. Với ba slot,  $2T + 1D$  cao hơn  $3T$  0.016012, nhưng khoảng tin cậy  $[-0.002072, 0.041466]$  chứa 0 và mười target hòa. Mẫu giảm effect theo số TBM cho thấy candidate DRfold2 có giá trị lớn nhất khi nó thay một template dư thừa; khi ba TBM đã đa dạng, lợi ích biên nhỏ hơn

và bất định hơn.

Bảng 6.3: Candidate allocation với geometry refinement tắt.

| So sánh               | Mean baseline | Mean hybrid | Mean gain và CI 95%             |
|-----------------------|---------------|-------------|---------------------------------|
| $2T$ so với $1T + 1D$ | 0.549040      | 0.579586    | +0.030546 [0.002949, 0.068185]  |
| $3T$ so với $2T + 1D$ | 0.565183      | 0.581196    | +0.016012 [−0.002072, 0.041466] |
| $3T$ so với $3T + 2D$ | 0.565183      | 0.588304    | +0.023121 [0.006444, 0.047519]  |


Bảng 6.3 phân biệt fixed-size effect và production-bank effect. Dòng  $3T + 2D$  mô tả trần sẵn có của pipeline năm slot; hai dòng fixed- $N$  kiểm tra fairness. Ở cả  $N = 2$  và  $N = 3$ , thay một TBM bằng một DRfold2 làm mean tăng, nhưng chỉ khoảng tin cậy của so sánh hai slot nằm hoàn toàn phía dương.

## 6.3 RQ3: Geometry refinement

### 6.3.1 Kết quả xác nhận

Full refinement tăng C1'-IDDT từ 0.659836 lên 0.666496, tương ứng +0.006660 với khoảng tin cậy [0.000933, 0.013093]; 12/20 target cải thiện. SW-RMSD9 giảm từ 2.651395 xuống 2.611010 Å, mức tốt lên 0.040386 Å với khoảng tin cậy [0.029354, 0.052090] và 19/20 target cải thiện. SW-RMSD15 giảm 0.017257 Å, khoảng tin cậy [0.000617, 0.031336], tốt hơn ở 15/20 target.

Global TM thay đổi từ 0.588304 xuống 0.587197, tức −0.001107 với khoảng tin cậy [−0.002809, 0.000418]. Effect nằm trong biên bảo toàn 0.005 đã khóa. C1 RMSD toàn cấu trúc và SW-RMSD31 chưa có bằng chứng thay đổi. Hình 6.2 cho thấy local improvement cùng global preservation trong hai panel có đơn vị riêng.



Hình 6.2: Effect confirmatory của geometry refinement. Điểm tăng dùng trực score; RMSD reduction dùng angstrom và được định hướng dương là tốt hơn.

Bảng 6.4: Raw và full geometry refinement trên 20 RNA validation.

| Metric                 | Raw      | Refined  | Thay đổi tốt lên | CI 95%                |
|------------------------|----------|----------|------------------|-----------------------|
| Best-of-five TM        | 0.588304 | 0.587197 | -0.001107        | [-0.002809, 0.000418] |
| C1'-IDDT               | 0.659836 | 0.666496 | +0.006660        | [0.000933, 0.013093]  |
| SW-RMSD9 (Å)           | 2.651395 | 2.611010 | +0.040386        | [0.029354, 0.052090]  |
| SW-RMSD15 (Å)          | 4.273393 | 4.256136 | +0.017257        | [0.000617, 0.031336]  |
| Backbone deviation (Å) | 1.040270 | 0.785817 | +0.254453        | diagnostic            |
| Clash per residue      | 0.065121 | 0.022802 | +0.042319        | diagnostic            |

Dominant pattern trong Bảng 6.4 là hiệu quả tăng khi metric tập trung vào cửa sổ ngắn. SW-RMSD9 có effect ổn định nhất, SW-RMSD15 nhỏ hơn, còn SW-RMSD31 và global RMSD không rõ. Gradient theo scale này khớp với mục tiêu thiết kế: refinement di chuyển quan hệ lân cận chứ không tái sắp xếp toàn fold.

### 6.3.2 Baseline đơn giản và ablation

Source+backbone baseline tăng IDDT 0.007581, cao hơn numeric gain 0.006660 của full method. Chênh full trừ simple là -0.000921 với khoảng tin cậy [-0.003118, 0.001327], do đó full objective không được xem là vượt baseline về IDDT. Ngược lại, full method giảm SW-RMSD9 thêm 0.030585 Å so với simple, khoảng tin cậy [0.019640, 0.044115], và sửa angle-NLL, torsion-NLL, clash cùng kink mà baseline đơn giản làm xấu.

Leave-one-out trên calibration liên kết từng term với cơ chế. Bỏ backbone gần như làm mất IDDT gain; bỏ angle hoặc torsion làm xấu NLL tương ứng; bỏ kink tăng sharp-kink rate; bỏ clash hoặc  $R_g$  làm clash diagnostic xấu. Các kết quả này chứng minh objective hoạt động theo thiết kế, nhưng không biến diagnostic đã tối ưu thành bằng chứng độc lập. Claim chính vẫn dựa trên IDDT và sliding-window RMSD.

### 6.3.3 Factorial source và refinement

Trên bank  $3T$ , refinement làm TM thay đổi  $-0.005852$  với khoảng tin cậy  $[-0.014781, 0.000724]$ . Trên bank  $2T + 1D$ , effect là  $-0.002604$  với khoảng tin cậy  $[-0.005473, -0.000278]$ . Interaction bằng  $+0.003248$  và khoảng tin cậy chứa 0. Bảng 6.5 cho thấy source-bank effect dương khi geometry tắt, trong khi geometry effect không dương ở cả hai bank.

Bảng 6.5: Factorial fixed- $N=3$  tách source composition và geometry refinement.

| Candidate bank | Raw mean TM | Refined mean TM |
|----------------|-------------|-----------------|
| $3T + 0D$      | 0.565183    | 0.559331        |
| $2T + 1D$      | 0.581196    | 0.578592        |

Factorial bác bỏ cách giải thích đơn giản rằng refinement tạo ra mức tăng global TM của pipeline hybrid. Khi geometry tắt, đổi từ  $3T$  sang  $2T + 1D$  đã tạo mean gain 0.016012. Khi bật geometry, cả hai bank giảm nhẹ về TM. Kết quả cùng complementarity study ủng hộ source diversity là cơ chế global chính; geometry refinement cung cấp một effect local khác hướng đo.

### 6.3.4 Phân tầng và failure case


Phân tích hậu kiểm cho thấy candidate có chất lượng ban đầu thấp tăng IDDT 0.016261, khoảng tin cậy  $[0.008900, 0.024089]$ . Nhóm chất lượng cao thay đổi  $-0.001788$  với khoảng tin cậy  $[-0.005775, 0.002420]$ . Pattern gợi ý source restraint cố định có thể quá mạnh cho candidate yếu hoặc refinement không cần thiết cho candidate đã tốt. Vì nhóm được định nghĩa sau khi mở validation, kết quả chỉ tạo giả thuyết cho quality gate tương lai.



Ba failure case cần được giữ trong narrative. Target 9E2Z\_F và 8K7W\_A giảm TM khoảng 0.009; 9B0S\_Et giảm IDDT khoảng 0.011. Refinement bảo thủ vì vậy không đồng nghĩa với monotonic improvement trên từng target. Khoảng tin cậy trung bình và số improve/regress cùng cần thiết để phản ánh rủi ro này.

## 6.4 Đánh giá external trên Kaggle

Time-safe composite TBM đạt 0.60084 public và 0.60175 private. Pipeline cuối đạt 0.62809 public và 0.61390 private, tương ứng tăng 0.02725 và 0.01215. Notebook TBM-only tham chiếu báo private 0.59298 [28]; pipeline cuối cao hơn mốc này 0.02092. Hình 6.3 đặt ba kết quả trên cùng thang đo.




Hình 6.3: Đánh giá hidden-set. Mốc TBM-only tham chiếu chỉ có private score được báo cáo; hai phương pháp của luận văn có cả public và private score.

Public execution cung cấp sanity check cho deployment. DRfold2 sinh hai candidate ở 11/12 target; target 720 nucleotide dùng năm TBM do resource limit. Geometry refinement hoàn tất cho 60/60 candidate, output có đúng schema và không đọc native. Những kiểm tra này hỗ trợ tính tin cậy của điểm nhưng không cho biết target hidden nào tạo mức tăng.

Kết quả Kaggle phải được đọc cùng local factorial. Lần nộp cuối thay hai TBM slot bằng DRfold2 và áp dụng refinement, nên +0.01215 pri-

vate là pipeline-level effect. Local evidence cho thấy hybrid bank tăng global TM trước refinement, trong khi refinement cải thiện local metric và làm TM giảm nhẹ. Sự kết hợp hai nguồn bằng chứng giải thích vì sao pipeline vượt mốc tham chiếu mà không gán toàn bộ chênh lệch cho geometry refinement.



Hình 6.4: Placeholder cho hình chồng cấu trúc. Bản cuối nên dùng một RNA validation có native công khai, cùng một Kabsch transform và đầy đủ provenance; không dùng target hidden Kaggle.

Hình 6.4 được giữ có chủ ý thay vì dựng một minh họa giả. Khi chọn target đại diện, tiêu chí nên được khai báo trước, chẳng hạn target có SW-RMSD9 gần median effect. Caption cuối cần ghi target ID, candidate source, raw và refined metric, cửa sổ được đánh dấu cùng script tạo hình.

# Chương 7

## Thảo luận

### 7.1 Vì sao pipeline hybrid có giá trị

Kết quả vượt mốc TBM-only không xuất phát từ việc một nhánh luôn mạnh hơn nhánh kia. TBM có mean oracle cao hơn DRfold2 và thắng 12/20 target, nhưng DRfold2 thắng tám target còn lại. Khi metric lấy best-of-five, một candidate nguồn khác chỉ cần thắng ở một tập con đủ lớn để nâng mean union. Complementarity vì vậy là thuộc tính phân bố theo target, không phải chênh lệch mean của từng source.

Fixed-N=2 củng cố lập luận bằng cách loại candidate-count advantage: thay một trong hai TBM bằng DRfold2 vẫn tạo gain có khoảng tin cậy dương. Fixed-N=3 yếu hơn vì ba TBM đã giữ nhiều diversity hơn và cohort chỉ có 20 target. Cùng với union gain dương, pattern này cho thấy allocation ba TBM và hai DRfold2 là một thỏa hiệp hợp lý cho hidden distribution, không phải tỷ lệ phổ quát cho mọi benchmark.

TBM mạnh trong cuộc thi còn có một nguyên nhân dữ liệu. Paper tổng kết cho biết 19/20 private target có ít nhất một prior structure với TM-align trên 0.45, cao hơn tỷ lệ của CASP15 [12]. Snapshot template lớn và composite search giúp pipeline khai thác regime giàu khuôn này. Tuy nhiên, chính paper cũng cảnh báo kết luận ưu tiên TBM có thể không khái quát sang template-poor RNA [12]. DRfold2 giữ giá trị như bảo hiểm cho phần phân bố đó.

## 7.2 Vì sao geometry refinement không tăng TM-score

Source restraint làm objective có một nghiệm gần candidate đầu. Backbone, angle, torsion và clash term chủ yếu tác động trên quan hệ ngắn hạn; chúng không cung cấp tín hiệu để đổi topology hoặc dịch chuyển cả domain. Do đó, IDDT và SW-RMSD9 cải thiện trong khi TM gần như giữ nguyên là kết quả phù hợp với thiết kế, không phải mâu thuẫn.

Một global fold sai cần thông tin về contact xa, motif hoặc template khác. Tối ưu một trace quanh source không thể tự tạo thông tin này. Quan sát tương tự đã được thảo luận trong refinement nucleic acid: cải thiện stereochemistry không bảo đảm systematic RMSD improvement [20]. Vì vậy, geometry refinement nên được xem như hậu xử lý chất lượng hình học, còn source diversity quyết định định hướng global chính.

Simple baseline tăng IDDT ngang full method, cho thấy backbone smoothing là cơ chế mạnh nhất cho metric này. Giá trị bổ sung của full objective xuất hiện rõ hơn ở SW-RMSD9 và các diagnostic angle, torsion, clash, kink. Điều này thu hẹp contribution: full method không cần thiết để đạt mọi local gain, nhưng nó tạo một trace cân bằng hơn trên nhiều ràng buộc mà không phá global fold trung bình.

## 7.3 Diễn giải điểm leaderboard

Điểm private 0.61390 có value vì được đo trên cấu trúc ẩn và cao hơn cả pipeline TBM của dự án lẫn mốc notebook tham chiếu. Nó chứng minh implementation đầy đủ hoạt động trên một phân bố ngoài cohort local. Tuy nhiên, một scalar score không chứa per-target counterfactual. Không thể biết cùng target sẽ đạt bao nhiêu nếu chỉ tắt refinement hoặc đổi một slot DRfold2 sau khi cuộc thi đã đóng.

Lập luận thuyết phục vì thế gồm ba lớp. Thứ nhất, integrity audit cho thấy submission không dùng native và tuân temporal gate. Thứ hai, local complementarity xác định một cơ chế global có effect dương. Thứ ba, local refinement xác định một cơ chế local riêng và cho thấy nó không tăng TM. Ba lớp cùng giải thích kết quả nhưng vẫn giữ ranh giới giữa

external performance và component causality.

Sự đảo chiều giữa cohort cũng đáng chú ý. Rule frozen trên 12 CASP15 target đạt 0.46450 và kém local TBM bank, trong khi private Kaggle tăng 0.01215. Khác biệt cho thấy target distribution quyết định allocation hiệu quả. Báo cáo cả hai kết quả đáng tin cậy hơn việc chọn cohort thuận lợi, đồng thời phản bác claim rằng một tỷ lệ nguồn luôn tối ưu.

## 7.4 Nguy cơ đối với tính hợp lệ

### 7.4.1 Tính hợp lệ nội tại

Calibration và validation chỉ có 20 target mỗi split, vì vậy interval còn rộng cho nhiều ablation. Bootstrap theo target xử lý dependence giữa candidate nhưng không tạo thêm thông tin ngoài 20 RNA [26]. Nhiều phân tích subgroup làm tăng khả năng tìm thấy pattern ngẫu nhiên; luận văn do đó ghi chúng là post hoc và không dùng để thay đổi method.

Candidate cache chỉ có ba TBM và hai DRfold2. Fixed-N đến ba slot được xác định đầy đủ, nhưng allocation năm slot từ  $5T$  đến  $5D$  không thể đánh giá. Một nghiên cứu tiếp theo cần sinh ít nhất năm candidate độc lập từ mỗi nguồn trước khi mở cohort mới.

### 7.4.2 Tính hợp lệ external

Validation local dài tối đa 96 nucleotide và tập trung vào RNA đơn chuỗi. Kết quả refinement không trực tiếp khái quát sang RNA 720 nucleotide, multi-chain complex hoặc RNA-protein interface. Các hệ này có tương tác và độ linh động khác, đồng thời thường được xác định bằng kỹ thuật thực nghiệm có nhiều mức phân giải [1, 5].

Kaggle private set có tỷ lệ target giàu template cao [12]. Do đó, chênh lệch với notebook TBM-only là bằng chứng phù hợp cho phân bố cuộc thi nhưng không bảo đảm cùng thứ tự trên template-poor benchmark. Một temporal benchmark mới sau năm 2026 là phép kiểm tra phù hợp hơn cho khả năng khái quát.

### 7.4.3 Độ phù hợp của metric

TM-score và C1'-IDDT chỉ đánh giá trace coarse-grained. Chúng không đo trực tiếp base orientation, hydrogen bond, ion coordination hoặc stereochemistry full-atom. Những đặc điểm này quan trọng đối với tertiary interaction và chức năng RNA [4, 2]. Vì vậy, một trace có TM cao chưa phải mô hình đủ cho docking hoặc mechanistic interpretation.

Angle-NLL, torsion-NLL, clash và kink là objective diagnostics nên có bias thuận lợi cho full method. Chúng giải thích mechanism nhưng không thể thay thế metric độc lập. Việc đặt IDDT, SW-RMSD và TM làm primary evidence giảm circularity, song một validation full-atom vẫn cần thiết trước ứng dụng hóa sinh.

## 7.5 Hướng cải tiến

Hướng gần nhất là quality-gated refinement. Pattern hậu kiểm cho thấy candidate yếu tăng IDDT nhiều hơn candidate mạnh; một gate blind có thể bỏ refinement khi source confidence cùng self-consistency cao. Gate phải được preregister trên calibration mới và kiểm tra trên cohort chưa mở, nếu không nó sẽ tái tạo overfitting mà protocol hiện tại tránh.

Hướng thứ hai là tăng diversity trong từng nguồn. Năm TBM và năm DRfold2 độc lập sẽ cho phép allocation sweep đầy đủ, đo marginal return của từng slot và chọn tỷ lệ theo confidence. Hướng thứ ba là mở rộng representation từ C1' sang full atom bằng một công cụ reconstruction có benchmark rõ, chẳng hạn Arena, rồi đánh giá stereochemistry bằng metric chuyên biệt [21, 8].

Cuối cùng, temporal metadata cần fail closed trong mọi trường hợp và self-PDB exclusion cần đọc trực tiếp reference ID của target. Những thay đổi này không nhằm tăng score mà tăng auditability. Với một lĩnh vực có dữ liệu công bố liên tục, khả năng tái dựng chính xác kiến thức có sẵn tại thời điểm dự đoán là điều kiện để kết quả còn ý nghĩa.

# Chương 8

## Kết luận

Luận văn xây dựng và kiểm chứng một pipeline RNA 3D gồm time-safe TBM, DRfold2 và geometry refinement. Thay vì xem điểm cuối là bằng chứng duy nhất, nghiên cứu tách retrieval, source diversity và local refinement thành ba câu hỏi có ablation cùng protocol riêng.

Đối với RQ1, MMseqs2 cung cấp candidate mạnh khi tìm thấy homolog nhưng chỉ phủ 8/20 RNA calibration. Composite search mở rộng availability lên 20/20; full weighted score không thắng rõ G-only, còn coverage là tín hiệu reranking có effect lớn nhất. Kết quả xác định composite như một recall heuristic trong pipeline TBM an toàn thời gian.

Đối với RQ2, TBM có mean cao hơn DRfold2 nhưng hai nguồn thắng trên các target khác nhau. Union tăng mean best-available TM 0.023121 với khoảng tin cậy dương, và fixed-N=2 vẫn cho gain 0.030546. Đây là bằng chứng trực tiếp rằng diversity giữa nguồn có thể nâng best-of-five score mà không cần một source luôn vượt source kia.

Đối với RQ3, geometry refinement tăng C1'-lDDT 0.006660, giảm SW-RMSD9 0.040386 Å và giữ TM change ở  $-0.001107$ . Simple baseline giải thích phần lớn lDDT gain, còn full objective tốt hơn ở cửa sổ ngắn và các diagnostic hình học. Kết luận phù hợp là refinement sửa local trace và bảo toàn global fold trung bình.

Pipeline cuối đạt 0.62809 public và 0.61390 private, cao hơn time-safe TBM của dự án và mốc TBM-only tham chiếu. Local factorial cho thấy mức tăng global hợp lý nhất đến từ candidate complementarity; geometry refinement đóng góp một lợi ích local riêng và không được dùng để giải thích toàn bộ chênh lệch leaderboard. Sự phân biệt này là value khoa học

chính của luận văn: không chỉ báo cáo một hệ thống đạt điểm cao, mà còn chỉ ra bằng chứng nào hỗ trợ từng cơ chế và giới hạn của bằng chứng đó.



# Phụ lục A

## Khả năng tái lập

Các artifact chính gồm:

- `scripts/run_tbm_whitebox_ablation.py`: component study của TBM;
- `scripts/summarize_hybrid_complementarity.py`: candidate allocation và source complementarity;
- `reports/thesis_notes/tbm_whitebox_ablation.md`: bảng RQ1;
- `reports/thesis_notes/hybrid_complementarity.md`: bảng RQ2;
- `reports/thesis_notes/kaggle_submission_analysis.md`: manifest và score external;
- `scripts/generate_thesis_v2_figures.py`: tạo toàn bộ hình dữ liệu trong bản thảo này.

Runner confirmatory và báo cáo chi tiết RQ3 được lưu trong repository cùng frozen configuration. Khi đóng gói release cuối, nên thêm manifest gồm Git commit, Python environment, checksum của template database, pretrained model version và lệnh chạy cho từng bảng.

## Phụ lục B

### Danh mục hình cần hoàn thiện

Hình 6.4 là placeholder duy nhất có chủ ý. Quy trình hoàn thiện gồm: chọn một target validation theo tiêu chí cố định; lấy native công khai, raw candidate và refined candidate từ artifact; dùng cùng correspondence và Kabsch transform; vẽ ba trace với residue index đồng nhất; đánh dấu cửa sổ có thay đổi gần median; xuất cả PDF vector và PNG; ghi source path cùng metric trong caption.

Các hình còn lại được tạo từ aggregate frozen bằng script trong Phụ lục A. Trước khi nộp, cần kiểm tra font, bảng màu khi in grayscale, kích thước chữ ở 100% và đối chiếu từng con số trong hình với table nguồn.

# Tài liệu tham khảo

- [1] J. Zhang, Y. Fei, L. Sun, and Q. C. Zhang, “Advances and opportunities in RNA structure experimental determination and computational modeling,” *Nature Methods*, vol. 19, pp. 1193-1207, 2022. doi: 10.1038/s41592-022-01623-y.
- [2] X. Cao, Y. Zhang, Y. Ding, and Y. Wan, “Identification of RNA structures and their roles in RNA functions,” *Nature Reviews Molecular Cell Biology*, vol. 25, pp. 784-801, 2024. doi: 10.1038/s41580-024-00748-6.
- [3] I. Tinoco Jr. and C. Bustamante, “How RNA folds,” *Journal of Molecular Biology*, vol. 293, no. 2, pp. 271-281, 1999. doi: 10.1006/jmbi.1999.3001.
- [4] S. E. Butcher and A. M. Pyle, “The Molecular Interactions That Stabilize RNA Tertiary Structure: RNA Motifs, Patterns, and Networks,” *Accounts of Chemical Research*, vol. 44, no. 12, pp. 1302-1311, 2011. doi: 10.1021/ar200098t.
- [5] H. Ma, X. Jia, K. Zhang, and Z. Su, “Cryo-EM advances in RNA structure determination,” *Signal Transduction and Targeted Therapy*, vol. 7, article 58, 2022. doi: 10.1038/s41392-022-00916-0.
- [6] S. K. Burley and coauthors, “Protein Data Bank: the single global archive for 3D macromolecular structure data,” *Nucleic Acids Research*, vol. 47, no. D1, pp. D520-D528, 2019. doi: 10.1093/nar/gky949.
- [7] J. A. Cruz and coauthors, “RNA-Puzzles: A CASP-like evaluation of RNA three-dimensional structure prediction,” *RNA*, vol. 18, no. 4, pp. 610-625, 2012. doi: 10.1261/rna.031054.111.

- [8] M. Magnus, M. Antczak, T. Zok, and coauthors, “RNA-Puzzles toolkit: a computational resource of RNA 3D structure benchmark datasets, structure manipulation, and evaluation tools,” *Nucleic Acids Research*, vol. 48, no. 2, pp. 576-588, 2020. doi: 10.1093/nar/gkz1108.
- [9] R. Das and coauthors, “Assessment of three-dimensional RNA structure prediction in CASP15,” *Proteins: Structure, Function, and Bioinformatics*, vol. 91, no. 12, pp. 1747-1770, 2023. doi: 10.1002/prot.26602.
- [10] C. Bernard, G. Postic, S. Ghannay, and F. Tahi, “State-of-the-RNART: benchmarking current methods for RNA 3D structure prediction,” *NAR Genomics and Bioinformatics*, vol. 6, no. 2, article lqae048, 2024. doi: 10.1093/nargab/lqae048.
- [11] X. Wang, S. Yu, E. Lou, Y. L. Tan, and Z. J. Tan, “RNA 3D Structure Prediction: Progress and Perspective,” *Molecules*, vol. 28, no. 14, article 5532, 2023. doi: 10.3390/molecules28145532.
- [12] Y. Lee, S. He, T. Oda, and coauthors, “Template-based RNA structure prediction advanced through a blind code competition,” *bioRxiv*, preprint 2025.12.30.696949, 2025. doi: 10.64898/2025.12.30.696949.
- [13] M. Steinegger and J. Söding, “MMseqs2 enables sensitive protein sequence searching for the analysis of massive data sets,” *Nature Biotechnology*, vol. 35, pp. 1026-1028, 2017. doi: 10.1038/nbt.3988.
- [14] S. B. Needleman and C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *Journal of Molecular Biology*, vol. 48, no. 3, pp. 443-453, 1970. doi: 10.1016/0022-2836(70)90057-4.
- [15] T. F. Smith and M. S. Waterman, “Identification of common molecular subsequences,” *Journal of Molecular Biology*, vol. 147, no. 1, pp. 195-197, 1981. doi: 10.1016/0022-2836(81)90087-5.
- [16] Y. Li, C. Zhang, C. Feng, R. Pearce, P. L. Freddolino, and Y. Zhang, “Integrating end-to-end learning with deep geometrical potentials

- for ab initio RNA structure prediction,” *Nature Communications*, vol. 14, article 5745, 2023. doi: 10.1038/s41467-023-41303-9.
- [17] T. Shen, Z. Hu, S. Sun, and coauthors, “Accurate RNA 3D structure prediction using a language model-based deep learning approach,” *Nature Methods*, vol. 21, pp. 2287-2298, 2024. doi: 10.1038/s41592-024-02487-0.
- [18] Y. Li, C. Feng, X. Zhang, S. Tsukiyama, D. Feng, and Y. Zhang, “DR-fold2 is a deep learning-based tool that enables efficient and accurate RNA structure prediction,” *PLOS Biology*, vol. 24, no. 2, article e3003659, 2026. doi: 10.1371/journal.pbio.3003659.
- [19] R. J. L. Townshend, S. Eismann, A. M. Watkins, and coauthors, “Geometric deep learning of RNA structure,” *Science*, vol. 373, no. 6558, pp. 1047-1051, 2021. doi: 10.1126/science.abe5650.
- [20] P. Stasiewicz, S. Mukherjee, C. Nithin, and J. M. Bujnicki, “QRNAS: software tool for refinement of nucleic acid structures,” *BMC Structural Biology*, vol. 19, article 5, 2019. doi: 10.1186/s12900-019-0103-1.
- [21] Z. R. Perry, A. M. Pyle, and C. Zhang, “Arena: Rapid and Accurate Reconstruction of Full Atomic RNA Structures From Coarse-grained Models,” *Journal of Molecular Biology*, vol. 435, article 168210, 2023. doi: 10.1016/j.jmb.2023.168210.
- [22] Y. Zhang and J. Skolnick, “Scoring function for automated assessment of protein structure template quality,” *Proteins: Structure, Function, and Bioinformatics*, vol. 57, no. 4, pp. 702-710, 2004. doi: 10.1002/prot.20264.
- [23] C. Zhang, M. Shine, A. M. Pyle, and Y. Zhang, “US-align: universal structure alignments of proteins, nucleic acids, and macromolecular complexes,” *Nature Methods*, vol. 19, pp. 1109-1115, 2022. doi: 10.1038/s41592-022-01585-1.
- [24] V. Mariani, M. Biasini, A. Barbato, and T. Schwede, “lDDT: a local superposition-free score for comparing protein structures and models using distance difference tests,” *Bioinformatics*, vol. 29, no. 21, pp. 2722-2728, 2013. doi: 10.1093/bioinformatics/btt473.

- [25] W. Kabsch, “A solution for the best rotation to relate two sets of vectors,” *Acta Crystallographica Section A*, vol. 32, pp. 922-923, 1976. doi: 10.1107/S0567739476001873.
- [26] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman and Hall/CRC, 1993.
- [27] Stanford University and Kaggle, “Stanford RNA 3D Folding,” Kaggle competition documentation, 2025. Available: <https://www.kaggle.com/competitions/stanford-rna-3d-folding>.
- [28] JaeJohn, “RNA 3D folds - TBM only approach,” Kaggle notebook, version 1, 2025. Available: <https://www.kaggle.com/code/jaejohn/rna-3d-folds-tbm-only-approach>.