

TRƯỜNG ĐẠI HỌC KHOA HỌC VÀ CÔNG NGHỆ HÀ NỘI
ICT LAB

ĐỒ THÀNH ĐẠT

MÔ HÌNH LAI DỰA TRÊN KHUÔN MẪU
VÀ HỌC SÂU CHO DỰ ĐOÁN
CẤU TRÚC BA CHIỀU RNA
VỚI KIỂM SOÁT RÒ RỈ THỜI GIAN
VÀ TÍNH CHỈNH HÌNH HỌC

*A Hybrid Template-Based and Deep-Learning Framework for RNA
Three-Dimensional Structure Prediction with Temporal Leakage Control
and Geometry Refinement*

LUẬN VĂN THẠC SĨ

DATA SCIENCE

Giảng viên hướng dẫn: NGUYỄN MINH HƯƠNG

NGUYỄN CẨM LINH

Mã số học viên: 2440059

HÀ NỘI, 2026

Lời cam đoan

[CẦN ĐIỀN: Bổ sung lời cam đoan theo biểu mẫu chính thức của trường.]

Lời cảm ơn

[CẦN ĐIỀN: Bổ sung lời cảm ơn giảng viên hướng dẫn, đơn vị đào tạo, đồng nghiệp và gia đình.]

Tóm tắt

Dự đoán cấu trúc ba chiều RNA từ trình tự vẫn là một bài toán khó vì RNA có thể tồn tại ở nhiều cấu dạng, trong khi số cấu trúc thực nghiệm còn hạn chế [1, 11, 10]. Luận văn kế thừa ý tưởng cốt lõi từ phương pháp công khai của đội thắng cuộc Stanford RNA 3D Folding: tìm cấu trúc tương tự trong kho dữ liệu, chuyển tọa độ sang RNA cần dự đoán và bổ sung phương án từ mô hình học sâu. Trên nền tảng đó, luận văn xây dựng một pipeline có thể kiểm toán gồm TBM an toàn theo thời gian, hai phương án DRfold2 và Geometry Refinement. Hệ thống xuất năm cấu trúc mà không đọc cấu trúc thật, phù hợp với cách Kaggle giữ dự đoán tốt nhất trong năm phương án cho mỗi RNA [12, 27, 28].

Các thí nghiệm được tách thành hai tầng. Tầng phân tích sử dụng 60 RNA để ước lượng phân bố tham chiếu, 20 RNA để chọn cấu hình và 20 RNA mới hơn để xác nhận một lần; tầng bên ngoài dùng public và private leaderboard của Kaggle để đánh giá toàn pipeline. Trên 20 RNA hiệu chỉnh, MMseqs2 tìm được khuôn cho 8 RNA, trong khi tìm kiếm tổng hợp tạo phương án cho cả 20. Kết quả này cho thấy tổng hợp chủ yếu mở rộng khả năng tìm khuôn, còn công thức trọng số đầy đủ chưa chứng minh được ưu thế so với căn chỉnh toàn cục đơn lẻ.

Trên 20 RNA xác nhận, ba phương án TBM đạt TM-score tốt nhất sẵn có trung bình 0.565, trong khi hai phương án DRfold2 đạt 0.503. Khi giữ cả năm phương án, điểm tăng lên 0.588, tương ứng chênh lệch tuyệt đối +0.023 với khoảng tin cậy 95% [0.006, 0.048]. DRfold2 cung cấp phương án tốt hơn trên 8/20 RNA, cho thấy giá trị của mô hình nằm ở những trường hợp bổ sung thay vì ưu thế trung bình. Geometry Refinement làm C1'-IDDT tăng từ 0.660 lên 0.666 và SW-RMSD9 giảm từ 2.651 xuống 2.611 Å, trong khi TM-score thay đổi từ 0.588 xuống 0.587. Kết quả này cho thấy phương pháp cải thiện quan hệ cục bộ nhưng chưa làm tăng độ đúng của nếp gấp tổng thể.

Trên Kaggle, TBM của luận văn đạt 0.601 public và 0.602 private; pipeline cuối đạt 0.628 public và 0.614 private. Điểm private cuối cao hơn 0.021 so với notebook TBM-only công khai của John, 0.038 so với notebook hybrid công khai của cùng tác giả và 0.036 so với điểm 0.578 của đội thắng cuộc. Đây là so sánh ở mức toàn pipeline vì các hệ thống khác

nhau đồng thời về dữ liệu, cách tìm khuôn, nguồn đã huấn luyện sẵn và hậu xử lý. Kết hợp với thí nghiệm có kiểm soát, bằng chứng hiện tại xác định sự đa dạng phương án là cơ chế chính làm tăng TM-score, còn Geometry Refinement tạo một lợi ích riêng ở quy mô cục bộ.

Từ khóa: cấu trúc ba chiều RNA, mô hình hóa dựa trên khuôn mẫu, DRfold2, TM-score, C1'-IDDT, an toàn thời gian, tinh chỉnh hình học.

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt	iii
1 Giới thiệu	1
1.1 Bối cảnh nghiên cứu	1
1.2 Vấn đề nghiên cứu	2
1.3 Câu hỏi nghiên cứu	3
1.4 Đóng góp	3
1.5 Phạm vi và cấu trúc luận văn	5
2 Nền tảng và công trình liên quan	6
2.1 Tổ chức cấu trúc RNA	6
2.2 Mô hình hóa dựa trên khuôn mẫu	7
2.3 Dự đoán bằng học sâu	7
2.4 Tinh chỉnh cấu trúc	8
2.5 Đánh giá cấu trúc	8
2.6 Khoảng trống nghiên cứu	8
3 Dữ liệu và kiểm soát đánh giá	10
3.1 Các nguồn dữ liệu	10
3.2 Mốc thời gian và loại khuôn của chính RNA mục tiêu	12
3.3 Quy tắc sử dụng nhãn	13
3.4 Đơn vị phân tích và thống kê	14

4	Pipeline đề xuất	15
4.1	Tổng quan	15
4.2	Nhánh TBM an toàn thời gian	16
4.2.1	Truy hồi hai đường	16
4.2.2	Căn chỉnh lại và xếp hạng	17
4.2.3	Chuyển tọa độ và lấp khoảng trống	18
4.3	Nhánh DRfold2	18
4.4	Geometry Refinement	19
4.4.1	Mục tiêu thiết kế	19
4.4.2	Phân bố tham chiếu hình học	20
4.4.3	Đối chứng và đầu ra	21
4.5	Mã giả	21
5	Thiết kế thí nghiệm	22
5.1	Chiến lược kiểm định	22
5.2	Đối chứng kế thừa và nguyên tắc so sánh	23
5.3	Thí nghiệm tách thành phần TBM	23
5.4	Thí nghiệm tính bổ sung	24
5.5	Thí nghiệm Geometry Refinement	24
5.6	Đánh giá Kaggle và khả năng tái lập	25
6	Kết quả	26
6.1	RQ1: Truy hồi và xếp hạng TBM	26
6.1.1	Hai nguồn truy hồi	26
6.1.2	Thành phần tổng hợp	27
6.1.3	Xếp hạng lại và lấp khoảng trống	27
6.1.4	So sánh với TBM kế thừa	28
6.2	RQ2: TBM và DRfold2 bổ sung nhau	28
6.3	RQ3: Geometry Refinement	29
6.3.1	Kết quả xác nhận	29
6.3.2	Đối chứng đơn giản và thí nghiệm tách thành phần	30
6.3.3	Thiết kế nhân tố cho nguồn và tinh chỉnh	31

6.3.4	Phân tầng và trường hợp thất bại	31
6.4	Đánh giá bên ngoài trên Kaggle	32
7	Thảo luận	34
7.1	Phân nào được kế thừa và phân nào là đóng góp của luận văn	34
7.2	Vì sao kết hợp TBM và DRfold2 có giá trị	35
7.3	Vì sao Geometry Refinement không làm tăng TM-score	35
7.4	Cách đọc điểm Kaggle	36
7.5	Giới hạn của nghiên cứu	36
7.6	Công việc cần hoàn thành	37
8	Kết luận	38
A	Khả năng tái lập	40
B	Danh mục kiểm tra trước khi nộp	41

Danh mục bảng

1.1	Nguồn gốc các thành phần và thay đổi của luận văn.	4
3.1	Các tệp Kaggle chính và vai trò trong pipeline.	10
3.2	Phân chia dữ liệu cho Geometry Refinement và thí nghiệm tính bổ sung. . .	11
5.1	Ảnh xạ câu hỏi nghiên cứu sang thí nghiệm và kết luận được phép.	22
6.1	Ảnh hưởng của nguồn truy hồi trên 20 RNA hiệu chỉnh. Chất lượng MM-seqs2 được tính có điều kiện trên tám RNA tìm thấy khuôn.	26
6.2	Thí nghiệm tách thành phần xếp hạng TBM.	27
6.3	Phân bổ phương án khi tắt Geometry Refinement.	29
6.4	Cấu trúc thô và Geometry Refinement đầy đủ trên 20 RNA xác nhận. . . .	30
6.5	Thiết kế nhân tố fixed-N=3 tách thành phần nguồn và Geometry Refinement. .	31
6.6	So sánh điểm Kaggle. Dấu gạch ngang nghĩa là nguồn tham chiếu không báo mốc đó.	32

Danh mục hình

3.1	Quy trình bằng chứng hai tầng. Ba phần dữ liệu cục bộ tách theo thời gian và họ; Kaggle đóng vai trò kiểm tra bên ngoài ở mức toàn pipeline.	12
3.2	Minh họa mức tăng điểm do rò rỉ khuôn trên tập RNA CASP15 phát triển. Hai cột không an toàn chỉ là chỉ số chẩn đoán và không tham gia kết quả phương pháp.	13
4.1	Pipeline cuối. Đa dạng nguồn được tạo trước tinh chỉnh; không có lựa chọn hay hợp nhất tọa độ dựa trên nhãn cấu trúc thật.	15
4.2	Luồng TBM. MMseqs2 ưu tiên RNA họ hàng rõ, tìm kiếm tổng hợp mở rộng độ phủ, còn điều kiện an toàn được áp dụng trước khi căn chỉnh lại và chuyển tọa độ.	17
4.3	Cơ chế Geometry Refinement. Ràng buộc nguồn giữ cấu trúc gần phương án ban đầu, trong khi các phân bố tham chiếu điều chỉnh khoảng cách, góc, góc xoắn, va chạm, gấp khúc và kích thước.	19
6.1	Tính bổ sung của tập phương án trên 20 RNA xác nhận. Mức tăng của hợp hai nguồn được tính so với ba TBM và khoảng tin cậy bootstrap theo RNA mục tiêu.	28
6.2	Tác động xác nhận của Geometry Refinement. Thay đổi điểm dùng trực riêng; mức giảm RMSD dùng đơn vị angstrom và giá trị dương nghĩa là tốt hơn. .	30
6.3	Đánh giá trên cấu trúc ẩn. Ba mốc của John chỉ dùng điểm private được công bố; hai pipeline của luận văn có cả điểm public và private.	32

Chương 1

Giới thiệu

1.1 Bối cảnh nghiên cứu

RNA tham gia điều hòa biểu hiện gene, xúc tác, nhận diện phân tử và hình thành các phức hợp ribonucleoprotein. Các chức năng này phụ thuộc không chỉ vào thứ tự A, C, G và U mà còn vào cách chuỗi tạo cặp base, motif và cấu trúc ba chiều [2, 3, 4]. Cấu trúc bậc hai mô tả các cặp base và motif cục bộ, trong khi cấu trúc bậc ba xác định cách các motif tương tác và sắp xếp trong không gian [3, 4]. Do đó, một mô hình dự đoán RNA 3D hữu ích phải khôi phục được cả nếp gấp tổng thể lẫn quan hệ hình học cục bộ.

Tinh thể học tia X, cộng hưởng từ hạt nhân và kính hiển vi điện tử nghiệm lạnh là ba nhóm kỹ thuật chính để xác định cấu trúc RNA. Mỗi kỹ thuật có miền áp dụng và giới hạn riêng; chẳng hạn, cryo-EM đã mở rộng khả năng khảo sát các phức hợp RNA lớn nhưng việc chuẩn bị mẫu, thu dữ liệu và dựng mô hình vẫn đòi hỏi chuyên môn cùng tài nguyên đáng kể [1, 5]. Kho lưu trữ PDB cung cấp nền tảng dữ liệu cấu trúc thực nghiệm cho cộng đồng, song RNA vẫn ít đại diện hơn protein và nhiều họ RNA chưa có khuôn gài [6, 1]. Khoảng trống đó tạo động lực cho các phương pháp suy cấu trúc từ trình tự.

Các phương pháp tính toán RNA 3D thường kết hợp ba nguồn thông tin: nguyên lý vật lý, tri thức cấu trúc đã quan sát và mẫu học từ dữ liệu. Mô hình dựa trên khuôn có thể rất chính xác khi nhận ra một họ hàng cấu trúc phù hợp; ngược lại, mô hình học sâu có thể tạo một giả thuyết ngay cả khi truy hồi khuôn yếu [11, 16, 17, 18]. Các đánh giá mù RNA-Puzzles và CASP cho thấy thứ hạng phương pháp thay đổi theo RNA mục tiêu, độ dài, mức độ mới của fold và nguồn thông tin được phép sử dụng [7, 9, 10]. Vì vậy, một tập phương án đa nguồn là lựa chọn tự nhiên khi chỉ số giữ cấu trúc tốt nhất trong nhiều dự đoán.

Cuộc thi Stanford RNA 3D Folding tạo một bối cảnh đặc biệt phù hợp để khảo sát lựa chọn này. Hơn 1,700 đội tham gia dự đoán 43 cấu trúc chưa công bố, và hai hệ thống dẫn

đầu điều khai thác TBM. Phân tích sau cuộc thi còn cho thấy một mô hình tích hợp TBM với học sâu có thể vượt các mô hình thành phần trên cùng tập kiểm tra [12]. Kết quả đó không làm mọi RNA trở thành bài toán có khuôn; thay vào đó, nó nhấn mạnh hai câu hỏi: làm thế nào truy hồi khuôn mà không nhìn tương lai, và làm thế nào bổ sung một nguồn de novo khi khuôn không đủ tốt.

1.2 Vấn đề nghiên cứu

Một pipeline TBM có thể nhận điểm cao giả tạo nếu thư viện chứa cấu trúc được phát hành sau ngày RNA mục tiêu cần được dự đoán. Đây là rõ ràng thời gian: thuật toán vẫn chỉ đọc dữ liệu công khai ở thời điểm chạy lại, nhưng dữ liệu đó chưa tồn tại trong bối cảnh đánh giá ban đầu. Các thử thách mù RNA-Puzzles và CASP được thiết kế nhằm tách dự đoán khỏi cấu trúc chưa công bố; tính toàn vẹn của phép so sánh vì vậy phụ thuộc vào mốc dữ liệu [7, 9, 12]. Luận văn yêu cầu mọi khuôn có ngày phát hành sớm hơn mốc thời gian của RNA mục tiêu và loại PDB tham chiếu của chính RNA mục tiêu.

Ngay cả khi an toàn thời gian, truy hồi bằng một công cụ duy nhất vẫn có thể bỏ lỡ khuôn. MMseqs2 được thiết kế cho tìm kiếm trình tự có tốc độ và độ nhạy cao trên tập dữ liệu lớn [13]; tuy nhiên, RNA tương đồng về fold không nhất thiết biểu lộ một homolog đủ mạnh trong bước truy hồi nhanh. Luận văn vì thế kết hợp MMseqs2 với một đường tìm kiếm tổng hợp dựa trên căn chỉnh toàn cục, căn chỉnh cục bộ, thành phần trình tự và 3-mer. Mục tiêu của tổng hợp là tăng recall của tập phương án, không phải khẳng định một hàm điểm sinh học tối ưu.

TBM cũng không thể bảo đảm một ứng viên tốt cho mọi RNA mục tiêu. Để xử lý giới hạn này, DRfold2 được đưa vào như nguồn dự đoán độc lập thay vì thay thế nhánh khuôn. DRfold2 kế thừa hướng kết hợp end-to-end learning và thế năng hình học của DRfold, đồng thời được báo cáo là cải thiện hiệu quả và độ chính xác của dự đoán RNA 3D [16, 18]. Cách bố trí ba TBM và hai DRfold2 giữ đủ ứng viên khuôn trong các trường hợp dễ, đồng thời dành hai vị trí cho fold mà mô hình học sâu có thể bổ sung.

Ứng viên từ cả hai nguồn vẫn có thể chứa khoảng cách backbone bất thường, va chạm hoặc biến dạng cục bộ. Các công cụ tinh chỉnh trước đây cho thấy tối ưu hình học có thể tăng độ hợp lý hóa học nhưng không bảo đảm giảm RMSD so với cấu trúc thật [20, 21]. Luận văn do đó đặt một mục tiêu hẹp cho Geometry Refinement: cải thiện quan hệ C1' cục bộ trong khi giữ thay đổi TM-score trong biên bảo toàn đã định trước. Cách phát biểu này tách rõ sửa hình học khỏi dự đoán lại tổng thể fold.

1.3 Câu hỏi nghiên cứu

Luận văn trả lời ba câu hỏi theo thứ tự từ nguồn ứng viên đến hậu xử lý:

- RQ1.** Tìm kiếm tổng hợp bổ sung gì cho MMseqs2 trong một pipeline TBM an toàn thời gian, và thành phần xếp hạng nào tạo ra thay đổi đo được?
- RQ2.** Khi số vị trí dự đoán được kiểm soát, DRfold2 có bổ sung các RNA mục tiêu mà TBM bỏ lỡ hay không?
- RQ3.** Geometry Refinement có cải thiện độ chính xác cục bộ theo C1'-IDDT và sliding-window RMSD trong khi bảo toàn tổng thể TM-score hay không?

Ba câu hỏi tạo một mạch nhân quả có thể kiểm tra. RQ1 giải thích cách mở rộng phương án độ phủ, RQ2 kiểm tra lợi ích của sự đa dạng giữa hai nguồn, còn RQ3 xác định chính xác phần nào của cấu trúc được thay đổi sau tinh chỉnh. Leaderboard chỉ đóng vai trò đánh giá bên ngoài cho pipeline đã khóa và không thay thế thí nghiệm tách thành phần cục bộ.

1.4 Đóng góp

Luận văn không trình bày toàn bộ pipeline như một phương pháp được xây dựng từ đầu. Điểm khởi đầu là notebook TBM công khai của John, tác giả thuộc đội thắng cuộc, cùng notebook hybrid kết hợp Boltz, DRfold2 và khuôn fallback [28, 29]. Trên điểm khởi đầu đó, luận văn thay đổi cách tổ chức dữ liệu, truy hồi, xếp hạng, phân bổ phương án và hậu xử lý. Bảng 1.1 tách rõ phần kế thừa và phần được phát triển trong nghiên cứu này.

Bảng 1.1: Nguồn gốc các thành phần và thay đổi của luận văn.

Thành phần	Nguồn	Thay đổi trong luận văn
TBM và tìm kiếm tổng hợp	Notebook TBM của John	Hợp nhất MMseqs2 với quét tổng hợp, lọc theo mốc thời gian và loại PDB của chính RNA mục tiêu
Chọn khuôn	Notebook TBM của John	Xếp hạng lại bằng tỷ lệ giống nhau $\times$ độ phủ truy vấn $\times$ độ hoàn chỉnh, đồng thời ưu tiên các PDB khác nhau
Chuyển tọa độ và lấp khoảng trống	TBM công khai	Lưu độ tin cậy theo nucleotide và kiểm tra nội suy đường cong theo độ dài khoảng trống
DRfold2 và Arena	DRfold2; notebook hybrid của John	Dùng hai dự đoán trực tiếp có độ tin cậy cao, không dùng Boltz làm ràng buộc
Phân bổ năm phương án	Thiết kế của luận văn	Giữ cố định ba TBM và hai DRfold2, dùng TBM thay thế khi DRfold2 không chạy được
Geometry Refinement	Thiết kế của luận văn	Tối ưu đồng thời ràng buộc giữ gần cấu trúc nguồn và các phân bố tham chiếu hình học, sau đó đánh giá bằng chỉ số độc lập

Đóng góp thứ nhất là một nhánh TBM có thể kiểm toán theo thời gian. Nhánh này kết hợp truy hồi nhanh và tìm kiếm tổng hợp, kiểm tra ngày phát hành, căn chỉnh lại phương án, xếp hạng bằng ba đại lượng có ý nghĩa cụ thể rồi chuyển tọa độ C1'. Mỗi thay đổi được đánh giá bằng thí nghiệm tách thành phần thay vì chỉ dựa vào điểm cuối.

Đóng góp thứ hai là bằng chứng định lượng cho tính bổ sung giữa TBM và DRfold2. Phân tích so sánh từng nguồn, hợp của hai nguồn và các tập phương án có cùng số lượng. Thiết kế fixed-N, tức cố định số vị trí dự đoán, tách lợi ích của nguồn khỏi lợi ích cơ học do có thêm cơ hội dự đoán.

Đóng góp thứ ba là Geometry Refinement bảo thủ cùng quy trình xác nhận độc lập. Phân bố tham chiếu được ước lượng trên 60 RNA, cấu hình được chọn trên 20 RNA hiệu chỉnh và được khóa trước khi mở 20 RNA xác nhận. Phương pháp được so sánh với phương án thô và một đối chứng đơn giản. Hai kiểu thí nghiệm tách thành phần được dùng: thêm dần từng hạng vào hàm mục tiêu và lần lượt bỏ từng hạng khỏi cấu hình đầy đủ.

Đóng góp cuối cùng là một lập luận hai tầng về kết quả leaderboard. Điểm private 0.614 cho thấy pipeline hoàn chỉnh hoạt động trên cấu trúc ẩn, còn các thí nghiệm cục bộ giải thích phần nào của mức tăng đến từ phương án và phần nào liên quan đến Geometry Refinement. Cách trình bày này không gán toàn bộ chênh lệch Kaggle cho một thành phần chưa được tách riêng trên private set.

1.5 Phạm vi và cấu trúc luận văn

Luận văn dự đoán một tọa độ $C1'$ cho mỗi nucleotide và xuất năm cấu trúc cho mỗi RNA mục tiêu. Phân tích xác nhận tập trung vào RNA đơn chuỗi dài tối đa 96 nucleotide; Kaggle cung cấp phép kiểm tra bên ngoài trên một phân bố khác, gồm RNA mục tiêu dài hơn. Luận văn không mô hình hóa đầy đủ nguyên tử, ion, ligand, biến đổi hóa học hoặc tương tác RNA-protein. Những yếu tố này là thành phần quan trọng của cấu trúc RNA thực tế [4, 1], nhưng nằm ngoài phạm vi dữ liệu và biểu diễn được đánh giá ở đây.

Phần còn lại được tổ chức như sau. Chương 2 trình bày nền tảng và công trình liên quan. Chương 3 mô tả dữ liệu và kiểm soát leakage. Chương 4 trình bày pipeline. Chương 5 xây dựng quy trình thí nghiệm. Chương 6 báo cáo kết quả theo ba câu hỏi nghiên cứu. Chương 7 giải thích cơ chế, giới hạn và quan hệ với cuộc thi. Chương 8 tổng kết và đề xuất hướng phát triển.

Chương 2

Nền tảng và công trình liên quan

2.1 Tổ chức cấu trúc RNA

RNA là một polymer có backbone đường-phosphate và bốn base chính. Tương tác Watson-Crick, base stacking, cặp base không chuẩn, ion và tiếp xúc bậc ba cùng góp phần ổn định cấu trúc [3, 4]. Do nhiều tương tác cách xa nhau trên trình tự lại gần nhau trong không gian, sai lệch ở một motif có thể thay đổi toàn bộ bố cục của phân tử. Điều này giải thích vì sao chất lượng cục bộ và tổng thể cần được đo bằng các chỉ số khác nhau.

Luận văn sử dụng đường khung C1' làm biểu diễn thống nhất. Với chuỗi dài L , một ứng viên được viết thành ma trận

$$X = [\mathbf{x}_1, \dots, \mathbf{x}_L]^T \in \mathbb{R}^{L \times 3}, \quad (2.1)$$

trong đó $\mathbf{x}_i$ là tọa độ C1' của nucleotide i . Biểu diễn coarse-grained này phù hợp trực tiếp với định dạng dự đoán của cuộc thi [12, 27]. Nó không thể hiện hướng base hoặc hóa học đầy đủ, vì vậy mọi kết luận của luận văn được giới hạn ở chất lượng fold và đường khung C1'.

Một phép quay hoặc tịnh tiến toàn phân tử không làm thay đổi cấu trúc nội tại. Khi cần so sánh theo correspondence đã biết, phép chồng Kabsch tìm rigid transformation làm nhỏ nhất tổng bình phương sai lệch giữa hai tập điểm [25]. Các chỉ số như IDDT không cần superposition, trong khi TM-score tìm căn chỉnh cấu trúc và chuẩn hóa theo độ dài để giảm độ nhạy với kích thước phân tử [22, 24, 23].

2.2 Mô hình hóa dựa trên khuôn mẫu

TBM dựa trên giả thuyết rằng một cấu trúc đã biết có thể cung cấp scaffold cho chuỗi mục tiêu có liên hệ. Quy trình điển hình gồm truy hồi khuôn, căn chỉnh trình tự cần dự đoán với khuôn, chuyển tọa độ tương ứng, xây phần thiếu và tinh chỉnh mô hình [11, 12]. Chất lượng phụ thuộc vào việc nhận ra khuôn phù hợp và căn đúng nucleotide. Một kết quả có tỷ lệ giống nhau cao nhưng chỉ phủ đoạn ngắn có thể kém hữu ích hơn kết quả yếu hơn nhưng phủ gần toàn chuỗi.

Needleman-Wunsch giải bài toán căn chỉnh toàn cục bằng quy hoạch động, còn Smith-Waterman tìm căn chỉnh cục bộ tốt nhất [14, 15]. Hai dạng căn chỉnh phục vụ tín hiệu khác nhau: tổng thể căn chỉnh đo sự tương đồng trên toàn chuỗi, trong khi căn chỉnh cục bộ nhận ra motif hoặc miền bảo tồn. Tìm kiếm tổng hợp của luận văn sử dụng cả hai cùng các đặc trưng thành phần và 3-mer để mở rộng tập kết quả.

MMseqs2 cung cấp truy hồi nhạy và nhanh trên cơ sở dữ liệu trình tự quy mô lớn [13]. Tuy nhiên, một pipeline nghiên cứu không nên đồng nhất tốc độ truy hồi với độ phủ cấu trúc. Vì vậy, luận văn đo riêng tỷ lệ tìm thấy khuôn, TM có điều kiện khi có kết quả và trung bình trên toàn RNA mục tiêu. Cách tách này ngăn 12 RNA không tìm thấy khuôn bị biến mất khỏi trung bình của tập RNA.

2.3 Dự đoán bằng học sâu

Các mô hình học sâu gần đây học biểu diễn trình tự, phân bố khoảng cách hoặc tọa độ để dự đoán RNA 3D. ARES sử dụng geometric deep learning để chấm điểm cấu trúc; DRfold kết hợp end-to-end learning với deep geometrical potentials; RhoFold+ sử dụng RNA language model; và DRfold2 phát triển một pipeline dự đoán hiệu quả hơn [19, 16, 17, 18]. Các phương pháp này giảm phụ thuộc trực tiếp vào một khuôn gán, nhưng độ chính xác vẫn thay đổi theo RNA mục tiêu và bộ đánh giá [10, 18].

Trong luận văn, DRfold2 không được mô tả là đối thủ thay thế TBM. Hai nguồn có failure mode khác nhau: TBM phụ thuộc vào truy hồi và căn chỉnh, còn mô hình học sâu phụ thuộc vào phân bố huấn luyện cùng tín hiệu tiến hóa. Tập phương án của luận văn giữ cả hai nguồn để tận dụng khác biệt đó. Lợi ích được kiểm tra trên RNA chưa được dùng khi chọn cấu hình, thay vì suy ra từ mô tả kiến trúc.

2.4 Tinh chỉnh cấu trúc

Tinh chỉnh cấu trúc tìm một cấu trúc lân cận thỏa các ràng buộc hình học hoặc năng lượng tốt hơn. QRNAS tối ưu cấu trúc acid nucleic bằng một hàm năng lượng mở rộng, trong khi Arena dựng mô hình đầy đủ nguyên tử từ biểu diễn rút gọn [20, 21]. Các công trình này cho thấy hợp lý hóa hình học và tiến gần cấu trúc thật là hai mục tiêu liên quan nhưng không đồng nhất. Một mô hình có bond hoặc va chạm tốt hơn vẫn có thể giữ nguyên, thậm chí giảm, độ đúng tổng thể.

Geometry Refinement trong luận văn được thiết kế theo nhận xét trên. Ràng buộc giữ gần cấu trúc nguồn giữ phương án gần cấu trúc ban đầu; phân bố tham chiếu khoảng cách, góc và góc xoắn điều chỉnh đường khung; va chạm, gấp khúc và bán kính quán tính kiểm soát các dạng lỗi cụ thể. Hiệu quả không được đánh giá bằng chính hàm mất mát đã tối ưu mà chủ yếu bằng TM-score, C1'-IDDT và sliding-window RMSD, là các đại lượng độc lập hơn với mục tiêu huấn luyện [22, 24, 23].

2.5 Đánh giá cấu trúc

TM-score ban đầu được phát triển cho protein và chuẩn hóa sai lệch cấu trúc theo độ dài [22]. US-align mở rộng căn chỉnh cấu trúc cho nucleic acid và phức hợp đại phân tử [23]. Theo quy trình cuộc thi, mỗi RNA mục tiêu được chấm bằng điểm tốt nhất qua năm mô hình và các cấu dạng thật khả dụng, sau đó lấy trung bình qua RNA mục tiêu [12]. Trong luận văn, “tốt nhất trong năm” luôn chỉ đánh giá phương án tốt nhất sẵn có; quy trình dự đoán không dùng cấu trúc thật để chọn phương án.

IDDT đo mức bảo toàn các khoảng cách cục bộ mà không cần chồng khít toàn cấu trúc [24]. Luận văn tính biến thể trên atom C1', do đó gọi là C1'-IDDT. Sliding-window RMSD trước hết chồng từng cửa sổ liên tiếp bằng Kabsch, sau đó lấy sai lệch tọa độ; cửa sổ 9 và 15 nhảy với biến dạng cục bộ hơn cửa sổ 31 hoặc RMSD toàn cấu trúc [25]. Bộ chỉ số kết hợp cho phép phân biệt sửa cục bộ đường khung với thay đổi tổng thể fold.

2.6 Khoảng trống nghiên cứu

Các bộ đánh giá đã so sánh nhiều phương pháp RNA 3D, còn bài báo cuộc thi đã cho thấy TBM vẫn cạnh tranh mạnh khi kho cấu trúc tăng trưởng [10, 12]. Tuy nhiên, một điểm leaderboard không giải thích thành phần nào tạo hiệu quả, và một thí nghiệm tách thành phần trên dữ liệu không kiểm soát thời gian có thể ưu ái việc tìm khuôn. Khoảng trống thứ nhất vì

vậy là phân tích minh bạch từng thành phần một pipeline TBM dưới mức thời gian thực tế.

Khoảng trống thứ hai là bằng chứng có kiểm soát về nguồn tính bổ sung. Nếu chỉ so hợp hai nguồn năm cấu trúc với một tập phương án ba cấu trúc, mức tăng có thể đến từ hai vị trí bổ sung. Luận văn báo cáo cả hợp hai nguồn và fixed-N để tách hai cơ chế. Khoảng trống cuối cùng là kiểm chứng Geometry Refinement trên tập xác nhận chưa dùng để chọn cấu hình, với đối chứng đơn giản, thí nghiệm tách thành phần và chỉ số độc lập. Ba khoảng trống tương ứng trực tiếp với RQ1, RQ2 và RQ3.

Chương 3

Dữ liệu và kiểm soát đánh giá

3.1 Các nguồn dữ liệu

Kaggle phát hành dữ liệu dưới dạng hai loại bảng. Bảng trình tự chứa một dòng cho mỗi RNA, gồm mã mục tiêu, chuỗi nucleotide, ngày giới hạn dữ liệu và mô tả của hệ phân tử; bảng nhãn chứa một dòng cho mỗi nucleotide, gồm mã vị trí và tọa độ C1' của một hoặc nhiều cấu dạng thực nghiệm. Cách tổ chức này tách đầu vào mà mô hình được phép đọc khỏi cấu trúc thật chỉ dùng khi huấn luyện hoặc đánh giá. Bảng 3.1 mô tả bản chụp dữ liệu được sử dụng trong dự án.

Bảng 3.1: Các tệp Kaggle chính và vai trò trong pipeline.

Tệp	Số dòng	Nội dung của một dòng	Vai trò
train_sequences.csv	844	Một RNA và metadata	Bộ huấn luyện ban đầu
train_sequences.v2.csv	5,135	Một RNA, dài 10-4,417 nucleotide	Nguồn chọn tập RNA theo thời gian
train_labels.v2.csv	3,677,095	Một nucleotide và tọa độ C1'	Cấu trúc tham chiếu công khai
validation_sequences.csv	12	Một RNA CASP15, dài 30-720 nucleotide	Phát triển và bản tái lập cục bộ
validation_labels.csv	2,515	Một nucleotide, tối đa 40 cấu dạng	Tính TM-score và chỉ số cục bộ
test_sequences.csv	12	Bản thử nghiệm trùng tập xác nhận	Kiểm tra notebook trước lần chạy lại trên dữ liệu ẩn
sample_submission.csv	2,515	ID và năm bộ tọa độ XYZ	Quy định cấu trúc bảng đầu ra 18 cột

Tập kiểm tra lưu trong repository chỉ là bản mock dựa trên CASP15. Khi Kaggle chấm notebook, code nhận bảng trình tự của các RNA ẩn tại runtime, nhưng không nhận cấu

trúc thật. Vì vậy trình tự là đầu vào của inference, còn cấu trúc thật coordinate vẫn được giữ kín để chấm điểm sau khi notebook tạo đủ năm dự đoán [12, 27]. Ngoài các bảng CSV, bản chụp dữ liệu còn có 856 tệp MSA ban đầu và 2,534 tệp MSA v2. Pipeline cuối không dùng trực tiếp các MSA này; chúng được nêu để phân biệt dữ liệu Kaggle có sẵn với dữ liệu thực sự đi vào từng nhánh thuật toán.

Thư viện khuôn được xây từ các cấu trúc PDB công khai. PDB là kho lưu trữ toàn cầu cho dữ liệu cấu trúc macromolecule và cung cấp metadata cần thiết để truy nguyên chain, trình tự cùng ngày phát hành [6]. Sau khi chuẩn hóa, bản chụp dữ liệu của dự án gồm 8,670 tệp cấu trúc, 23,869 chain RNA hoặc RNA-DNA và khoảng 10.86 triệu residue. Tỷ lệ residue có tọa độ C1' là 99.9%. MMseqs2 index chứa khoảng 20,844 chain hợp lệ, còn thư viện tổng hợp sau khử trùng lặp chứa 7,155 trình tự duy nhất. Những con số này mô tả tập kết quả đã khóa của dự án, không phải kích thước hiện tại của PDB.

CASP15 cung cấp 12 RNA dài 30-720 nucleotide và được dùng cho phát triển ban đầu. CASP là một đánh giá mù, trong đó cấu trúc RNA mục tiêu chưa công bố tại thời điểm dự đoán; bộ RNA của CASP15 đã được phân tích độc lập trong báo cáo đánh giá chính thức [9]. Vì tập RNA nhỏ và gồm nhiều RNA mục tiêu khó, luận văn dùng nó để phát triển, minh họa leakage và kiểm tra triển khai, chứ không dùng làm bằng chứng xác nhận duy nhất.

Phân tích chính sử dụng 100 RNA có ngày phát hành từ tháng 1 năm 2024 đến tháng 3 năm 2025. Mỗi RNA có năm phương án được sinh mà không đọc cấu trúc thật, gồm ba TBM và hai DRfold2. Dữ liệu được chia theo thời gian thành 60 huấn luyện, 20 hiệu chỉnh và 20 xác nhận như Bảng 3.2. Kiểm tra xác nhận không có nhóm trình tự hoặc nhóm họ nào đi qua hai phần dữ liệu. Việc vừa tách theo thời gian vừa tách họ làm giảm khả năng một motif gần xuất hiện ở cả bước chọn cấu hình và bước xác nhận.


Bảng 3.2: Phân chia dữ liệu cho Geometry Refinement và thí nghiệm tính bổ sung.

Phần dữ liệu	Số RNA	Khoảng ngày phát hành	Vai trò
Huấn luyện	60	2024-01-10 đến 2024-12-04	Ước lượng phân bố tham chiếu hình học
Hiệu chỉnh	20	2024-12-11 đến 2025-01-08	Chọn và khóa cấu hình
Xác nhận	20	2025-01-15 đến 2025-03-26	Đánh giá một lần

Điểm chính của Bảng 3.2 là mỗi phần dữ liệu chỉ có một vai trò. Tập huấn luyện tạo phân bố tham chiếu, tập hiệu chỉnh quyết định tham số và tập xác nhận chỉ đo cấu hình đã khóa. Cách bố trí này không loại bỏ mọi khác biệt giữa các họ RNA, nhưng nó tránh dùng

cùng một RNA vừa để chọn vừa để chứng minh phương pháp.

Kaggle tạo tầng đánh giá bên ngoài. Cuộc thi yêu cầu năm dự đoán cho mỗi RNA, dùng US-align trên atom C1' và trả về điểm tổng hợp của toàn tập ẩn [12, 27]. Luận văn lưu điểm public, điểm private, biên bản thực thi và mã băm của CSV public. Do Kaggle không công bố tọa độ cấu trúc thật hoặc điểm theo từng RNA, leaderboard chỉ đánh giá được toàn pipeline và không thay thế thí nghiệm tách thành phần có nhãn cục bộ.



Hình 3.1: Quy trình bằng chứng hai tầng. Ba phần dữ liệu cục bộ tách theo thời gian và họ; Kaggle đóng vai trò kiểm tra bên ngoài ở mức toàn pipeline.

Hình 3.1 làm rõ thứ tự sử dụng dữ liệu. Các mũi tên thời gian chỉ đi từ huấn luyện sang hiệu chỉnh rồi xác nhận; leaderboard bên ngoài không quay ngược vào quá trình chọn cấu hình. Đây là điều kiện quan trọng để diễn giải kết quả private như kiểm tra ngoài mẫu thay vì một lần dò tham số khác.

3.2 Mốc thời gian và loại khuôn của chính RNA mục tiêu


Với RNA mục tiêu q có mốc thời gian t_q , khuôn s chỉ hợp lệ khi

$$\text{release}(s) < t_q \quad \text{và} \quad \text{PDB}(s) \notin \mathcal{E}_q, \quad (3.1)$$

trong đó $\mathcal{E}_q$ là tập PDB cần loại cho chính RNA mục tiêu. Bất đẳng thức nghiêm ngặt tránh khuôn phát hành đúng ngày mốc thời gian đi qua do khác biệt múi giờ hoặc thứ tự cập nhật. Nếu thiếu mốc thời gian hoặc ngày phát hành, một triển khai an toàn phải loại khuôn thay vì mặc định coi khuôn là hợp lệ.

Ảnh hưởng của rò rỉ được minh họa bằng phiên bản TBM ban đầu trên CASP15. Điểm tốt nhất trong năm TM trung bình là 0.161 khi lọc theo thời gian, tăng lên 0.639 khi bỏ bộ lọc và 0.957 khi cố ý cho phép self-khuôn. Ba số này thuộc pipeline phát triển trước khi thêm

tìm kiếm tổng hợp, vì vậy chúng không được so trực tiếp với kết quả TBM 0.307 của phiên bản sau. Vai trò của thí nghiệm chỉ là cho thấy một bản chụp dữ liệu PDB không đúng thời điểm có thể làm kết quả lạc quan đến mức nào [7, 9].



Hình 3.2: Minh họa mức tăng điểm do rò rỉ khuôn trên tập RNA CASP15 phát triển. Hai cột không an toàn chỉ là chỉ số chẩn đoán và không tham gia kết quả phương pháp.

3.3 Quy tắc sử dụng nhãn

Cấu trúc thật chỉ được đọc trong các script đánh giá cục bộ sau khi phương án đã sinh. Trong thí nghiệm tính bổ sung, “tốt nhất sẵn có” nghĩa là lấy giá trị lớn nhất để đo trần của tập phương án; phép tính này không tham gia chọn cấu trúc trong quy trình dự đoán. Geometry Refinement chỉ nhận tọa độ nguồn, độ tin cậy và phân bố tham chiếu từ tập huấn luyện. Đối với mỗi phương án, cấu dạng thật dùng khi tính cục bộ chỉ số được cố định từ phương án thô để tinh chỉnh không hưởng lợi bằng cách đổi sang conformation tham chiếu dễ hơn.

Audit overlap trên CASP15 tìm thấy hai trình tự trùng chính xác với biên bản huấn luyện DRfold2: R1128 và R1138. Vì vậy các kết quả DRfold2 trên tập này được xem là phân tích phát triển và cần kèm phân tích độ nhạy sau khi loại cả hai RNA. Tập 100 RNA chính được tách theo thời gian và họ; kiểm tra không phát hiện nhóm trình tự hoặc nhóm họ đi qua hai phần dữ liệu, nhưng luận văn không khẳng định toàn bộ quá trình huấn luyện sẵn của mô hình ngôn ngữ RNA hoàn toàn không có quan hệ xa với các RNA đánh giá.

Biên bản của lần chạy public ghi nhận `native_labels_used: false`; đầu ra thử nghiệm có đúng 2,515 dòng, 18 cột, ID đúng thứ tự và tọa độ hữu hạn. SHA-256 của tệp public này là

54fe6e6598a1c2924ef7cbf03482f7ecf3c2e52e8726a1609569f777b1ac8c9a

Các kiểm tra này xác nhận cấu trúc bảng và đường dự đoán trên 12 RNA public. Điểm private

được tạo bởi lần chạy lại trên dữ liệu ẩn của Kaggle nên không được đồng nhất với tệp 2,515 dòng nói trên; điều kiện ở Phương trình 3.1 kiểm soát tính hợp lệ của khuôn ở cả hai lần chạy.

3.4 Đơn vị phân tích và thống kê

Mỗi RNA mục tiêu là một đơn vị độc lập trong mọi khoảng tin cậy. Năm phương án của cùng RNA có chung trình tự, cấu trúc thật và quá trình sinh, do đó không được xem như năm quan sát độc lập. Với tác động d_i trên n RNA mục tiêu, luận văn báo cáo

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i \quad (3.2)$$

và khoảng tin cậy phân vị từ 10,000 mẫu bootstrap, trong đó RNA mục tiêu được lấy lại có hoàn lại. Bootstrap là phương pháp ước lượng độ bất định bằng resampling từ mẫu quan sát [26]. Seed được cố định ở 2025 để tái lập kết quả.


Một tác động luôn được định hướng để giá trị dương nghĩa là tốt hơn. Với TM-score và IDDT, $d_i = m_i^{\text{new}} - m_i^{\text{base}}$; với RMSD, va chạm hoặc deviation, $d_i = m_i^{\text{base}} - m_i^{\text{new}}$. Quy ước này giúp các bảng có chung cách đọc nhưng caption phải nêu rõ đơn vị. Luận văn báo cáo trung bình, median, khoảng tin cậy và số RNA mục tiêu improve/tie/regress để tránh một trung bình che khuất trường hợp thất bại.

Chương 4

Pipeline đề xuất

4.1 Tổng quan

Pipeline nhận một trình tự RNA và mốc thời gian, sau đó sinh hai tập phương án độc lập. Nhánh TBM trả tối đa ba cấu trúc đã xếp hạng; DRfold2 trả hai cấu trúc theo độ tin cậy nội bộ. Nếu DRfold2 vượt giới hạn tài nguyên, vị trí còn thiếu được lấp bằng TBM. Geometry Refinement xử lý riêng từng phương án trong 300 bước và bộ ghi kết quả xuất đúng năm đường khung C1'. Hình 4.1 tóm tắt luồng dữ liệu.



Hình 4.1: Pipeline cuối. Đa dạng nguồn được tạo trước tinh chỉnh; không có lựa chọn hay hợp nhất tọa độ dựa trên nhãn cấu trúc thật.

Thiết kế có hai nguyên tắc. Trước hết, hệ thống tạo nhiều giả thuyết bằng cách giữ ba phương án TBM và hai phương án DRfold2. Sau đó, Geometry Refinement chỉ được phép sửa phương án trong lân cận của cấu trúc ban đầu. Bước đầu mở rộng khả năng tìm đúng nếp gấp, trong khi bước sau xử lý sai lệch hình học cục bộ; hai tác động được đánh giá riêng ở

Chương 6.

4.2 Nhánh TBM an toàn thời gian

4.2.1 Truy hồi hai đường


Nhánh thứ nhất chạy MMseqs2 trên chỉ mục gồm 20,844 chuỗi RNA. Công cụ này dùng các đoạn khớp ngắn để loại nhanh phần lớn thư viện, sau đó căn chỉnh chi tiết những chuỗi còn lại [13]. Các kết quả truy hồi được sắp theo bit score, tức điểm căn chỉnh nội bộ; pipeline chỉ căn chỉnh lại tối đa 40 kết quả hợp lệ đầu tiên để giới hạn thời gian chạy. Mỗi kết quả được gắn với chuỗi PDB, ngày phát hành và tọa độ C1' trước khi đi qua bộ lọc thời gian.

Nhánh thứ hai quét thư viện trình tự đã khử trùng lặp bằng điểm tổng hợp

$$S_{\text{comp}}(q, s) = 0.4G(q, s) + 0.3L(q, s) + 0.2F(q, s) + 0.1K_3(q, s), \quad (4.1)$$

trong đó G đo độ giống trên toàn chuỗi, còn L tìm đoạn giống nhau tốt nhất trong hai chuỗi. Cả hai dùng điểm khớp 2.9, điểm không khớp -1 , phạt mở khoảng trống -10 và phạt kéo dài khoảng trống -0.5 , rồi chuẩn hóa theo chiều dài chuỗi ngắn hơn. Thành phần F là độ tương đồng cosine giữa các vector gồm tỷ lệ A, U, G, C, mười dinucleotide, GC/AU, purine/pyrimidine, chiều dài, entropy và mức lặp motif. Hai căn chỉnh tương ứng với Needleman-Wunsch và Smith-Waterman [14, 15].

Thành phần K_3 so sánh các tập 3-mer, tức mọi đoạn liên tiếp gồm ba nucleotide. Với trình tự cần dự đoán AUGCGUAA, tập 3-mer là {AUG, UGC, GCG, CGU, GUA, UAA}. Khuôn AUGCAUAA có ba phần tử chung trong chín phần tử của hợp hai tập, nên Jaccard 3-mer bằng $3/9 = 0.333$. Ví dụ này minh họa cách K_3 ghi nhận motif ngắn mà không yêu cầu hai chuỗi giống nhau hoàn toàn. Các trọng số trong Phương trình 4.1 được kế thừa như một quy tắc cố định; thí nghiệm tách thành phần kiểm tra chúng thay vì coi công thức là một xác suất sinh học.



Hình 4.2: Luồng TBM. MMseqs2 ưu tiên RNA họ hàng rõ, tìm kiếm tổng hợp mở rộng độ phủ, còn điều kiện an toàn được áp dụng trước khi căn chỉnh lại và chuyển tọa độ.

Tìm kiếm tổng hợp quét 7,155 trình tự đã khử trùng lặp và trả thêm tối đa tám kết quả trước khi hai danh sách được hợp nhất theo mã chuỗi. MMseqs2 ưu tiên tốc độ và RNA họ hàng rõ, trong khi tìm kiếm tổng hợp đôi thêm thời gian tính toán để mở rộng khả năng tìm được khuôn. Do hai nhánh có mục tiêu khác nhau, luận văn báo riêng tỷ lệ tìm được phương án và chất lượng có điều kiện khi phương án tồn tại.

4.2.2 Căn chỉnh lại và xếp hạng

Mỗi kết quả hợp lệ được căn chỉnh toàn cục lại với trình tự cần dự đoán bằng điểm khớp 2, không khớp -1 , phạt mở khoảng trống -6 và phạt kéo dài khoảng trống -0.5 ; khoảng trống ở hai đầu không bị phạt. Căn chỉnh cuối tạo ánh xạ duy nhất giữa vị trí của RNA cần dự đoán và khuôn để chuyển tọa độ. Gọi tỷ lệ giống nhau trên các cột khớp là I , tỷ lệ RNA cần dự đoán nhận được tọa độ là C_q và tỷ lệ nucleotide khuôn có tọa độ là C_s . Điểm xếp hạng được viết

$$S_{\text{rank}} = I C_q C_s. \quad (4.2)$$

Pipeline sắp xếp trực tiếp theo toàn bộ tích $I C_q C_s$; độ hoàn chỉnh vì vậy là một thành phần của điểm chứ không phải tiêu chí phụ. Ví dụ, một kết quả có tỷ lệ giống nhau 0.900 nhưng chỉ phủ 0.400 RNA cần dự đoán sẽ nhận điểm 0.360. Kết quả khác có tỷ lệ giống nhau 0.750, độ phủ 0.950 và độ hoàn chỉnh 0.950 sẽ nhận điểm 0.677. Kết quả thứ hai được xếp cao hơn vì cung cấp tọa độ cho phần lớn RNA. Sau khi sắp xếp, pipeline lấy phương án từ các PDB khác nhau trước, rồi mới dùng các chuỗi còn lại để lấp đủ số lượng.

Điểm xếp hạng không phải độ tin cậy đã hiệu chỉnh. Nó là tín hiệu nội bộ để sắp thứ

tự phương án mà không nhìn cấu trúc thật. Điểm này đặc biệt hữu ích khi một kết quả căn chỉnh cục bộ có tỷ lệ giống nhau cao nhưng chỉ phù đoạn ngắn: nhân C_q giảm khả năng kết quả đó chiếm vị trí đầu. Tác động thực nghiệm của độ phủ được báo cáo ở Bảng 6.2.

4.2.3 Chuyển tọa độ và lấp khoảng trống

Với mỗi cặp nucleotide đã căn chỉnh, tọa độ C1' của khuôn được chép sang RNA cần dự đoán. Vị trí được chép trực tiếp giữ độ tin cậy cao, còn vị trí không được khuôn hỗ trợ nhận độ tin cậy thấp. Một khoảng trống nằm giữa hai điểm neo được nội suy; nếu hai điểm neo quá gần so với số bước cần lấp, một độ lệch hình sin vuông góc với đường thẳng được thêm vào để tránh ép cả đoạn co lại. Khoảng trống ở đầu hoặc cuối chuỗi được ngoại suy theo hướng của bước backbone gần nhất. Khi không có điểm neo, một đường khung khởi tạo xác định bảo đảm mọi tọa độ đều hữu hạn.

Nội suy đường cong chỉ nhằm tạo một phương án hợp lệ trước tinh chỉnh. Nó không mang thông tin cấu trúc thật và không thể khôi phục một motif mới chỉ từ hai điểm neo. Vì vậy, thí nghiệm chia khoảng trống theo độ dài và đo SW-RMSD9 tại nucleotide không được hỗ trợ. Kết quả chỉ cho thấy cải thiện rõ ở khoảng trống 9-20 nucleotide; các nhóm còn lại được báo cáo như kết quả trung tính thay vì suy rộng.

4.3 Nhánh DRfold2

DRfold2 nhận trình tự và chạy bộ trọng số `cfg_97` đã huấn luyện để sinh các tệp `.ret`. Mỗi tệp chứa tọa độ thô, phân bố hình học dự đoán và độ tin cậy theo nucleotide. Pipeline lấy trung bình độ tin cậy để xếp hạng mô hình, chạy Arena để dựng PDB, đọc đúng một nguyên tử C1' cho mỗi nucleotide rồi giữ hai mô hình đứng đầu. Nếu số tọa độ không bằng chiều dài trình tự hoặc có giá trị không hữu hạn, phương án bị loại. Luận văn không huấn luyện bổ sung DRfold2 bằng tập 100 RNA [16, 18].

Khác với notebook hybrid của John, nhánh này không chạy Boltz và không đưa cấu trúc Boltz vào DRfold2 như một ràng buộc kiểu AF3. DRfold2 tạo phương án trực tiếp từ bộ trọng số, còn TBM tạo phương án từ khuôn; hai danh sách chỉ gặp nhau khi lấp năm vị trí đầu ra. Sự độc lập này mô tả đường dự đoán, không có nghĩa dữ liệu huấn luyện của mô hình hoàn toàn tách khỏi PDB.

Giới hạn triển khai đã khóa là 600 nucleotide. Trong lần chạy public, DRfold2 chạy cho 11/12 RNA mục tiêu và bỏ qua RNA dài 720 nucleotide; RNA đó giữ năm TBM. Luật thay thế được xác định trước khi chạy tập ẩn, nhờ đó đầu ra luôn có năm phương án mà không

thay đổi theo điểm.

4.4 Geometry Refinement


4.4.1 Mục tiêu thiết kế

Notebook TBM của John dùng một đối chứng dựa trên luật trước khi thêm nhiều: đưa khoảng cách hai nucleotide liên tiếp về miền 5.5-6.5 Å, tách va chạm gần hơn 3.8 Å và kéo nhẹ một số cặp base bổ sung về 10.5 Å. Các luật được áp dụng một lượt với độ mạnh giảm theo độ tin cậy. Trong notebook hybrid, DRfold2 còn có Optimization và Arena, nhưng đây là phần tạo phương án từ mô hình đã huấn luyện sẵn chứ không phải một bước tinh chỉnh chung cho cả năm đầu ra. Geometry Refinement của luận văn vì vậy được định nghĩa là bước tối ưu C1' sau khi phương án TBM hoặc DRfold2 đã được tạo hoàn chỉnh.

Cho phương án nguồn $X^{(0)}$, phương pháp tìm X làm giảm một hàm mục tiêu hình học nhưng vẫn nằm gần nếp gấp ban đầu. Mục tiêu đầy đủ là

$$\mathcal{L}(X) = \lambda_s \mathcal{L}_{\text{source}} + \alpha(c) (\lambda_b \mathcal{L}_{\text{backbone}} + \lambda_a \mathcal{L}_{\text{angle}} + \lambda_t \mathcal{L}_{\text{torsion}} + \lambda_c \mathcal{L}_{\text{clash}} + \lambda_k \mathcal{L}_{\text{kink}} + \lambda_r \mathcal{L}_{R_g}) , \quad (4.3)$$

trong đó c là độ tin cậy toàn phương án và $\alpha(c) = 0.2 + 0.8(1 - c)$. Phương án có độ tin cậy cao nhận tác động hình học yếu hơn, trong khi phương án kém chắc chắn được phép thay đổi nhiều hơn. Ràng buộc giữ gần cấu trúc nguồn giới hạn dịch chuyển tổng thể; các hạng còn lại xử lý từng dạng sai lệch cục bộ.



Hình 4.3: Cơ chế Geometry Refinement. Ràng buộc nguồn giữ cấu trúc gần phương án ban đầu, trong khi các phân bố tham chiếu điều chỉnh khoảng cách, góc, góc xoắn, va chạm, gấp khúc và kích thước.

4.4.2 Phân bố tham chiếu hình học

Khoảng cách kề nhau được ký hiệu $d_i = \|\mathbf{x}_{i+1} - \mathbf{x}_i\|_2$. Trên 60 RNA huấn luyện, khoảng cách này có trung bình 6.090 Å, độ lệch chuẩn 1.110 Å và trung vị 5.660 Å. Ngưỡng va chạm giữa các điểm không liên kề là 4.180 Å. Bán kính quán tính được mô hình bằng quan hệ lũy thừa

$$\hat{R}_g(L) = 5.180L^{0.346}. \quad (4.4)$$

Các thống kê thuộc bản chụp dữ liệu của dự án, không phải hằng số vật lý phổ quát. Chúng được ước lượng chỉ trên tập huấn luyện và giữ cố định cho hiệu chỉnh cùng xác nhận.

Khoảng cách backbone không dùng xác suất từ biểu đồ phân bố. Mỗi d_i được chuẩn hóa thành $e_i = (d_i - \mu)/\sigma$, sau đó hàm Huber phạt sai lệch nhỏ theo bình phương và sai lệch lớn theo tuyến tính. Cách phạt này vẫn kéo một liên kết dài về miền thường gặp nhưng không để một giá trị ngoại lệ chi phối toàn bộ quá trình tối ưu.

Góc của ba điểm liên tiếp và góc xoắn của bốn điểm liên tiếp dùng âm log-likelihood, tức mức phạt cao khi một góc ít xuất hiện trong biểu đồ của tập huấn luyện. Hai phân bố tham chiếu được chia thành bối cảnh *pair-like*, có dấu hiệu giống một cặp base, và *unpaired*, không có dấu hiệu đó. Một nucleotide được xem là *pair-like* khi tạo cặp AU, UA, GC, CG, GU hoặc UG với một nucleotide cách ít nhất bốn vị trí và có khoảng cách C1' gần 10.5 ± 2.5 Å trong phương án nguồn. Đây là chỉ báo nội bộ không đọc cấu trúc thật, không phải xác nhận chính thức rằng hai base thật sự tạo liên kết hydro.

Điều kiện bảo vệ gấp khúc dùng ngưỡng báo cáo 70° và biên bảo vệ 5° . Nó ngăn một góc mới trở nên sắc hơn giới hạn 75° , đồng thời không ép một gấp khúc xấu có sẵn phải thẳng hoàn toàn. Hạng va chạm tách các điểm không liên kề ở quá gần nhau, còn R_g dùng hàm Huber quanh kích thước dự kiến để hạn chế cấu trúc co sụp hoặc giãn quá mức.

Đặt $h_\delta(e)$ là hàm Huber của sai số e . Ràng buộc nguồn được viết

$$\mathcal{L}_{\text{source}} = \frac{\sum_{i=1}^L w_i h_\delta(\|\mathbf{x}_i - \mathbf{x}_i^{(0)}\|_2)}{\sum_{i=1}^L w_i}, \quad (4.5)$$

trong đó w_i lớn hơn ở nucleotide được khuôn hỗ trợ hoặc có độ tin cậy mô hình cao. Cấu hình xác nhận cục bộ chạy Adam trong 300 bước, với tốc độ học 0.040 và giới hạn độ lớn gradient ở 10.000. Trọng số giữ nguồn là 1.500. Lần nộp Kaggle hybrid cũng chạy 300 bước nhưng dùng trọng số giữ nguồn 3.000; vì vậy điểm private không được trình bày như một kiểm định riêng của đúng cấu hình cục bộ 1.500.

4.4.3 Đối chứng và đầu ra

Đối chứng đơn giản chỉ giữ ràng buộc nguồn và làm mượt backbone. Đối chứng kế thừa của John dùng ba luật khoảng cách, va chạm và cặp base được mô tả ở trên. Kết quả hiện đã khóa so sánh phương pháp đầy đủ với cấu trúc thô và đối chứng đơn giản. Phép so sánh trực tiếp với refiner dựa trên luật của John trên cùng 20 RNA là thí nghiệm bổ sung chưa hoàn thành, vì vậy chưa được dùng để tạo kết luận trong bản v3.

Sau tinh chỉnh, mỗi phương án được kiểm tra kích thước $L \times 3$, tọa độ hữu hạn và thứ tự nucleotide. Bộ ghi kết quả ghép năm phương án thành các cột x_1, y_1, z_1 đến x_5, y_5, z_5 , đồng thời giữ đúng mã mẫu. Không có bước chọn nguồn theo cấu trúc thật, không hợp nhất tọa độ và không có mô hình điều phối trong pipeline cuối.

4.5 Mã giả

1. Nhận trình tự q , mốc thời gian t_q và danh sách PDB cần loại.
2. Truy hồi bằng MMseqs2 và quét tổng hợp; hợp nhất kết quả theo mã chuỗi.
3. Loại kết quả không thỏa Phương trình 3.1.
4. Căn chỉnh lại, tính $IC_q C_s$ và tạo ba phương án TBM.
5. Chạy DRfold2 nếu $L \leq 600$ và giữ hai phương án theo độ tin cậy của mô hình.
6. Nếu thiếu DRfold2, lấp vị trí bằng TBM để luôn có năm phương án.
7. Chạy Geometry Refinement độc lập trên từng phương án trong 300 bước.
8. Kiểm tra ID, kích thước, thứ tự, tính duy nhất và tọa độ hữu hạn, sau đó ghi CSV.

Mã giả cho thấy cấu trúc thật không nằm trên đường dự đoán. Mọi quyết định trước khi ghi đầu ra chỉ dùng trình tự, siêu dữ liệu của khuôn, độ tin cậy của mô hình và phân bố tham chiếu tổng hợp. Điểm của phương án tốt nhất sẵn có chỉ được tính sau khi các phương án đã sinh để phân tích giới hạn của tập phương án.

Chương 5

Thiết kế thí nghiệm

5.1 Chiến lược kiểm định

Mỗi RQ được gắn với một nhóm thí nghiệm và một kết luận tối đa. RQ1 dùng 20 RNA hiệu chỉnh để phân tích nguồn tìm kiếm, điểm tổng hợp, cách xếp hạng lại và cách lấp khoảng trống. RQ2 dùng 20 RNA xác nhận để so tập phương án trước tinh chỉnh. RQ3 dùng quy trình 60/20/20, trong đó tập xác nhận chỉ được mở sau khi khóa cấu hình. Phân tách này ngăn kết quả khám phá TBM trở thành bằng chứng xác nhận cho Geometry Refinement.

Bảng 5.1: Ánh xạ câu hỏi nghiên cứu sang thí nghiệm và kết luận được phép.

RQ	So sánh chính	Kết luận được phép
RQ1	MMseqs2, tìm kiếm tổng hợp, hợp hai nguồn; tách thành phần xếp hạng	Tìm kiếm tổng hợp mở rộng tỷ lệ tìm thấy khuôn; hiệu quả xếp hạng được định lượng theo thành phần
RQ2	3T, 2D, hợp hai nguồn; phân bổ fixed-N	TBM và DRfold2 bổ sung nhau theo RNA mục tiêu
RQ3	Cấu trúc thô, nguồn+backbone và tinh chỉnh đầy đủ; thêm dần và bỏ lần lượt từng hạng	Geometry Refinement cải thiện đường khung cục bộ trong biên bảo toàn TM

Bảng 5.1 giới hạn mức diễn giải trước khi nhìn kết quả. RQ3 không đặt giả thuyết tăng TM-score. Gate đã khóa yêu cầu đồng thời: C1'-IDDT trung bình tăng, ít nhất hai trong ba SW-RMSD9/15/31 giảm, và TM-score không giảm quá 0.005. Khoảng tin cậy cùng số RNA tăng hoặc giảm vẫn phải được báo cáo ngay cả khi gate đạt.

5.2 Đối chứng kế thừa và nguyên tắc so sánh

Ba mốc từ John được giữ tách biệt. Notebook TBM-only là mã công khai của phương pháp được bài báo cuộc thi gọi là Kaggle-winning algorithm; notebook hybrid là một phiên bản công khai kết hợp Boltz, DRfold2 và khuôn fallback; còn 0.578 là điểm submission cuối của đội john trên leaderboard. Notebook hybrid đạt 0.576 và không được coi là đồng nhất với submission thắng cuộc [12, 28, 29].

Trên CASP15, luận văn dùng hai bản tái lập của TBM John: bản không lọc thời gian để chặn đoán leakage và bản an toàn theo thời gian để so phương pháp trong cùng bối cảnh. Trên tập RNA 20 RNA chính, đối chứng tinh chỉnh hợp lệ phải nhận đúng cùng phương án thô. Rule-based refiner của John được xác định là đối chứng kế thừa; kết quả cũ trên CASP15 dùng refiner gradient trước đây nên không được dùng thay cho phép so sánh trực tiếp của Geometry Refinement.

5.3 Thí nghiệm tách thành phần TBM

Thí nghiệm nguồn tìm kiếm so sánh ba cấu hình: chỉ MMseqs2, chỉ tìm kiếm tổng hợp và hợp hai nguồn. Với MMseqs2, TM chỉ được tính có điều kiện trên RNA mục tiêu tìm thấy khuôn, đồng thời tỷ lệ tìm thấy khuôn được báo riêng. Với tổng hợp và hợp hai nguồn, trung bình tính trên đủ 20 RNA mục tiêu. Cách báo cáo này tránh so sánh 8 RNA mục tiêu dễ với 20 RNA mục tiêu đầy đủ như thể hai mẫu giống nhau.

Thí nghiệm thành phần của điểm tổng hợp so sánh G , $G + L$, $G + L + F$, tổ hợp bốn thành phần có trọng số bằng nhau, công thức đầy đủ và các biến thể đổi từng trọng số $\pm 25\%$. Tập kết quả chung được dùng để tính tỷ lệ truy hồi hữu ích ở ngưỡng TM 0.45; đại lượng này là chỉ số chặn đoán nội bộ, không phải chỉ số chính thức. Biến thể không lọc thời gian chỉ dùng để lượng hóa rò rỉ.

Thí nghiệm xếp hạng lại bắt đầu từ tỷ lệ giống nhau, rồi lần lượt thêm độ phủ truy vấn, độ hoàn chỉnh của khuôn và quy tắc chọn các PDB khác nhau. Thí nghiệm khoảng trống so nội suy thẳng với nội suy cong ở bốn nhóm độ dài 1-3, 4-8, 9-20 và trên 20 nucleotide. Mỗi khoảng trống được đo tại nucleotide không được khuôn hỗ trợ; các khoảng trống trong cùng RNA được lấy trung bình trước khi bootstrap theo RNA.

5.4 Thí nghiệm tính bổ sung

Nguồn tạo phương án được đánh giá trước Geometry Refinement để không trộn hai yếu tố. Với RNA mục tiêu i , đặt T_i là ba điểm TBM và D_i là hai điểm DRfold2. Ba đại lượng tốt nhất sẵn có là

$$O_T(i) = \max T_i, \quad O_D(i) = \max D_i, \quad O_U(i) = \max(T_i \cup D_i). \quad (5.1)$$

Mức tăng $O_U - O_T$ đo giá trị tối đa sẵn có khi thêm hai phương án DRfold2. Vì $|T_i \cup D_i| > |T_i|$, phép đo này bao gồm cả tác động của đa dạng nguồn và tác động của số lượng phương án.

Để kiểm soát số vị trí, fixed-N=2 so $2T$ với $1T + 1D$, còn fixed-N=3 so $3T$ với $2T + 1D$. Phương án trong mỗi nguồn được chọn theo thứ tự độ tin cậy mà không nhìn nhần. Bộ nhớ hiện chỉ có ba TBM và hai DRfold2 cho mỗi RNA, nên không thể dựng một sweep đủ từ $5T$ đến $5D$ mà không nhân bản phương án. Luận văn báo giới hạn này thay vì tạo một allocation giả.

5.5 Thí nghiệm Geometry Refinement

Tập huấn luyện chỉ dùng để ước lượng phân bố tham chiếu. Trên tập hiệu chỉnh, thí nghiệm thêm dần lần lượt đưa ràng buộc nguồn, backbone, góc, góc xoắn, va chạm, gấp khúc và R_g vào hàm mục tiêu. Thí nghiệm bỏ lần lượt làm điều ngược lại với cấu hình đầy đủ. Cấu hình `source_1p5` được chọn vì cải thiện chỉ số cục bộ trong khi thỏa điều kiện bảo toàn TM, sau đó được lưu cố định trước khi mở tập xác nhận.

Tập xác nhận so sánh cấu trúc thô, đối chứng nguồn+backbone và tinh chỉnh đầy đủ. Các chỉ số độc lập chính gồm C1'-IDDT, SW-RMSD9 và SW-RMSD15; tốt nhất trong năm TM-score bảo vệ nếp gấp tổng thể, còn C1 RMSD và SW-RMSD31 là chỉ số phụ. Sai lệch backbone, va chạm, số góc gấp khúc sắc, angle-NLL, torsion-NLL và sai số R_g chỉ giải thích cơ chế vì chúng nằm trong hoặc gần hàm mục tiêu. Đối chứng dựa trên luật của John sẽ được chạy trên cùng phương án thô với cùng cách cố định cấu dạng thật; cho đến khi có kết quả này, luận văn không khẳng định Geometry Refinement vượt bộ tinh chỉnh của John.

Thiết kế nhân tố fixed-N=3 tạo bốn ô: $3T$ thô, $3T$ sau tinh chỉnh, $2T + 1D$ thô và $2T + 1D$ sau tinh chỉnh. Tác động chính ước lượng mức tăng do đổi nguồn khi tắt tinh chỉnh và tác động của tinh chỉnh trong từng tập phương án. Tương tác kiểm tra tinh chỉnh có hoạt động khác nhau theo thành phần nguồn hay không. Thiết kế này trực tiếp kiểm tra liệu Geometry Refinement có thể giải thích mức tăng TM của pipeline hybrid.

5.6 Đánh giá Kaggle và khả năng tái lập

Hai submission của luận văn đã được chấm: TBM 0.602 private và hybrid 0.614 private. Chúng cho thấy hiệu quả triển khai nhưng chưa tạo thành một thí nghiệm tách thành phần một biến, vì submission TBM dùng refiner đối chứng trước đây còn submission hybrid thay tập phương án và dùng Geometry Refinement. Do đó, chênh 0.012 chỉ được gọi là tác động của toàn pipeline.

Để tách hai thành phần trên private set, quy trình bổ sung đã định nghĩa thiết kế nhân tố 2×2 gồm 5T thô, 5T sau tinh chỉnh, 3T+2D thô và 3T+2D sau tinh chỉnh. Bốn CSV phải được sinh từ cùng một lần tạo phương án để tránh nhiễu do chạy lại DRfold2. Bản v3 chưa có bốn điểm private này, vì vậy không điền số giả và không quy mức tăng Kaggle riêng cho DRfold2 hoặc tinh chỉnh.

Mọi bảng cục bộ được tạo bởi script trong repository. Bootstrap dùng seed 2025; cấu hình, nguồn phân bố tham chiếu và phương án cache được lưu cùng tệp kết quả. Audit kiểm tra một dòng metadata cho mỗi RNA, không có group đi qua phần dữ liệu, đúng ba TBM và hai DRfold2, tọa độ hữu hạn và cấu dạng thật không đổi giữa thô với sau tinh chỉnh evaluation. Danh sách tệp tái lập được ghi ở Phụ lục A.

Chương 6

Kết quả

6.1 RQ1: Truy hồi và xếp hạng TBM

6.1.1 Hai nguồn truy hồi

MMseqs2 tìm được khuôn cho 8/20 RNA hiệu chỉnh, tương ứng tỷ lệ tìm thấy khuôn 40%. Trên riêng tám RNA có khuôn, top-1 TM là 0.660 và điểm tốt nhất trong năm là 0.678. Tìm kiếm tổng hợp tạo phương án cho 20/20 RNA nhưng điểm tốt nhất trong năm trung bình chỉ 0.376. Hợp hai nguồn giữ tỷ lệ tìm thấy khuôn 100% và tăng trung bình lên 0.390. Bảng 6.1 trình bày đầy đủ ba đại lượng.

Bảng 6.1: Ảnh hưởng của nguồn truy hồi trên 20 RNA hiệu chỉnh. Chất lượng MMseqs2 được tính có điều kiện trên tám RNA tìm thấy khuôn.

Nguồn	RNA có khuôn	Tỷ lệ tìm thấy khuôn	TM tốt nhất trong năm khi có khuôn
MMseqs2-only	8/20	0.40	0.678
Composite-only	20/20	1.00	0.376
MMseqs2 + tổng hợp	20/20	1.00	0.390

Kết quả cho thấy hai nhánh tìm kiếm có vai trò khác nhau. Khi MMseqs2 nhận ra RNA họ hàng, phương án thường mạnh; tìm kiếm tổng hợp lấp 12 RNA còn thiếu nhưng độ chính xác trung bình thấp hơn. Hợp hai nguồn tăng 0.014 so với chỉ tìm kiếm tổng hợp, song khoảng tin cậy $[-0.004, 0.043]$ chứa 0 vì chỉ hai RNA mục tiêu thay đổi theo chiều tốt. Do đó, lợi ích được hỗ trợ rõ nhất là tỷ lệ tìm thấy khuôn, không phải ưu thế trung bình của mọi kết quả tìm kiếm tổng hợp.

6.1.2 Thành phần tổng hợp

Điểm tổng hợp đầy đủ đạt TM tốt nhất trong năm 0.376, trong khi chỉ dùng G đạt 0.381. Chênh lệch theo chiều G -only tốt hơn là 0.005 với khoảng tin cậy $[-0.002, 0.015]$. Các biến thể đổi trọng số $\pm 25\%$ nằm trong khoảng 0.375-0.377. Như vậy, công thức tổng hợp ổn định trước nhiễu nhỏ nhưng không có bằng chứng rằng bốn thành phần vượt căn chỉnh toàn cục trên tập này.

Tuy vậy, $G + L + F$ có tỷ lệ truy hồi hữu ích 0.676 so với 0.635 của chỉ G trong tập kết quả chung. Mẫu này phù hợp với vai trò quy tắc mở rộng khả năng tìm thấy: tín hiệu bổ sung có thể đưa phương án mới vào năm vị trí đầu dù điểm tốt nhất sẵn có trung bình chưa tăng rõ. Vì tỷ lệ truy hồi hữu ích dùng ngưỡng nội bộ, luận văn không dùng nó thay thế TM-score.

Bỏ bộ lọc thời gian làm trung bình tăng từ 0.376 lên 0.403, chênh 0.027. Khoảng tin cậy $[-0.000, 0.071]$ còn rộng và 15/20 RNA mục tiêu không đổi. Kết quả không chứng minh phương pháp không an toàn tốt hơn; nó cho thấy chỉ một vài khuôn bị rò rỉ cũng đủ dịch chuyển trung bình và vì vậy bộ lọc thời gian là yêu cầu về tính hợp lệ.

6.1.3 Xếp hạng lại và lấp khoảng trống

Thêm độ phủ của RNA cần dự đoán vào tỷ lệ giống nhau làm TM tốt nhất trong năm tăng từ 0.372 lên 0.388, tương ứng $+0.016$ với khoảng tin cậy $[-0.004, 0.045]$. Thêm độ hoàn chỉnh của khuôn không đổi điểm trên tập này; quy tắc chọn PDB khác nhau cũng giữ nguyên TM tốt nhất sẵn có dù số PDB riêng trung bình tăng từ 4.95 lên 5.00. Bảng 6.2 cho thấy độ phủ là tín hiệu chính, còn hai quy tắc sau chủ yếu bảo vệ độ ổn định và đa dạng.

Bảng 6.2: Thí nghiệm tách thành phần xếp hạng TBM.

Xếp hạng	Top-1 TM	Top-3 TM	Top-5 TM
Chỉ tỷ lệ giống nhau	0.334	0.364	0.372
Tỷ lệ giống nhau $\times$ độ phủ	0.364	0.378	0.388
+ độ hoàn chỉnh của khuôn	0.364	0.378	0.388
+ distinct PDB	0.364	0.378	0.388


Nội suy đường cong chỉ cải thiện rõ ở khoảng trống dài 9-20 nucleotide. SW-RMSD9 giảm trung bình 0.037 Å với khoảng tin cậy $[0.009, 0.068]$. Khoảng trống 1-3 và 4-8 không có bằng chứng khác nội suy thẳng, còn khoảng trống trên 20 không đổi trong triển khai hiện tại. Cơ chế hợp lý là đường cong có đủ chiều dài để tránh đoạn nối thẳng, nhưng hai điểm neo vẫn không đủ thông tin cho khoảng trống rất dài.

6.1.4 So sánh với TBM kế thừa

Trên cùng 12 RNA CASP15 và cùng điều kiện an toàn theo thời gian, bản tái lập notebook TBM của John đạt 0.298, còn pipeline TBM hiện tại đạt 0.307. Chênh lệch tuyệt đối 0.009 đi kèm kết quả tốt hơn trên 9/12 RNA. So sánh này cho thấy toàn bộ nhánh TBM sau khi thêm hai đường truy hồi, xếp hạng lại và cách xử lý phương án hoạt động tốt hơn bản tái lập, nhưng không tách riêng đóng góp của từng thay đổi; các thí nghiệm tách thành phần ở ba mục trên mới cung cấp bằng chứng thành phần.

6.2 RQ2: TBM và DRfold2 bổ sung nhau

Trước tinh chỉnh, ba TBM đạt TM-score tốt nhất sẵn có trung bình 0.565, còn hai DRfold2 đạt 0.503. Giữ cả năm phương án nâng điểm lên 0.588, tương ứng chênh lệch +0.023 với khoảng tin cậy [0.006, 0.048]. TBM cung cấp phương án tốt hơn trên 12/20 RNA, nhưng DRfold2 thắng tám RNA còn lại; giá trị của mô hình đã huấn luyện sẵn vì vậy nằm ở khả năng bổ sung những trường hợp mà tập phương án từ khuôn xử lý chưa tốt.



Hình 6.1: Tính bổ sung của tập phương án trên 20 RNA xác nhận. Mức tăng của hợp hai nguồn được tính so với ba TBM và khoảng tin cậy bootstrap theo RNA mục tiêu.

Trung bình riêng của DRfold2 thấp hơn TBM 0.063, nên kết quả không ủng hộ việc thay toàn bộ khuôn bằng mô hình học sâu. Đồng thời, phép lấy tốt nhất trong năm luôn có lợi thế cơ học so với tốt nhất trong ba. Vì vậy fixed-N được dùng để kiểm tra liệu lợi ích còn tồn tại khi hai phương pháp có cùng số vị trí dự đoán.

Với hai vị trí, $1T + 1D$ cao hơn $2T$ 0.031 và khoảng tin cậy [0.003, 0.068] nằm hoàn toàn phía dương. Với ba vị trí, $2T + 1D$ cao hơn $3T$ 0.016, nhưng khoảng tin cậy [-0.002, 0.041] chứa 0 và mười RNA hòa. Bằng chứng mạnh nhất vì vậy nằm ở tập phương

án hai vị trí; khi ba TBM đã tương đối đa dạng, lợi ích biên của một DRfold2 nhỏ và bất định hơn.

Bảng 6.3: Phân bố phương án khi tắt Geometry Refinement.

So sánh	Trung bình đối chứng	Trung bình hybrid	Mức tăng trung bình và CI 95%
$2T$ so với $1T + 1D$	0.549	0.580	+0.031 [0.003, 0.068]
$3T$ so với $2T + 1D$	0.565	0.581	+0.016 [−0.002, 0.041]
$3T$ so với $3T + 2D$	0.565	0.588	+0.023 [0.006, 0.048]


Bảng 6.3 phân biệt tác động khi giữ nguyên số lượng với tác động của tập năm phương án trong pipeline. Dòng $3T + 2D$ mô tả trần sẵn có của pipeline năm vị trí; hai dòng fixed- N kiểm tra công bằng về số lượng. Ở cả $N = 2$ và $N = 3$, thay một TBM bằng một DRfold2 làm trung bình tăng, nhưng chỉ khoảng tin cậy của so sánh hai vị trí nằm hoàn toàn phía dương.

6.3 RQ3: Geometry Refinement

6.3.1 Kết quả xác nhận

Geometry Refinement tăng C1'-IDDT từ 0.660 lên 0.666, với chênh lệch +0.007 và khoảng tin cậy [0.001, 0.013]; 12/20 RNA cải thiện. SW-RMSD9 giảm từ 2.651 xuống 2.611 Å, tương ứng giảm lỗi 0.040 Å với khoảng tin cậy [0.029, 0.052] và 19/20 RNA tốt hơn. SW-RMSD15 giảm 0.017 Å, khoảng tin cậy [0.001, 0.031], và tốt hơn trên 15/20 RNA. Ba quan sát cùng chỉ về một tác động ở phạm vi ngắn thay vì thay đổi toàn bộ cấu trúc.

TM-score thay đổi từ 0.588 xuống 0.587, tương ứng −0.001 với khoảng tin cậy [−0.003, 0.000] có chứa 0 trước khi làm tròn. Mức thay đổi nằm trong biên bảo toàn 0.005, trong khi C1 RMSD toàn cấu trúc và SW-RMSD31 chưa cho thấy thay đổi rõ ràng. Geometry Refinement vì vậy đạt điều kiện cục bộ đã khóa nhưng chưa có bằng chứng làm tăng nếp gấp tổng thể.



Hình 6.2: Tác động xác nhận của Geometry Refinement. Thay đổi điểm dùng trực riêng; mức giảm RMSD dùng đơn vị angstrom và giá trị dương nghĩa là tốt hơn.

Bảng 6.4: Cấu trúc thô và Geometry Refinement đầy đủ trên 20 RNA xác nhận.

Chỉ số	Thô	Sau tinh chỉnh	Thay đổi tốt lên	CI 95%
TM tốt nhất trong năm	0.588	0.587	-0.001	[-0.003, 0.000]
C1'-IDDT	0.660	0.666	+0.007	[0.001, 0.013]
SW-RMSD9 (Å)	2.651	2.611	+0.040	[0.029, 0.052]
SW-RMSD15 (Å)	4.273	4.256	+0.017	[0.001, 0.031]
Sai lệch backbone (Å)	1.040	0.786	+0.254	chỉ số chuẩn đoán
Va chạm trên mỗi nucleotide	0.065	0.023	+0.042	chỉ số chuẩn đoán

Bảng 6.4 cho thấy hiệu quả giảm dần khi cửa sổ đánh giá rộng hơn. SW-RMSD9 thay đổi rõ nhất, SW-RMSD15 nhỏ hơn, còn SW-RMSD31 và RMSD toàn cấu trúc chưa rõ. Mẫu theo quy mô này phù hợp với mục tiêu thiết kế: phương pháp điều chỉnh quan hệ giữa các nucleotide lân cận mà không sắp xếp lại toàn bộ nếp gấp.

6.3.2 Đối chứng đơn giản và thí nghiệm tách thành phần

Đối chứng nguồn+backbone tăng IDDT 0.008, gần tương đương mức 0.007 của phương pháp đầy đủ. Chênh lệch trực tiếp là -0.001 với khoảng tin cậy [-0.003, 0.001], nên hàm mục tiêu đầy đủ không vượt đối chứng đơn giản về IDDT. Tuy nhiên, phương pháp đầy đủ giảm SW-RMSD9 thêm 0.031 Å với khoảng tin cậy [0.020, 0.044], đồng thời tránh làm xấu góc, góc xoắn, va chạm và gấp khúc như đối chứng đơn giản.

Thí nghiệm bỏ lần lượt trên tập hiệu chỉnh liên kết từng hạng mất mát với cơ chế dự kiến. Bỏ backbone gần như làm mất mức tăng IDDT; bỏ góc, góc xoắn hoặc gấp khúc làm xấu chỉ số tương ứng; bỏ va chạm hoặc R_g cũng làm chuẩn đoán cơ chế kém hơn. Kết quả này

phù hợp với cách hàm mục tiêu được thiết kế, nhưng bằng chứng về độ chính xác vẫn dựa trên IDDT và sliding-window RMSD, không dựa vào chính hàm mất mát đã tối ưu.

6.3.3 Thiết kế nhân tố cho nguồn và tinh chỉnh

Trên tập phương án $3T$, tinh chỉnh làm TM thay đổi -0.006 với khoảng tin cậy $[-0.015, 0.001]$. Trên tập phương án $2T + 1D$, tác động là -0.003 với khoảng tin cậy $[-0.005, 0.000]$. Cận trên vẫn âm trước khi làm tròn. Tương tác bằng $+0.003$ và khoảng tin cậy chứa 0. Bảng 6.5 cho thấy tác động của thành phần nguồn dương khi tắt tinh chỉnh, trong khi tác động tinh chỉnh không dương ở cả hai tập phương án.

Bảng 6.5: Thiết kế nhân tố fixed-N=3 tách thành phần nguồn và Geometry Refinement.

Tập phương án	TM trung bình thô	TM trung bình sau tinh chỉnh
$3T + 0D$	0.565	0.559
$2T + 1D$	0.581	0.579

Thiết kế nhân tố cho thấy mức tăng TM không xuất phát từ Geometry Refinement. Khi tắt tinh chỉnh, đổi từ $3T$ sang $2T + 1D$ đã tăng trung bình 0.016; khi bật tinh chỉnh, TM giảm nhẹ ở cả hai tập phương án. Kết quả này cùng thí nghiệm tính bổ sung xác định sự đa dạng nguồn là cơ chế chính cho độ đúng tổng thể, trong khi Geometry Refinement tác động lên chỉ số cục bộ.

6.3.4 Phân tầng và trường hợp thất bại

Phân tích hậu kiểm cho thấy phương án có chất lượng ban đầu thấp tăng IDDT 0.016, khoảng tin cậy $[0.009, 0.024]$. Nhóm chất lượng cao thay đổi -0.002 với khoảng tin cậy $[-0.006, 0.002]$. Mẫu kết quả gợi ý rằng buộc giữ gần cấu trúc nguồn cố định có thể quá mạnh cho phương án yếu hoặc tinh chỉnh không cần thiết cho phương án đã tốt. Vì nhóm được định nghĩa sau khi mở xác nhận, kết quả chỉ tạo giả thuyết cho công chất lượng tương lai.


Ba trường hợp thất bại cần được báo cáo rõ. RNA 9E2Z_F và 8K7W_A giảm TM khoảng 0.009; 9B0S_Et giảm IDDT khoảng 0.011. Geometry Refinement bảo thủ vì vậy không đồng nghĩa với việc mọi RNA đều tốt lên. Khoảng tin cậy trung bình và số trường hợp cải thiện hoặc giảm cùng cần thiết để phản ánh rủi ro này.

6.4 Đánh giá bên ngoài trên Kaggle

TBM của luận văn đạt 0.601 public và 0.602 private, trong khi pipeline cuối đạt 0.628 và 0.614. Chênh lệch tuyệt đối giữa hai submission của luận văn là +0.027 public và +0.012 private. So với các mốc công khai, pipeline cuối cao hơn notebook TBM-only của John 0.021, notebook hybrid của John 0.038 và submission thắng cuộc 0.036 [28, 29]. Bảng 6.6 giữ các mốc này tách biệt để tránh đồng nhất một notebook công khai với submission cuối.

Bảng 6.6: So sánh điểm Kaggle. Dấu gạch ngang nghĩa là nguồn tham chiếu không báo mốc đó.

Phương pháp	Public TM	Private TM
Notebook hybrid John	-	0.576
Đội thắng cuộc john	-	0.578
Notebook TBM-only John	-	0.593
TBM của luận văn	0.601	0.602
Pipeline cuối của luận văn	0.628	0.614



Hình 6.3: Đánh giá trên cấu trúc ẩn. Ba mốc của John chỉ dùng điểm private được công bố; hai pipeline của luận văn có cả điểm public và private.

Lần chạy public kiểm tra đường triển khai trước lần chạy lại trên dữ liệu ẩn. DRfold2 sinh hai phương án cho 11/12 RNA; RNA dài 720 nucleotide dùng năm TBM do giới hạn 600 nucleotide. Geometry Refinement hoàn tất cho 60/60 phương án, đầu ra đúng cấu trúc bảng và biên bản xác nhận không đọc cấu trúc thật coordinate. Các kiểm tra này hỗ trợ tính toàn vẹn của submission nhưng không cho biết RNA ẩn nào tạo mức tăng.

Kết quả Kaggle cần được đọc cùng thiết kế nhân tố cục bộ. Submission cuối vừa thay hai vị trí TBM bằng DRfold2 vừa áp dụng Geometry Refinement, nên mức +0.012 private

hiện chỉ là tác động của toàn pipeline. Bảng chứng cục bộ cho thấy hybrid tập phương án tăng TM trước tinh chỉnh, trong khi tinh chỉnh cải thiện chỉ số cục bộ và làm TM giảm nhẹ. Vì vậy luận văn chưa gán bất kỳ phần cụ thể nào của mức tăng private cho Geometry Refinement. Khi chọn RNA mục tiêu đại diện, tiêu chí nên được khai báo trước, chẳng hạn RNA mục tiêu có SW-RMSD9 gần median tác động. Caption cuối cần ghi RNA mục tiêu ID, nguồn tạo phương án, thô và sau tinh chỉnh chỉ số, cửa sổ được đánh dấu cùng script tạo hình.

Chương 7

Thảo luận

7.1 Phần nào được kế thừa và phần nào là đóng góp của luận văn

Pipeline không được xây dựng từ con số không. Luận văn kế thừa ý tưởng cốt lõi của lời giải thắng cuộc: tìm cấu trúc đã biết bằng TBM, dùng mô hình học sâu để tạo thêm phương án, sau đó hậu xử lý và nộp năm cấu trúc. Việc ghi rõ nguồn gốc này quan trọng vì điểm Kaggle chỉ có ý nghĩa khoa học khi người đọc biết phần nào là tái sử dụng và phần nào đã thay đổi.

Nhánh TBM của John dùng nhiều cách tìm kiếm và các luật xếp hạng để lấy cấu trúc khuôn. Luận văn giữ nguyên nguyên lý “tìm rồi chuyển tọa độ”, nhưng thay đổi cách triển khai bằng hai nguồn truy hồi bổ sung nhau, bộ dữ liệu khuôn hợp nhất, điều kiện lọc theo thời gian, xếp hạng có xét độ phủ của RNA cần dự đoán, chọn khuôn từ các PDB khác nhau và nội suy đường cong cho khoảng trống vừa. Trên cùng 12 RNA CASP15, bản tái lập TBM của John đạt 0.298, còn TBM của luận văn đạt 0.307. Mức tăng tuyệt đối là 0.009, tương đương khoảng 3.0% so với mốc 0.298, và pipeline mới tốt hơn trên 9/12 RNA. Đây là kết quả của toàn bộ nhóm thay đổi TBM; các thí nghiệm tách thành phần ở Chương 6 cho biết thay đổi nào có bằng chứng riêng.

Nhánh học sâu cũng kế thừa hướng hybrid của John, nhưng không sao chép nguyên đường chạy. Notebook công khai của John có thể dùng DRfold2, Boltz và các nhánh dự phòng khác tùy RNA mục tiêu. Pipeline của luận văn dùng một đường chạy cố định, gồm DRfold2, bước dừng lại tọa độ bằng Arena, rồi lấy đúng nguyên tử C1'. Boltz không nằm trong pipeline cuối. Thay đổi quan trọng nhất không phải một mô hình mới, mà là thí nghiệm kiểm soát số vị trí dự đoán để đo xem DRfold2 có thật sự bổ sung cho TBM hay chỉ hưởng lợi vì có thêm phương án.

Cuối cùng, John dùng một bộ luật hậu xử lý một lượt: kéo khoảng cách giữa hai nucleotide liên tiếp về một miền định trước, tách các điểm quá gần nhau và thêm ràng buộc cho một số cặp base. Geometry Refinement của luận văn khác ở chỗ tối ưu lặp nhiều bước với các hạng giữ gần cấu trúc nguồn, độ dài backbone, góc, góc xoắn, va chạm và độ gấp khúc. Tuy nhiên, hai refiner chưa được chạy trên cùng một bộ phương án thô với cùng cách chấm. Vì vậy v3 chưa khẳng định refiner của luận văn tốt hơn refiner của John; đây là phép so sánh còn thiếu cần hoàn thành trước bản nộp cuối.

7.2 Vì sao kết hợp TBM và DRfold2 có giá trị

Kết quả không cho thấy DRfold2 luôn mạnh hơn TBM. TBM có điểm trung bình cao hơn và thắng trên 12/20 RNA, trong khi DRfold2 thắng trên tám RNA còn lại. Điều quan trọng nằm ở tám trường hợp đảo thứ tự này. Khi Kaggle lấy cấu trúc tốt nhất trong năm dự đoán để tính điểm, một nguồn mới có thể nâng kết quả chung dù điểm trung bình riêng của nguồn đó thấp hơn.

So sánh hai vị trí làm rõ cơ chế trên. Khi giữ nguyên hai cơ hội dự đoán, tổ hợp một TBM và một DRfold2 cao hơn hai TBM 0.031 điểm, với khoảng tin cậy hoàn toàn ở phía dương. Ở ba vị trí, thay một trong ba TBM bằng DRfold2 tăng 0.016 điểm, nhưng khoảng tin cậy còn chứa 0. Bằng chứng mạnh nhất vì vậy nằm ở cấu hình hai vị trí. Tỷ lệ ba TBM và hai DRfold2 trong pipeline cuối là một lựa chọn hợp lý cho dữ liệu hiện có, chứ chưa phải tỷ lệ tối ưu cho mọi bộ RNA.

Đặc điểm cuộc thi giúp giải thích vì sao TBM vẫn rất mạnh. Bài báo tổng kết cho biết 19/20 RNA mục tiêu private có ít nhất một cấu trúc cũ đạt TM-align trên 0.45 [12]. Nói đơn giản, phần lớn RNA ẩn có một khuôn tương đối giống trong kho dữ liệu. Một bản chụp dữ liệu khuôn lớn và cách tìm rộng vì thế có lợi. Kết luận này không tự động áp dụng cho RNA không có họ hàng gần; ở những trường hợp đó, DRfold2 đóng vai trò tạo phương án thay thế.

7.3 Vì sao Geometry Refinement không làm tăng TM-score

Geometry Refinement được thiết kế để sửa các sai lệch nhỏ quanh cấu trúc ban đầu. Hạng giữ gần nguồn ngăn tọa độ trôi quá xa, còn các hạng backbone, góc, góc xoắn và va chạm chủ yếu tác động lên các nucleotide lân cận. Chúng không cung cấp thông tin mới về việc hai đoạn RNA ở xa nhau phải tiếp xúc ở đâu. Bởi vậy, phương pháp có thể làm đoạn ngắn mượt và hợp lý hơn nhưng khó biến một nếp gấp tổng thể sai thành đúng.

Kết quả phản ánh đúng giới hạn đó. C1'-IDDT tăng 0.007, SW-RMSD9 giảm 0.040 Å,

còn TM-score thay đổi -0.001 . Đối chứng đơn giản chỉ giữ gần nguồn và sửa backbone đã tạo phần lớn mức tăng IDDT. Hàm mục tiêu đầy đủ không tốt hơn đối chứng này về IDDT, nhưng giảm thêm 0.031 Å ở SW-RMSD9 và cân bằng tốt hơn các chỉ số hình học. Vì vậy đóng góp được bảo vệ ở phạm vi hẹp: phương pháp cải thiện chất lượng cục bộ trung bình mà giữ gần như nguyên nếp gấp, chứ không làm tăng TM-score.

Cần phân biệt kết quả này với bộ luật của John. Số liệu hiện tại so Geometry Refinement với cấu trúc thô và với một đối chứng làm mượt đơn giản, chưa phải với bộ tinh chỉnh dựa trên luật của John. Phép chạy trực tiếp trên cùng phương án sẽ cho biết phương pháp mới có mang lại lợi ích ngoài phần hậu xử lý đã được kế thừa hay không. Nếu không vượt được đối chứng đó, luận văn phải thu hẹp khẳng định thành một phân tích về đánh đổi giữa độ đúng toàn cục và tính hợp lý cục bộ.

7.4 Cách đọc điểm Kaggle

Pipeline cuối đạt 0.614 private. Điểm này cao hơn TBM của luận văn 0.012 , tương đương khoảng 2.0% so với mốc 0.602 . Nó cũng cao hơn notebook TBM-only của John 0.021 (khoảng 3.5%), notebook hybrid công khai 0.038 (khoảng 6.5%) và điểm private của đội thắng cuộc 0.036 (khoảng 6.3%). Các tỷ lệ phần trăm chỉ giúp diễn giải độ lớn tương đối; đại lượng chính vẫn là chênh lệch TM-score tuyệt đối.

Không nên diễn giải 0.012 là đóng góp riêng của DRfold2 hoặc Geometry Refinement. Hai lần nộp hiện có khác nhau ở cả nguồn phương án và bước hậu xử lý. Hơn nữa, cấu hình cục bộ đã xác nhận dùng trọng số giữ nguồn 1.5 , trong khi lần chạy Kaggle dùng 3.0 . Điểm 0.614 vì thế chứng minh toàn pipeline vận hành tốt trên dữ liệu ẩn, nhưng không phải một thí nghiệm tách thành phần một biến của đúng cấu hình cục bộ.

Bằng chứng hiện tại nên được đọc theo ba lớp. Kiểm tra triển khai xác nhận submission không đọc cấu trúc thật và tuân lọc thời gian. Thí nghiệm cục bộ cho thấy sự đa dạng giữa TBM với DRfold2 làm tăng TM-score trước tinh chỉnh. Thí nghiệm Geometry Refinement cho thấy lợi ích cục bộ nhưng không tăng TM-score. Ba lớp này giải thích kết quả mà không gán sai quan hệ nhân quả. Factorial private gồm 5T thô, 5T sau tinh chỉnh, 3T+2D thô và 3T+2D sau tinh chỉnh vẫn cần được chạy để tách hai thành phần trên Kaggle.

7.5 Giới hạn của nghiên cứu

Mỗi phân dữ liệu hiệu chỉnh và xác nhận chỉ có 20 RNA. Bootstrap theo RNA giúp ước lượng độ bất định, nhưng không thể thay thế một tập dữ liệu lớn hơn [26]. Một số khoảng tin cậy

còn rộng, đặc biệt ở thí nghiệm tách thành phần TBM và cấu hình ba vị trí. Các phân nhóm chất lượng phương án được xem sau khi mở kết quả nên chỉ tạo giả thuyết, không được dùng như bằng chứng xác nhận.

Tập xác nhận cục bộ gồm RNA đơn chuỗi dài tối đa 96 nucleotide, trong khi Kaggle có RNA mục tiêu dài đến 720 nucleotide. Kết quả Geometry Refinement vì thế chưa trực tiếp khái quát cho RNA rất dài, phức hợp nhiều chuỗi hoặc tương tác RNA-protein. Ngoài ra, R1128 và R1138 trong CASP15 có trùng lặp chính xác với dữ liệu huấn luyện công khai của DRfold2. Luận văn phải báo riêng phân tích có và không có hai RNA mục tiêu này để người đọc đánh giá mức ảnh hưởng.

TM-score, C1'-IDDT và SW-RMSD đều chấm đường nối qua nguyên tử C1', tức là một biểu diễn rút gọn của RNA. Chúng không trực tiếp đo hướng base, liên kết hydro, ion kim loại hoặc toàn bộ hình học nguyên tử [4, 2]. Các chỉ số góc, góc xoắn, va chạm và gấp khúc lại nằm trong hoặc gần hàm tối ưu nên chỉ dùng giải thích cơ chế. Bằng chứng độc lập chính vẫn là TM-score, C1'-IDDT và SW-RMSD; đánh giá toàn nguyên tử là công việc tiếp theo.

7.6 Công việc cần hoàn thành

Ưu tiên thứ nhất là chạy bộ tinh chỉnh của John và Geometry Refinement trên đúng cùng phương án thô, cùng cấu dạng thật và cùng chỉ số. Ưu tiên thứ hai là tạo bốn submission private theo thiết kế 2×2 đã khóa. Hai phép đo này quyết định liệu có thể khẳng định cải thiện so với phương pháp hậu xử lý kế thừa hay chỉ nên báo lợi ích toàn pipeline.

Sau đó, nghiên cứu có thể thử một công chất lượng đã định nghĩa trước. Công này bỏ qua tinh chỉnh khi phương án ban đầu đã tốt, vì phân tích hậu kiểm gợi ý nhóm mạnh ít hưởng lợi. Việc chọn ngưỡng phải thực hiện trên tập hiệu chỉnh mới và kiểm tra trên một tập chưa mở để tránh khớp quá mức. Một hướng khác là sinh năm TBM và năm DRfold2 độc lập, từ đó đo đầy đủ mọi tỷ lệ phân bổ thay vì bị giới hạn bởi cache ba cộng hai hiện nay.

Chương 8

Kết luận

Luận văn kế thừa khung TBM kết hợp mô hình học sâu của lời giải thắng cuộc, sau đó xây dựng lại thành một pipeline có kiểm soát thời gian, thí nghiệm tách thành phần và Geometry Refinement riêng. Nghiên cứu không xem một điểm Kaggle duy nhất là bằng chứng đầy đủ, mà tách việc tìm khuôn, đa dạng nguồn phương án và hậu xử lý cục bộ thành ba câu hỏi.

Đối với RQ1, MMseqs2 cung cấp phương án mạnh khi tìm thấy RNA họ hàng nhưng chỉ phủ 8/20 RNA hiệu chỉnh. Composite search mở rộng độ phủ lên 20/20, tức tăng 60 điểm phần trăm. Điểm tổng hợp đầy đủ không thắng rõ tổng thể căn chỉnh đơn lẻ, còn độ phủ truy vấn là tín hiệu xếp hạng hữu ích nhất. Trên CASP15, toàn bộ TBM mới tăng từ 0.298 lên 0.307 so với bản tái lập của John.

Đối với RQ2, TBM có trung bình cao hơn DRfold2 nhưng hai nguồn thắng trên các RNA mục tiêu khác nhau. Giữ cả hai nguồn tăng điểm tốt nhất sẵn có 0.023 với khoảng tin cậy dương, và phép so sánh cùng hai vị trí vẫn tăng 0.031. Đây là bằng chứng trực tiếp rằng sự đa dạng nguồn có thể nâng điểm tốt nhất trong năm dự đoán dù không có nguồn nào luôn vượt nguồn kia.

Đối với RQ3, Geometry Refinement tăng C1'-IDDT 0.007, giảm SW-RMSD 0.040 Å và làm TM-score thay đổi -0.001 . Đối chứng đơn giản giải thích phần lớn mức tăng IDDT, còn hàm mục tiêu đầy đủ tốt hơn ở cửa sổ ngắn và cân bằng nhiều chỉ số hình học hơn. Kết luận phù hợp là tinh chỉnh sửa quan hệ cục bộ và gần như bảo toàn nếp gấp tổng thể trung bình.

Pipeline cuối đạt 0.628 public và 0.614 private. Điểm private cao hơn notebook TBM-only của John 0.021, notebook hybrid công khai 0.038 và đội thắng cuộc 0.036. Đây vẫn là so sánh toàn pipeline, không phải bằng chứng rằng từng thành phần riêng đều vượt bản gốc. Factorial cục bộ cho thấy cơ chế toàn cục được hỗ trợ tốt nhất là sự bổ sung giữa TBM với DRfold2, còn Geometry Refinement đem lại lợi ích cục bộ riêng. So sánh trực tiếp hai refiner

và thiết kế nhân tố private là hai thí nghiệm cần hoàn thành trước khi khóa luận văn.

Phụ lục A

Khả năng tái lập

Các tệp kết quả chính gồm:

- `scripts/run_tbm_whitebox_ablation.py`: thí nghiệm tách thành phần TBM;
- `scripts/summarize_hybrid_complementarity.py`: phân bổ phương án và tính bổ sung giữa các nguồn;
- `reports/thesis_notes/tbm_whitebox_ablation.md`: bảng RQ1;
- `reports/thesis_notes/hybrid_complementarity.md`: bảng RQ2;
- `reports/thesis_notes/kaggle_submission_analysis.md`: biên bản và điểm đánh giá bên ngoài;
- `scripts/generate_thesis_v3_figures.py`: tạo toàn bộ hình dữ liệu trong bản thảo này.

Chương trình chạy xác nhận và báo cáo chi tiết RQ3 được lưu trong repository cùng cấu hình đã khóa. Khi đóng gói bản cuối, nên thêm biên bản gồm Git commit, môi trường phần mềm Python, mã kiểm tra của cơ sở dữ liệu khuôn, phiên bản mô hình đã huấn luyện sẵn và lệnh chạy cho từng bảng.

Phụ lục B

Danh mục kiểm tra trước khi nộp

Các hình dữ liệu được tạo từ kết quả đã khóa bằng script trong Phụ lục A. Trước khi nộp, cần đối chiếu từng con số trong hình với bảng nguồn, kiểm tra khả năng đọc khi in đen trắng và xác nhận cỡ chữ ở mức thu phóng 100%. Nếu bổ sung hình chồng cấu trúc, hình đó phải dùng một RNA xác nhận công khai được chọn theo tiêu chí định trước, ghi rõ RNA mục tiêu, nguồn phương án, chỉ số trước và sau cùng chương trình tạo hình. Không dùng cấu trúc ẩn của Kaggle để dựng ví dụ minh họa.

Tài liệu tham khảo

- [1] J. Zhang, Y. Fei, L. Sun, and Q. C. Zhang, “Advances and opportunities in RNA structure experimental determination and computational modeling,” *Nature Methods*, vol. 19, pp. 1193-1207, 2022. doi: 10.1038/s41592-022-01623-y.
- [2] X. Cao, Y. Zhang, Y. Ding, and Y. Wan, “Identification of RNA structures and their roles in RNA functions,” *Nature Reviews Molecular Cell Biology*, vol. 25, pp. 784-801, 2024. doi: 10.1038/s41580-024-00748-6.
- [3] I. Tinoco Jr. and C. Bustamante, “How RNA folds,” *Journal of Molecular Biology*, vol. 293, no. 2, pp. 271-281, 1999. doi: 10.1006/jmbi.1999.3001.
- [4] S. E. Butcher and A. M. Pyle, “The Molecular Interactions That Stabilize RNA Tertiary Structure: RNA Motifs, Patterns, and Networks,” *Accounts of Chemical Research*, vol. 44, no. 12, pp. 1302-1311, 2011. doi: 10.1021/ar200098t.
- [5] H. Ma, X. Jia, K. Zhang, and Z. Su, “Cryo-EM advances in RNA structure determination,” *Signal Transduction and Targeted Therapy*, vol. 7, article 58, 2022. doi: 10.1038/s41392-022-00916-0.
- [6] S. K. Burley and coauthors, “Protein Data Bank: the single global archive for 3D macromolecular structure data,” *Nucleic Acids Research*, vol. 47, no. D1, pp. D520-D528, 2019. doi: 10.1093/nar/gky949.
- [7] J. A. Cruz and coauthors, “RNA-Puzzles: A CASP-like evaluation of RNA three-dimensional structure prediction,” *RNA*, vol. 18, no. 4, pp. 610-625, 2012. doi: 10.1261/rna.031054.111.
- [8] M. Magnus, M. Antczak, T. Zok, and coauthors, “RNA-Puzzles toolkit: a computational resource of RNA 3D structure benchmark datasets, structure manipulation, and evaluation tools,” *Nucleic Acids Research*, vol. 48, no. 2, pp. 576-588, 2020. doi: 10.1093/nar/gkz1108.

- [9] R. Das and coauthors, “Assessment of three-dimensional RNA structure prediction in CASP15,” *Proteins: Structure, Function, and Bioinformatics*, vol. 91, no. 12, pp. 1747-1770, 2023. doi: 10.1002/prot.26602.
- [10] C. Bernard, G. Postic, S. Ghannay, and F. Tahi, “State-of-the-RNArt: benchmarking current methods for RNA 3D structure prediction,” *NAR Genomics and Bioinformatics*, vol. 6, no. 2, article lqae048, 2024. doi: 10.1093/nargab/lqae048.
- [11] X. Wang, S. Yu, E. Lou, Y. L. Tan, and Z. J. Tan, “RNA 3D Structure Prediction: Progress and Perspective,” *Molecules*, vol. 28, no. 14, article 5532, 2023. doi: 10.3390/molecules28145532.
- [12] Y. Lee, S. He, T. Oda, and coauthors, “Template-based RNA structure prediction advanced through a blind code competition,” *bioRxiv*, preprint 2025.12.30.696949, 2025. doi: 10.64898/2025.12.30.696949.
- [13] M. Steinegger and J. Söding, “MMseqs2 enables sensitive protein sequence searching for the analysis of massive data sets,” *Nature Biotechnology*, vol. 35, pp. 1026-1028, 2017. doi: 10.1038/nbt.3988.
- [14] S. B. Needleman and C. D. Wunsch, “A general method applicable to the search for similarities in the amino acid sequence of two proteins,” *Journal of Molecular Biology*, vol. 48, no. 3, pp. 443-453, 1970. doi: 10.1016/0022-2836(70)90057-4.
- [15] T. F. Smith and M. S. Waterman, “Identification of common molecular subsequences,” *Journal of Molecular Biology*, vol. 147, no. 1, pp. 195-197, 1981. doi: 10.1016/0022-2836(81)90087-5.
- [16] Y. Li, C. Zhang, C. Feng, R. Pearce, P. L. Freddolino, and Y. Zhang, “Integrating end-to-end learning with deep geometrical potentials for ab initio RNA structure prediction,” *Nature Communications*, vol. 14, article 5745, 2023. doi: 10.1038/s41467-023-41303-9.
- [17] T. Shen, Z. Hu, S. Sun, and coauthors, “Accurate RNA 3D structure prediction using a language model-based deep learning approach,” *Nature Methods*, vol. 21, pp. 2287-2298, 2024. doi: 10.1038/s41592-024-02487-0.
- [18] Y. Li, C. Feng, X. Zhang, S. Tsukiyama, D. Feng, and Y. Zhang, “DRfold2 is a deep learning-based tool that enables efficient and accurate RNA structure prediction,” *PLOS Biology*, vol. 24, no. 2, article e3003659, 2026. doi: 10.1371/journal.pbio.3003659.

- [19] R. J. L. Townshend, S. Eismann, A. M. Watkins, and coauthors, “Geometric deep learning of RNA structure,” *Science*, vol. 373, no. 6558, pp. 1047-1051, 2021. doi: 10.1126/science.abe5650.
- [20] P. Stasiewicz, S. Mukherjee, C. Nithin, and J. M. Bujnicki, “QRNAS: software tool for refinement of nucleic acid structures,” *BMC Structural Biology*, vol. 19, article 5, 2019. doi: 10.1186/s12900-019-0103-1.
- [21] Z. R. Perry, A. M. Pyle, and C. Zhang, “Arena: Rapid and Accurate Reconstruction of Full Atomic RNA Structures From Coarse-grained Models,” *Journal of Molecular Biology*, vol. 435, article 168210, 2023. doi: 10.1016/j.jmb.2023.168210.
- [22] Y. Zhang and J. Skolnick, “Scoring function for automated assessment of protein structure template quality,” *Proteins: Structure, Function, and Bioinformatics*, vol. 57, no. 4, pp. 702-710, 2004. doi: 10.1002/prot.20264.
- [23] C. Zhang, M. Shine, A. M. Pyle, and Y. Zhang, “US-align: universal structure alignments of proteins, nucleic acids, and macromolecular complexes,” *Nature Methods*, vol. 19, pp. 1109-1115, 2022. doi: 10.1038/s41592-022-01585-1.
- [24] V. Mariani, M. Biasini, A. Barbato, and T. Schwede, “lDDT: a local superposition-free score for comparing protein structures and models using distance difference tests,” *Bioinformatics*, vol. 29, no. 21, pp. 2722-2728, 2013. doi: 10.1093/bioinformatics/btt473.
- [25] W. Kabsch, “A solution for the best rotation to relate two sets of vectors,” *Acta Crystallographica Section A*, vol. 32, pp. 922-923, 1976. doi: 10.1107/S0567739476001873.
- [26] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman and Hall/CRC, 1993.
- [27] Stanford University and Kaggle, “Stanford RNA 3D Folding,” Kaggle competition documentation, 2025. Available: <https://www.kaggle.com/competitions/stanford-rna-3d-folding>.
- [28] G. John Rao (JaeJohn), “RNA 3D folds: TBM-only approach,” Kaggle notebook, version 1, 2025. Available: <https://www.kaggle.com/code/jaejohn/rna-3d-folds-tbm-only-approach>.
- [29] G. John Rao (JaeJohn), “[sub-1] 4/4 hybrid - final take,” Kaggle notebook, version 4, 2025. Available: <https://www.kaggle.com/code/jaejohn/sub-1-4-4-hybrid-final-take>.